CONTENTS

10주차 모델을 어떻게 내보내고, 무엇으로 통과시키는가

1. 오늘의 질문

2. 이 장에서 실행할 것

시작 전 준비

3. 배치는 계산이 멈춘 사실을 알리는 장치를 따로 두어야 한다

4. 서빙 API는 응답에 모델 신원을 싣고 입력 규격을 검사한다

5. shadow는 이용자에게 영향 없이 후보를 시험한다

6. 검증은 여러 단계에서 반복하고, 같은지는 바이트로 확인한다

7. 핵심 요약

8. 과제

9. 더 알아보기

10주차 모델을 어떻게 내보내고, 무엇으로 통과시키는가

> **10주차 · 모델 배포와 CI/CD**
>
> 이 장의 수치는 대부분 `practice/chapter10/`의 코드를 실행해 얻은 값이다. 인용한 값의 출처 파일은 출력 블록 첫 줄에 적었다. 실행하지 않은 숫자는 5절에서 배포 방법 세 가지를 비교할 때 쓴 "요청 6건 중 1건" 하나뿐이며, 그 자리에 가정이라고 밝혔다.
>
> 한 가지 예외가 있다. Docker 컨테이너에서 서빙 API를 띄운 결과는 이 강의 환경에서 다시 돌릴 수 없어 **과거 실행이 남긴 산출물에서 옮긴 값**이며, 그 블록의 출처는 `practice/chapter10/data/output/`으로 적었다.

☐ 9주차에서 champion 별칭까지 붙은 모델은 아직 실습 스크립트 안에서만 실행됨

- ○ 이용자는 스크립트를 실행하지 않음. 다른 프로그램이 요청을 보내면 답을 돌려주도록, 모델을 서버에서 계속 실행해 두어야 함
- ○ 이 장은 모델을 서버에서 실행하는 방법과, 새 모델을 서버에 넣기 전에 무엇을 확인하는지를 다룸

☐ 이 장도 설명과 실습을 나누지 않음

- ○ 절마다 실행할 명령이 나오고, 출력을 한 덩어리씩 끊어 그 바로 아래에서 설명함
- ○ 순서대로 실행하면 이 장의 수치를 직접 만들 수 있음

1. 오늘의 질문

☐ 예측을 미리 만들어 둘 것인가, 요청이 도착한 순간 계산할 것인가?

☐ 서빙 API가 "지금 어느 모델로 답하고 있는가"에 답하지 못하면 무엇을 잃는가?

☐ 새 모델 후보를 이용자에게 위험을 주지 않고 실제 요청으로 시험해 볼 수 있는가?

☐ 같은 확인을 왜 여러 단계에서 반복하는가?

2. 이 장에서 실행할 것

☐ 모델을 내보내기 전에 다섯 가지를 확인하며, 각각 다른 절에서 실행함

확인할 것	어떻게 확인하는가	다루는 절
앱이 입력 규격과 응답 규격을 지키는가	서버를 띄우지 않고 앱 함수를 직접 호출해 요청 7건을 보냄	4
실제 프로세스로 띄워도 기동되는가	내 컴퓨터(호스트)에서 서빙 프로세스를 띄워 같은 요청을 보냄	6
환경이 바뀌어도 같은 답을 내는가	컨테이너에서 같은 요청을 보내고 두 답을 비교함	6
지금 어느 모델로 답하는지 말할 수 있는가	응답에 모델 이름·버전·불러온 곳 세 칸을 함께 넣음	4
새 후보를 이용자 위험 없이 시험할 수 있는가	요청을 후보에도 똑같이 보내되 이용자에게는 champion의 답만 돌려줌	5

표 10.1 이 장에서 실행하는 다섯 가지 확인

☐ 셋째 확인(환경이 바뀌어도 같은가)은 숫자로 따로 확인함

- ○ 두 파일의 내용이 줄마다 똑같아도, 줄 끝 처리 방식(줄바꿈 규약) 하나만 다르면 sha256 해시가 달라짐
- ○ 그래서 배포에서는 “같은 코드인가”에서 멈추지 않고 “파일의 바이트가 같은가”까지 계산함. 6절 출력 [4]에서 그 차이를 숫자로 봄

☐ 이 장에서 실행할 코드는 넷이며 순서가 정해져 있음

순서	실행할 파일	하는 일	절	선행 조건
1	`10-2-batch-vs-online.py`	계산이 멈췄을 때 배치와 온라인에서 오류가 나는지 비교	3	9주차 산출물(저장소 포함)
2	`10-3-serving-contract.py`	신원 응답과 입력 검증 규칙 적용	4	9주차 산출물
3	`10-4-shadow-compare.py`	champion·challenger를 나란히 실행하고 후보 재평가	5	9주차 산출물
4	`10-5-release-gate.py`	배포 검수표 재계산과 바이트 비교	6	10주차 산출물(저장소 포함)
선택	`10-1-model-api/`	FastAPI·Docker로 실제 서빙 API 구동	4·6	mlflow·FastAPI·Docker

☐ 1~4번은 9주차가 남긴 훈련 쌍과 이 장의 과거 실행 기록을 입력으로 읽음

- ○ 넷은 서로의 출력을 입력으로 쓰지 않으므로 순서를 바꿔 실행해도 결과가 같음
- ○ 선택 실습만 패키지 설치와 Docker가 필요함

시작 전 준비

☐ 1~4번은 표준 라이브러리만 쓰므로 설치할 패키지가 없음(실습 검증 환경은 Python 3.13)

☐ 선택 실습은 mlflow·FastAPI·pytest를 설치해야 하고, 컨테이너 단계는 Docker 데몬이 켜져 있어야 함

○ 아래 명령을 실행하면 Python 버전·패키지·Docker 데몬을 점검하고 가상환경을 만듦

```
python scripts/setup_practice.py 10
```

3. 배치는 계산이 멈춘 사실을 알리는 장치를 따로 두어야 한다

☐ 모델을 만들었다고 예측이 이용자에게 전달되지는 않음. 누군가 어느 시점에 모델을 실행해야 하며, 실행 시점은 둘 중 하나임

○ **배치 추론(batch inference)**: 예측을 미리 만들어 표에 저장해 둠

– 예: 매일 밤 서울 자치구 전부의 다음 날 민원 건수를 한꺼번에 계산해 표에 넣어 둠. 낮에 누가 조회하면 계산하지 않고 표에서 값을 꺼내 줌

○ **온라인 추론(online inference)**: 요청이 도착한 순간 계산함

– 예: 이용자가 입력을 보내면 그때 모델을 실행해 답을 만듦

☐ 어느 쪽을 쓸지는 두 질문으로 정함

○ 요청이 와야만 알 수 있는 입력이 있는가

– 이용자가 방금 입력한 값이나 현재 위치는 미리 알 수 없으므로 배치로 계산해 둘 수 없음

○ 예측할 대상을 미리 전부 적을 수 있는가

– “서울 자치구별 내일 건수”는 미리 다 계산해 둘 수 있음. 입력 조합이 끝없이 많으면 미리 계산할 수 없음

☐ 둘의 가장 큰 차이는 **계산이 멈췄을 때 담당자가 따로 확인하지 않아도 알게 되는가**임 — 온라인은 요청마다 오류가 나므로 바로 알게 되고, 배치는 실패 알림이나 날짜 검사를 따로 두지 않으면 오류 없이 어제 값을 내주므로 아무도 모름

☐ 배치에서는 프로그램 두 개가 따로 돌기 때문에, 알림이나 날짜 검사를 두지 않으면 담당자가 고장을 알 수 없음

○ 계산 프로그램: 하루 한 번 예측을 계산해 표에 덮어씀

- ○ 조회 프로그램: 요청이 오면 표에 적힌 값을 꺼내 돌려줌. 이 실습의 표에는 예측값만 있고 계산한 날짜가 없으므로, 조회 프로그램은 그 표가 오늘 것인지 어제 것인지 구분하지 못함(날짜를 함께 저장하면 구분할 수 있으며, 출력 [5]에서 확인함)

□ 계산 프로그램이 멈추면 다음 일이 차례로 일어남(아래 실습의 challenger 모델 값)

- ○ 7월 2일 기준 표는 이미 만들어져 있고, 강남구 칸에 6.1364가 적혀 있음
- ○ 7월 3일 기준 표를 만들 계산 프로그램이 멈춤. 제대로 돌았다면 강남구 칸이 6.9545로 바뀌었어야 함
- ○ 7월 3일에 조회가 오면 조회 프로그램은 표에서 6.1364를 꺼내 정상 응답(응답 코드 200)으로 돌려줌. 표가 남아 있으므로 꺼내는 일 자체는 성공함
- ○ 화면에는 오류가 0건이므로 담당자는 6.1364를 오늘 예측으로 알고 씀. 1주차의 침묵 실패(오류 메시지 없이 틀린 결과가 나가는 실패)가 예측 단계에서 다시 생김

□ 온라인에는 미리 계산한 표가 없으므로, 모델을 불러오지 못하는 고장은 담당자가 바로 알게 됨

- ○ 요청이 올 때마다 그 자리에서 모델을 실행해 답을 만듦
- ○ 모델 파일을 불러오지 못하면 돌려줄 값이 아예 없으므로, 요청마다 “모델 로드 실패” 오류를 돌려줌
- ○ 아래 실습에서는 조회 3건이 모두 오류로 끝남. 담당자는 오류가 뜬 그 순간 고장을 알게 됨
- ○ 다만 모델을 불러온 뒤 틀린 값을 내는 경우(잘못된 버전을 불러옴, 11주차의 드리프트)에는 온라인도 오류 없이 틀린 값을 돌려줌

□ 첫 번째 코드를 실행함. 9주차가 남긴 훈련 쌍으로 모델 둘을 다시 만들어 배치 표를 채우고, 배치와 온라인을 각각 고장 내 봄

```
cd practice/chapter10
python3 code/10-2-batch-vs-online.py
```

```
# 출처: practice/chapter10/results/10-2-batch-vs-online.log
[1] 입력 — 9장 훈련 쌍 6개, 자치구 3개
    지문 96f6b6b3ce9dcdd1… (9장 산출물과 동일)
    champion(평균 예측기) 훈련 y 평균 36/6 = 6.0
    challenger(선형회귀) 절편 3.6818  기울기 0.4091
    자치구별 전일 건수  어제(2026-07-02) {'11440': 5, '11620': 5, '11680': 6}  오늘
(2026-07-03) {'11440': 5, '11620': 5, '11680': 8}
```

□ [1]에서 읽을 것

- ○ **9주차와 같은 데이터로 같은 모델을 만듦** — 훈련 데이터 지문 앞 16자가 9주차 값 `96f6b6b3ce9d-cdd1`과 같음
- ○ **두 모델이 답을 만드는 방식이 다름**

  - champion(v1)은 입력을 보지 않고 훈련 데이터의 당일 건수 평균 6.0(= 36 ÷ 6)만 냄
  - challenger(v2)는 전일 건수를 넣어 계산함. 계수를 분수로 쓰면 예측 = (81 + 9 × 전일 건수) ÷ 22임(9주차 `9-3-train-and-rerun.log`의 기울기 9/22, 절편 81/22)

○ 자치구 코드 11440은 마포구, 11620은 관악구, 11680은 강남구임. 전일 건수가 어제와 오늘 사이에 바뀐 곳은 강남구(6 → 8) 하나뿐임

```
# 출처: practice/chapter10/results/10-2-batch-vs-online.log ([2])
[2] 배치 추론 — 밤에 자치구 전부를 미리 계산해 표로 저장
    champion    어제 표 {'11440': 6.0, '11620': 6.0, '11680': 6.0}
                오늘 표 {'11440': 6.0, '11620': 6.0, '11680': 6.0}
    challenger  어제 표 {'11440': 5.7273, '11620': 5.7273, '11680': 6.1364}
                오늘 표 {'11440': 5.7273, '11620': 5.7273, '11680': 6.9545}
```

□ [2]에서 읽을 것

○ **champion의 표는 어제와 오늘이 똑같음** — 입력을 보지 않으므로 세 자치구 모두 매일 6.0임

○ **challenger의 표는 강남구 한 칸만 바뀜** — 강남구 전일 건수가 6에서 8로 바뀌어 예측이 6.1364(= 135 ÷ 22)에서 6.9545(= 153 ÷ 22)로 바뀜. 마포·관악은 전일 건수가 5로 같아 5.7273(= 126 ÷ 22)으로 그대로임

```
# 출처: practice/chapter10/results/10-2-batch-vs-online.log ([3])
[3] 오늘 밤 배치가 죽었다 — 낮의 조회 3건은 어제 표를 그대로 읽는다
    champion    조회 3건 전부 성공, 오류 0건, 응답 코드 200
                낸 값 {'11440': 6.0, '11620': 6.0, '11680': 6.0}
                오늘 값과 어긋난 자치구 0개 (없음)
    challenger  조회 3건 전부 성공, 오류 0건, 응답 코드 200
                낸 값 {'11440': 5.7273, '11620': 5.7273, '11680': 6.1364}
                오늘 값과 어긋난 자치구 1개 {'11680': 0.8181}
```

□ [3]에서 읽을 것

○ **배치가 멈춰도 조회는 전부 성공으로 끝남** — 두 모델 모두 조회 3건이 응답 코드 200(정상)이고 오류는 0건임. 그런데 돌려준 값은 오늘 값이 아니라 어제 표의 값임

○ **challenger에서는 강남구 값이 0.8181만큼 틀림** — 오늘 맞는 값 6.9545 대신 어제 값 6.1364를 돌려줌(6.9545 − 6.1364 = 0.8181)

○ **champion은 어제 표의 값을 돌려줘도 오늘 값과 같음** — 어제 표와 오늘 표가 원래 둘 다 6.0이므로 어긋난 자치구가 0개임. 그래서 이 모델에서는 값을 비교하는 방법으로는 표가 어제 것인지 알아낼 수 없음

```
# 출처: practice/chapter10/results/10-2-batch-vs-online.log ([4])
[4] 온라인 추론이 같은 이유로 죽으면
    11440 요청 → 즉시 실패: 모델 로드 실패
    11620 요청 → 즉시 실패: 모델 로드 실패
    11680 요청 → 즉시 실패: 모델 로드 실패
    조회 3건 중 실패 3건 — 아무도 모르고 지나갈 수 없다
```

☐ [4]에서 읽을 것

○ **같은 고장인데 온라인에서는 3건이 전부 실패함** — 요청마다 "모델 로드 실패"가 찍힘. [3]의 배치는 같은 고장에서 오류가 0건이었음. 알림 장치가 없는 배치에서는 아무도 모르고, 온라인에서는 3건이 전부 오류로 끝나 바로 알게 됨

```
# 출처: practice/chapter10/results/10-2-batch-vs-online.log ([5])
[5] 배치의 낡음을 조회가 판정하려면 — 표에 기준일을 함께 저장한다
    표의 기준일 2026-07-02 / 조회한 날 2026-07-03 → 낡음 판정 예
    기준일이 없으면 같은 조회 3건이 전부 정상으로 보인다
```

☐ [5]에서 읽을 것

○ **표에 "언제 계산했는가"를 함께 적으면 낡은 표를 알아낼 수 있음** — 표의 기준일 07-02와 조회한 날 07-03이 다르므로 값과 상관없이 "낡음"으로 판정함. [3]에서 champion처럼 값으로는 못 잡던 경우도 이 방법으로는 잡힘

> - **조회 날짜는 구성값이다**
> - 9주차 산출물에는 전일 건수와 당일 건수만 있고 "언제 조회했는가"는 없다. 어제와 오늘을 가르려고 두 날짜를 코드에 고정된 값으로 두었다.
> - 난수를 쓰지 않으므로 몇 번 실행해도 같은 값이 나오지만, 이 두 날짜는 실제로 관측된 조회 시각이 아니다. 예측값 자체는 9주차 훈련 쌍에서 계산한 값이다.

☐ 실무의 배치 시스템은 이 약점을 두 단계에서 막음. 보통 둘 다 둠

○ 계산 단계: 실행 순서를 관리하는 도구(6주차의 Airflow)가 작업이 실패하면 메일이나 메신저로 알림을 보내도록 설정함

○ 조회 단계: 출력 [5]처럼 표에 계산한 날짜를 함께 저장하고, 조회할 때 오늘 날짜와 비교함

○ 둘 다 없으면 출력 [3]처럼 오류 0건인 채로 어제 값이 나감. 어제 값이 오류 없이 나가는 문제는 배치 방식 때문이 아니라, 실패 알림과 날짜 검사를 넣지 않았기 때문에 생김

☐ 사실 일 단위 민원 건수 예측은 배치로 충분함

- ○ 자치구 목록은 정해져 있고, 입력인 전일 건수는 하루에 한 번 확정되므로 1분마다 새로 예측할 필요가 없음
- ○ 그런데도 실습에서 온라인 API를 세우는 이유는, 4절의 입력 규칙 검사와 6절의 컨테이너 배포·배포 전 검수를 실습하려면 요청을 받는 서버가 있어야 하기 때문임

☐ 반대로 배치로 충분한 문제에 24시간 켜 두는 API를 세우면, 서버를 켜 두는 비용이 들고 고장 날 수 있는 프로그램(API 서버)이 하나 더 생김

- ○ 발주 문서에 “실시간 AI”라고 적혀 있으면, 요청이 와야만 알 수 있는 입력이 실제로 있는지부터 물어야 함

4. 서빙 API는 응답에 모델 신원을 싣고 입력 규격을 검사한다

☐ 서빙 API는 모델을 호출할 수 있게 만들어 줄 뿐 아니라, 요청과 응답이 지켜야 할 규칙(계약)을 정해 검사함

- ○ 실습의 서빙 앱은 규칙을 셋으로 나눔

☐ **신원 응답** — 상태 확인 요청(`/health`)에 “살아 있음”만 답하지 않고, 지금 어느 모델로 답하고 있는지도 답함

- ○ 모델 이름, 버전, 그 모델을 어디서 불러왔는지를 함께 돌려줌

☐ **신원이 실린 예측** — 예측 응답에 예측값만 넣지 않고, 그 값을 만든 모델의 이름과 버전을 함께 넣음

☐ **입력 검증** — 자치구 코드는 5자리 숫자, 전일 건수는 0 이상 정수여야 한다는 규칙(스키마)을 앱이 검사함

- ○ 목적은 잘못된 입력(예: 음수 건수 -1)에도 모델이 계산을 해서 6.0 같은 숫자를 돌려주는 일을 막는 것임

☐ 응답에 모델 신원을 넣어야 하는 이유는 감사 상황을 보면 알 수 있음

- ○ 콜센터 상담 지원 시스템이 “이 예측의 근거를 설명하라”는 민원을 받았다고 가정함
- ○ 응답에 모델 이름과 버전이 있으면 그 시각에 답한 모델을 바로 찾고, 9주차 레지스트리를 따라 훈련 기록·데이터 지문·파라미터까지 찾아갈 수 있음
- ○ 응답에 예측값만 있으면 “그때 아마 이 버전이었을 것”이라고 짐작만 할 수 있고, 훈련 기록까지 찾아갈 수 없음

☐ 두 번째 코드를 실행함. 서빙 앱과 같은 규칙을 표준 라이브러리로 다시 만들어 요청 7건을 보냄

```
python3 code/10-3-serving-contract.py
```

```
# 출처: practice/chapter10/results/10-3-serving-contract.log
[1] GET /health — 살아 있는가가 아니라 무엇을 서빙 중인가
    status           ok
    model_name       complaint_daily_forecaster
    model_version    1
    model_source     registry-alias
    shadow_enabled   True
    model_version 1 은 9장이 champion으로 승격한 버전이다
```

☐ [1]에서 읽을 것

- ○ **상태 확인 응답 한 번으로 서빙 중인 모델을 알 수 있음** — 이름 `complaint_daily_forecaster`, 버전 1. 9주차에서 champion으로 정한 그 버전임
- ○ `model_source`가 `registry-alias`이므로, 이 모델은 레지스트리에서 champion 별칭으로 불러온 것임
- ○ `shadow_enabled`가 `True`인 것은 후보 모델에도 요청을 함께 보내는 기능이 켜져 있다는 뜻이며, 5절에서 다룸

```
# 출처: practice/chapter10/results/10-3-serving-contract.log ([2])
[2] POST /predict — 요청 7건을 계약에 통과시킨다
    200  정상 — 강남구, 전일 9건        {'lawd_cd': '11680', 'x_prev_count': 9} →
forecast 6.0
    200  정상 — 마포구, 전일 0건        {'lawd_cd': '11440', 'x_prev_count': 0} →
forecast 6.0
    422  음수 건수                   {'lawd_cd': '11680', 'x_prev_count': -1}
         └ x_prev_count는 0 이상 정수여야 함
    422  코드 자리에 한글              {'lawd_cd': '강남구', 'x_prev_count': 9}
         └ lawd_cd는 5자리 숫자 문자열이어야 함
    422  필드 누락                   {'x_prev_count': 9}
         └ lawd_cd 필드 누락
    422  코드 4자리                  {'lawd_cd': '1168', 'x_prev_count': 9}
         └ lawd_cd는 5자리 숫자 문자열이어야 함
    200  형식은 맞지만 없는 자치구         {'lawd_cd': '99999', 'x_prev_count': 9} →
forecast 6.0
    통과 3건 / 거절 4건
```

☐ [2]에서 읽을 것

- ○ 맨 앞 숫자는 응답 코드임. 200은 정상 처리, 422는 “입력 형식이 규칙에 맞지 않아 처리하지 않음”임
- ○ **잘못된 입력 4건은 모델을 실행하기 전에 거절됨** — 음수 건수(-1), 자치구 코드 자리에 한글, 코드 필드 없음, 4자리 코드가 각각 422를 받았고, 아래 줄(└)에 어느 규칙을 어겼는지 적혀 있음
- ○ **전일 9건과 전일 0건이 똑같이 6.0을 받음** — 오류가 아님. champion v1은 입력과 상관없이 평균 6.0을 내는 모델이기 때문임

- **형식만 맞으면 없는 자치구도 통과함** — `99999`는 서울에 없는 코드인데 5자리 숫자라는 형식을 지켰으므로 200과 6.0을 받음

```
# 출처: practice/chapter10/results/10-3-serving-contract.log ([3])
[3] 스키마 계약이 보는 것과 보지 않는 것
    형식을 어겨 거절된 요청 4건
    형식은 맞지만 사전에 없는 자치구 코드가 통과한 요청 1건 — ['99999']
    스키마는 값의 모양만 본다. 그 코드가 실제로 있는지는 표준 코드 사전(6주차 실습 입력)이 판정한다
```

☐ [3]에서 읽을 것

- **스키마 검사는 "모양"만 확인함** — 5자리 숫자인지는 검사하지만, 그 코드가 실제 자치구인지는 검사하지 않음
- 실제로 있는 코드인지는 표준 코드 목록(`practice/chapter6/data/input/lawd_cd_seoul.csv`)과 대조해야 알 수 있음. 스키마 검사를 통과했다고 입력이 맞는 것은 아님

```
# 출처: practice/chapter10/results/10-3-serving-contract.log ([4])
[4] 응답에 신원을 실을 때와 싣지 않을 때
    신원 있음 4개 필드 — forecast 6.0, complaint_daily_forecaster v1, 출처 registry-
alias
    신원 없음 1개 필드 — forecast 6.0
    '이 예측을 만든 모델이 무엇인가'에 답할 수 있는 쪽은 앞의 응답뿐이다
```

☐ [4]에서 읽을 것

- **두 응답의 예측값은 같고 칸 수만 다름** — 둘 다 6.0인데, 신원을 넣은 응답은 4칸(예측값·모델 이름·버전·출처), 넣지 않은 응답은 1칸(예측값)임
- 감사에서 "이 값을 어느 모델이 만들었는가"라고 물으면 4칸짜리 응답만 답할 수 있음. 두 응답의 계산 결과는 같고, 다른 점은 모델 이름·버전·출처 세 칸을 넣었는지뿐임

☐ 서빙 앱은 켤 때 모델을 한 번 메모리에 올리고, 앱이 꺼질 때까지 그 모델로 계산함(`10-1-model-api/app.py`의 `lifespan` 함수)

- 요청마다 레지스트리에서 다시 불러오면 응답이 그만큼 늦어지고, 레지스트리가 멈출 때 예측 요청도 함께 실패하기 때문임

☐ 다만 모델을 켤 때 한 번만 불러오기 때문에 다음 문제가 생김

- 불러오는 코드가 버전 번호가 아니라 `models:/complaint_daily_forecaster@champion`처럼 별칭을 적어 두므로, 승격할 때 코드를 고칠 필요는 없음

- ○ 그러나 이미 켜져 있는 앱은 별칭이 다른 버전으로 옮겨졌는지 모름. 앱을 다시 켜기 전까지는 예전 모델로 계속 답함
- ○ 새 모델로 바꿀 때 앱을 다시 켜야 하는 이유는 5절 끝에서 다시 다룸

5. shadow는 이용자에게 영향 없이 후보를 시험한다

□ 배포는 지금 서비스 중인 모델(champion)을 새 버전으로 바꾸는 일임

- ○ 배포 전 시험은 과거 데이터로만 하므로, 새 버전이 실제 요청에서 틀린 답을 내는지는 배포한 뒤에야 알 수 있음
- ○ 그래서 새 버전을 내보낼 때는 먼저 이렇게 따짐 — **새 버전이 틀린 답을 낸다면, 그 답을 받는 이용자가 전체의 몇 %인가.** 이 비율을 실패 반경(blast radius)이라 함

□ 이용자 요청이 6건 들어온다고 가정하고(아래 실습의 요청 수), 새 버전을 내보내는 방법 세 가지를 비교함

- ○ **한 번에 전부 교체**: 6건 모두 새 버전이 답함
  - – 새 버전이 틀렸다면 6명 모두 틀린 답을 받음. 실패 반경 = 6 ÷ 6 = 100%
- ○ **카나리(canary)**: 6건 중 1건만 새 버전이 답하고, 나머지 5건은 기존 champion이 답함
  - – 새 버전이 틀렸어도 틀린 답을 받는 사람은 1명임. 실패 반경 = 1 ÷ 6 ≈ 17%
  - – 1건에서 문제가 없으면 새 버전이 답하는 건수를 2건, 3건으로 늘려 가다가 6건 전부로 바꿈
- ○ **shadow**: 6건 모두 새 버전에도 똑같이 보내 계산하게 하지만, 이용자에게는 champion의 답만 돌려주고 새 버전의 답은 로그에만 적어 둠
  - – 새 버전이 틀렸어도 틀린 답을 받는 사람은 0명임. 실패 반경 = 0 ÷ 6 = 0%

□ 이 장의 실습은 shadow를 씀. 대신 치르는 비용이 둘 있음

- ○ 같은 요청을 두 모델이 각각 계산하므로 계산 비용이 두 배임
- ○ 이용자가 새 버전의 답을 실제로 받지 않으므로, 그 답을 받은 이용자가 어떻게 반응하는지는 알 수 없음

□ 공공 서비스에서 shadow가 특히 맞는 이유가 하나 더 있음

- ○ 카나리 방식으로 요청을 나눠 보내면, 같은 시각에 어떤 시민은 champion의 답을, 어떤 시민은 새 버전의 답을 받음
- ○ 민원 배정이나 복지 판정처럼 권리에 영향을 주는 결정에서는 시민마다 다른 기준이 적용되는 것 자체가 형평성 문제가 됨

□ 세 번째 코드를 실행함. 같은 훈련 쌍으로 두 모델을 만들고, 같은 요청을 두 모델에 함께 보냄

```
python3 code/10-4-shadow-compare.py
```

```
# 출처: practice/chapter10/results/10-4-shadow-compare.log
[1] 두 모델을 같은 훈련 쌍 6개로 적합
    champion   v1 평균 예측기      상수 6.0
    challenger v2 선형회귀        절편 3.6818  기울기 0.4091
    9장이 기록한 계수 {'intercept': 3.6818, 'slope': 0.4091} 와 일치: 예
```

□ [1]에서 읽을 것

- ○ **9주차와 같은 두 모델임** — champion은 항상 6.0을 내고, challenger의 절편 3.6818·기울기 0.4091이 9주차 기록과 일치함
- ○ challenger는 9주차 승격 게이트에서 반려된 v2임. 이 절에서는 반려된 후보를 실제 요청으로 다시 시험함

```
# 출처: practice/chapter10/results/10-4-shadow-compare.log ([2])
[2] shadow 호출 — 훈련 쌍의 전일 건수를 그대로 요청 6건으로 보낸다
    자치구         전일      이용자가 받는 값        로그에만 남는 값        차이
    11440       5            6.0          5.7273  -0.2727
    11440       5            6.0          5.7273  -0.2727
    11620       5            6.0          5.7273  -0.2727
    11620       5            6.0          5.7273  -0.2727
    11680       6            6.0          6.1364   0.1364
    11680       8            6.0          6.9545   0.9545
    이용자에게 나간 응답 6건 전부 champion 값 — challenger는 한 건도 닿지 않았다
```

□ [2]에서 읽을 것

- ○ **이용자가 받은 값은 6건 모두 6.0임** — `이용자가 받는 값` 열이 전부 champion의 답이고, challenger의 답은 `로그에만 남는 값` 열에만 있음
- ○ **차이의 부호가 자치구마다 다름** — 차이 = 로그 값 − 이용자 값임. 마포(11440)·관악(11620)에서는 후보가 0.2727 낮고, 강남(11680)에서는 0.1364, 0.9545 높음. 그래서 “후보는 항상 더 크게 답한다”처럼 한 방향으로 정리할 수 없음

```
# 출처: practice/chapter10/results/10-4-shadow-compare.log ([3])
[3] 과거 실행이 남긴 shadow 관찰과 대조
    이번 계산  전일 9 → champion 6.0 / challenger 7.3636
    과거 실행  전일 9 → champion 6.0 / challenger 7.3636
    (출처 ch10_deploy_report.json — 일치: 예)
    두 값의 차이 1.3636 가 이 절의 관찰 자료다
```

☐ [3]에서 읽을 것

- ○ **실제 서빙 API를 띄웠던 과거 실행과 값이 같음** — 전일 9건 요청에 champion 6.0, challenger 7.3636(= 162 ÷ 22)이 두 실행에서 똑같이 나옴
- ○ 두 모델의 차이 7.3636 – 6.0 = 1.3636은 이용자에게 나가지 않고 로그에만 남음. shadow 방식에서 담당자가 로그로 모으는 것이 이런 두 모델의 차이 값임

```
# 출처: practice/chapter10/results/10-4-shadow-compare.log ([4])
[4] 로그만으로 후보를 재평가 — 요청 6건의 절대오차 평균
    champion   1.0
    challenger 1.0455
    9장 기록  champion 1.0 / challenger 1.0455
    후보가 더 낫지 않음 — 승격 보류 판정이 실요청 위에서도 유지된다
```

☐ [4]에서 읽을 것

- ○ **로그만 가지고 두 모델의 성적을 다시 계산함** — 요청 6건에서 예측과 실제의 차이(절댓값)를 평균하니 champion 1.0, challenger 1.0455임
- ○ **9주차 판정이 그대로 유지됨** — 9주차 기록과 같은 값이고 challenger의 오차가 더 크므로, 후보를 승격하지 않는다는 결론이 바뀌지 않음. 이용자에게 위험을 주지 않고 이 판정을 다시 확인한 것임

```
# 출처: practice/chapter10/results/10-4-shadow-compare.log ([5])
[5] challenger가 요청 처리 중 죽으면
    shadow 실패 1건 / 이용자에게 나간 응답 6건
    실패 반경 0 — 후보가 무엇을 하든 이용자 응답은 champion 경로로만 만들어진다
```

☐ [5]에서 읽을 것

- ○ **후보가 고장 나도 이용자 응답은 6건 모두 나감** — challenger 쪽에서 실패가 1건 났지만 이용자가 받은 응답 수는 6건 그대로임. 실패 반경 0%를 숫자로 확인한 것임

☐ 실제로 모델을 바꾸려면 두 가지를 모두 해야 함

- ○ **모델 교체**: 레지스트리에서 champion 별칭을 v1에서 v2로 옮김
- ○ **서비스 교체**: 서빙 앱을 다시 켜서 새 모델을 불러오게 함
- ○ 4절에서 본 것처럼 앱은 켤 때 한 번만 모델을 불러오므로, 별칭만 옮기면 앱은 계속 v1으로 답함
- ○ 되돌릴 때(롤백, rollback)도 마찬가지로 별칭을 되돌리고 이전 앱을 다시 켜는 두 동작이 필요함

☐ 되돌리는 **방법**을 아는 것과 **언제** 되돌릴지 정해 두는 것은 다른 일임

- ○ 기준이 없으면 지표가 나빠지는 동안 “조금 더 지켜보자”를 반복하고, 그사이 잘못된 답을 받는 이용자가 계속 늘어남

☐ 그래서 롤백 기준은 세 가지를 함께 적어야 함 — **어떤 지표를, 얼마를 넘으면, 몇 분(몇 건) 동안 보고** 판정하는가

- ○ 셋 중 하나라도 비어 있으면 되돌릴 시점이 정해지지 않음
- ○ 이 장에서 바로 쓸 수 있는 기준은 배포 직후 확인 요청(스모크 테스트, smoke test)임 — 전일 9건 요청에 6.0이 나오지 않으면 이전 버전으로 되돌림

☐ 몇 분 동안 볼지는 되돌리는 데 드는 비용을 보고 정함

- ○ 이전 이미지를 다시 띄우기만 하면 되는 경우에는 짧게 보고 빨리 되돌림
- ○ 데이터베이스 구조 변경까지 되돌려야 하는 경우에는 오래 보고, 잘못된 경보로 되돌리는 일을 줄임

6. 검증은 여러 단계에서 반복하고, 같은지는 바이트로 확인한다

☐ 이 실습을 만들 때 실제로 난 오류를 보면, 검증을 여러 단계에서 반복해야 하는 이유를 알 수 있음

- ○ 서빙 앱은 설정 파일 위치를 "자기 파일에서 두 단계 위 폴더" 기준으로 계산했음
- ○ 서버 없이 한 테스트도 통과했고 내 컴퓨터에서 띄운 것도 통과했는데, 컨테이너에서는 상태 확인 응답이 끝내 나오지 않았음
- ○ 컨테이너 안에서는 앱이 `/app/app.py`에 있으므로 "두 단계 위 폴더"가 없었고, 경로를 계산하는 순간 오류가 났음

☐ 앞의 두 검증은 이 오류를 잡을 수 없었음

- ○ 둘 다 저장소 폴더 구조 위에서 돌았고, 그 구조에서는 "두 단계 위 폴더"가 항상 있었기 때문임
- ○ 폴더 구조가 다른 컨테이너 안에서만 나는 오류가 있으므로, 컨테이너에서 띄워 보는 검증은 앞의 두 검증과 별도로 해야 함

☐ 네 번째 코드를 실행함. 두 폴더 구조에서 같은 경로 계산을 해 보고, 배포 검수표를 과거 실행 기록에서 다시 계산함

```
python3 code/10-5-release-gate.py
```

```
# 출처: practice/chapter10/results/10-5-release-gate.log
[1] 층마다 잡는 결함이 다른 이유 — 같은 식이 배치에 따라 갈린다
    저장소 배치   /repo/practice/chapter10/code/10-1-model-api/app.py 상위 경로 5단계
parents[1] → /repo/practice/chapter10
    이미지 배치   /app/app.py                                    상위 경로 1단계  par-
ents[1] → IndexError: list index out of range
    pytest와 호스트 실행은 둘 다 저장소 배치 위에서 돌아 이 가정이 항상 참이었다
    가정이 깨지는 배치는 이미지 안뿐이므로, 컨테이너 스모크만 이 결함을 만난다
```

☐ [1]에서 읽을 것

○ **같은 코드 `parents[1]`(두 단계 위 폴더)이 위치에 따라 결과가 갈림**

– 저장소 안에서는 `app.py` 위로 폴더가 5단계 있으므로 두 단계 위 `/repo/practice/chapter10`을 찾음

– 컨테이너 안에서는 `/app/app.py` 위로 폴더가 1단계뿐이므로 `IndexError`(목록 범위를 벗어남) 오류로 끝남

○ 테스트(pytest)와 내 컴퓨터 실행은 둘 다 저장소 안에서 돌았으므로 이 오류가 날 수 없었음. 컨테이너에서 띄워 본 확인(스모크)에서만 이 오류가 남

```
# 출처: practice/chapter10/results/10-5-release-gate.log ([2])
[2] 배포 전 검수표를 과거 실행 증거에서 다시 계산한다
    통과  1_자동_테스트_통과
          판정 근거 tests.passed  /  커밋된 검수표 True
    통과  2_서빙_신원_응답(/health가 모델 이름·버전을 답함)
          판정 근거 host.health.model_version  /  커밋된 검수표 True
    통과  3_알려진_입력_알려진_출력_스모크
          판정 근거 host.forecast  /  커밋된 검수표 True
    통과  4_잘못된_입력_거절(422)
          판정 근거 host.invalid_input_status  /  커밋된 검수표 True
    통과  5_컨테이너_호스트_동일_예측(환경_동등성)
          판정 근거 container.forecast == host.forecast  /  커밋된 검수표 True
    미달  6_모델_실물_이미지_고정_및_출처_동봉
          판정 근거 파일 존재 검사  /  커밋된 검수표 True  ← 불일치
    통과  7_레지스트리_버전_보존(롤백_전제)
          판정 근거 bootstrap.challenger_version  /  커밋된 검수표 True
    미달  8_검증_파이프라인_정의(CI_워크플로)
          판정 근거 파일 존재 검사  /  커밋된 검수표 True  ← 불일치
    측정값으로 판정하는 항목 6개 — 전부 재계산되어 같은 값이 나왔다
    파일 존재로 판정하는 항목 2개 — 이 저장소에 그 파일이 없어 불일치 2건
```

☐ [2]에서 읽을 것

○ 검수표는 배포 전에 확인할 8가지 항목의 목록임. 항목마다 `판정 근거`(무엇을 보고 판정했는가)와 `커밋된 검수표`(과거에 저장소에 기록한 판정)를 나란히 보여 줌

○ **측정값으로 판정하는 6개 항목은 다시 계산해도 같은 판정이 나옴** — 1·2·3·4·5·7번은 테스트 통과 수, 모델 버전, 예측값, 응답 코드 422, 두 환경의 예측 일치, 레지스트리 버전을 과거 실행 기록에서 읽어 판정함. 어느 컴퓨터에서 돌려도 같은 기록을 읽으므로 결과가 같음

○ **파일이 있는지로 판정하는 2개 항목은 이 컴퓨터에서 결과가 뒤집힘** — 6번은 이미지에 넣을 모델 파일 폴더를, 8번은 CI 설정 파일을 찾는데, 앞의 폴더는 `.gitignore`가 저장소에서 빼 두었고 뒤의 파일은 이 저장소에 없음. 그래서 과거 기록은 `True`인데 지금 판정은 미달임

○ 정리하면, 판정 근거를 측정값에 두어야 다른 컴퓨터에서도 검수표 결과가 같게 나옴

```
# 출처: practice/chapter10/results/10-5-release-gate.log ([3])
[3] 게이트 하나를 뒤집어 보면 — 컨테이너 예측이 6.1로 나왔다면
    통과 항목 6개 → 5개, 배포 판정 중단
    검수표가 손으로 쓰는 문서였다면 이 한 항목이 바뀌어도 문서는 그대로 남는다
```

□ [3]에서 읽을 것

○ **값 하나가 바뀌면 배포 판정도 바로 바뀜** — 컨테이너 예측이 6.0이 아니라 6.1이었다고 바꿔 넣자 5번 항목(두 환경 예측 일치)이 미달이 되어 통과 항목이 6개에서 5개로 줄고, 판정이 “배포 중단”으로 바뀜

○ 사람이 손으로 쓴 검수 문서였다면 컨테이너 예측이 바뀌어도 문서의 “통과” 표시는 그대로 남아 있음

```
# 출처: practice/chapter10/results/10-5-release-gate.log ([4])
[4] '같은 코드'와 '같은 바이트'
    원본           5708 바이트  줄 120개  sha256 1718607ffbd39aad…
    줄바꿈 변환본   5588 바이트  줄 120개  sha256 ec7ec65397a3194a…
    줄 단위 내용 동일: 예  /  바이트 동일: 아니오
    '같은 코드로 만들었다'는 진술은 이 차이를 걸러 내지 못한다
```

□ [4]에서 읽을 것

○ **줄 내용이 같아도 파일은 다를 수 있음** — 원본과 변환본은 둘 다 120줄이고 줄마다 내용이 같음. 그런데 줄 끝 표시를 Windows 방식(2바이트)에서 macOS·Linux 방식(1바이트)으로 바꾸자 크기가 120바이트 줄었고(5708 → 5588, 줄 120개 × 1바이트), sha256 값도 달라짐

○ “같은 코드로 만들었다”는 말로는 이 차이를 알 수 없음. 배포할 파일이 같은지 확인하려면 바이트나 해시를 비교해야 함

> - **sha256 값 자체는 기계마다 다를 수 있다**
> - 위의 `1718607ffbd39aad…`는 이 저장소를 이 기계에 체크아웃했을 때의 `app.py` 해시다. git이 줄바꿈을 변환하도록 설정된 기계에서는 다른 값이 나온다.
> - 여기서 확인한 것은 특정 해시값이 아니라, 내용이 같아 보여도 바이트 동일성은 따로 판정된다는 사실이다.

□ 검증을 여러 단계에서 반복하는 이유는 단계마다 찾을 수 있는 오류가 다르기 때문임

○ 서버 없이 앱 함수를 직접 부르는 테스트로는 신원 누락·입력 검사 누락 같은 규칙 위반을 몇 초 안에 찾음

○ 내 컴퓨터에서 앱을 실제로 띄워 보면 앱 시작 절차·포트·레지스트리 연결 오류를 찾음

○ 컨테이너에서 띄워 보면 폴더 구조·빠진 패키지·경로 계산 오류를 찾음

☐ 6절의 마지막 확인은 **환경 동등성** 임 — 같은 입력을 보냈을 때 내 컴퓨터에서 띄운 앱과 컨테이너에서 띄운 앱이 같은 답을 내는가

○ 아래는 이 강의 환경에서 Docker를 켤 수 없어 **과거 실행이 남긴 산출물에서 옮긴 값**임. 앞부분부터 끊어서 읽음

```
# 출처: practice/chapter10/data/output/ch10_deploy_report.json
  "consistency": {
    "container_forecast": 6.0,
    "host_equals_container": true,
    "host_forecast": 6.0,
    "matches_ch9_forecast_6_0": true
  },
```

☐ `consistency`에서 읽을 것

○ **두 환경이 같은 답을 냄** — 내 컴퓨터(`host_forecast`) 6.0, 컨테이너(`container_forecast`) 6.0이고, 둘이 같다는 `host_equals_container`가 `true`임

○ 9주차 champion이 내는 6.0과도 같음(`matches_ch9_forecast_6_0`)

```
# 출처: practice/chapter10/data/output/ch10_deploy_report.json
  "container": {
    "forecast": 6.0,
    "health": {
      "model_name": "complaint_daily_forecaster",
      "model_source": "local-dir",
      "model_version": "1",
      "shadow_enabled": false,
      "status": "ok"
    },
    "invalid_input_status": 422,
    "predict_status": 200
  },
  "host": {
    "forecast": 6.0,
    "health": {
      "model_name": "complaint_daily_forecaster",
      "model_source": "registry-alias",
      "model_version": "1",
      "shadow_enabled": true,
      "status": "ok"
    },
    "invalid_input_status": 422,
    "predict_status": 200
  },
```

☐ `container`와 `host`에서 읽을 것

- ○ **잘못된 입력은 양쪽 다 422로 거절함** — `invalid_input_status`가 둘 다 422, 정상 요청은 둘 다 200임
- ○ **모델을 불러온 곳이 다름** — 내 컴퓨터는 `registry-alias`(레지스트리에 champion 별칭으로 물어봄), 컨테이너는 `local-dir`(이미지 안에 함께 넣어 둔 모델 파일을 읽음)임. 그래서 검수표는 "같은 답이 나오는가"와 "어느 모델로 답하는지 말할 수 있는가"를 따로 확인함
- ○ **컨테이너에서는 shadow가 꺼져 있음** — `shadow_enabled`가 내 컴퓨터는 `true`, 컨테이너는 `false`임. 컨테이너는 레지스트리에 연결하지 않으므로 challenger 별칭을 찾을 수 없음. 외부망이 막힌 기관 내부망에서도 돌아가도록 레지스트리 연결을 뺐고, 그 결과 shadow 기능을 쓸 수 없게 됨

```
# 출처: practice/chapter10/data/output/ch10_deploy_report.json
  "bootstrap": {
    "export": {
      "champion_version": 1,
      "export_check_forecast": 6.0,
      "exported_from": "models:/complaint_daily_forecaster@champion",
      ...
    }
  },
  "tests": {
    "passed": 4
  },
```

☐ `bootstrap.export`와 `tests`에서 읽을 것

- ○ **이미지를 만들 때 모델 파일까지 함께 넣음** — 이미지는 코드·패키지 버전·모델 파일을 한 묶음으로 담고, 한 번 만든 이미지는 바뀌지 않음. 그래서 문제가 생기면 이전 이미지를 다시 띄우는 것으로 되돌릴 수 있음
- ○ **넣은 모델이 제대로 동작하는지 바로 확인함** — `exported_from`에 champion 별칭에서 꺼냈다고 적혀 있고, 꺼낸 모델로 예측을 한 번 시켜 6.0(`export_check_forecast`)이 나오는 것까지 확인함. 파일을 저장한 뒤 다시 불러와 예측값까지 확인하는 방식은, 9주차에서 지문을 원천 자료로 다시 계산해 기록과 맞춰 본 방식과 같음
- ○ 서버 없이 한 자동 테스트는 4건 통과함(`tests.passed`). 6절 [2] 검수표 1번 항목이 이 값으로 판정됨

☐ 이 검증들을 사람이 매번 직접 실행하지 않고, 저장소에 코드가 올라올 때마다 자동으로 실행하게 하는 것이 CI(Continuous Integration, 지속적 통합)임

- ○ CI가 새로운 검증을 추가하지는 않음. 검증은 위에서 본 것들이 전부임
- ○ 달라지는 것은 "한 줄만 고쳤으니 검증은 건너뛰자"는 선택을 할 수 없게 된다는 점임

☐ CI가 잡지 못하는 것도 있음

- ○ 시간이 지나 데이터가 달라져 모델 성능이 떨어지는 문제(드리프트)는 코드 검증으로 잡을 수 없으며 11주차에서 다룸
- ○ **CI를 통과해야 배포할 수 있지만, CI를 통과했다고 배포해도 된다는 뜻은 아니다.**

7. 핵심 요약

☐ **1. 계산이 멈추면 온라인은 요청마다 오류를 내지만, 배치는 실패 알림이나 날짜 검사를 따로 두지 않으면 오류 없이 어제 값을 내준다.** (3절)

- ○ 밤 배치가 멈춘 다음 날 조회 3건이 전부 응답 코드 200으로 끝나고 오류가 0건이었으며, 온라인은 같은 원인으로 3건 전부 실패했다.
- ○ champion은 평균 예측기여서 어제 표와 오늘 표가 같아 어긋난 자치구가 0개였고, 입력을 쓰는 challenger로 바꾸자 강남구에서 0.8181이 어긋났다. 값을 비교해서는 낡은 표를 잡지 못하는 모델이 있으므로, 표에 기준일을 함께 저장한다.

☐ **2. 서빙 API의 최소 규칙은 신원·예측·검증 셋이다.** (4절)

- ○ 요청 7건 중 4건이 모델을 실행하기 전에 422로 거절됐고, 통과한 3건은 전일 건수와 상관없이 6.0을 받았다.
- ○ 신원을 넣은 응답은 4칸, 넣지 않은 응답은 1칸이고 예측값은 똑같이 6.0이다. “어느 모델이 만들었는가”에 답할 수 있는 쪽은 앞의 응답뿐이다.
- ○ 스키마는 값의 모양만 보므로 없는 코드 `99999`가 통과했다. 코드가 실제로 있는지는 표준 코드 목록(`practice/chapter6/data/input/lawd_cd_seoul.csv`)과 대조해야 한다.

☐ **3. shadow는 실패 반경을 0으로 두고 후보를 다시 시험한다.** (5절)

- ○ 요청 6건의 응답이 전부 champion의 6.0이었고 challenger 값은 로그에만 남았다. 후보가 처리 중 고장 난 1건에서도 이용자 응답 6건은 그대로 나갔다.
- ○ 로그만으로 절대오차 평균을 다시 계산하니 champion 1.0, challenger 1.0455로 9주차 판정이 그대로 유지됐다.
- ○ 교체는 별칭 이동과 앱 재시작 두 가지를 모두 해야 끝나고, 되돌리는 기준에는 지표·임계값·관찰 기간 세 가지가 필요하다.

☐ **4. 단계마다 찾을 수 있는 오류가 다르므로 검증은 여러 단계에서 반복한다.** (6절)

- ○ 같은 경로 계산이 저장소 안(위로 5단계)에서는 성립하고 컨테이너 안(위로 1단계)에서는 오류로 끝났다. 앞의 두 검증은 저장소 안에서 돌았으므로 이 오류가 날 수 없었다.
- ○ 내 컴퓨터와 컨테이너가 같은 입력에 6.0으로 같은 답을 냈지만, 모델을 불러온 곳은 `registry-alias`와 `local-dir`로 달랐고 컨테이너에서는 shadow가 꺼져 있었다.

☐ **5. 검수표는 계산으로 나와야 하고, 같은 파일인지는 바이트로 확인한다.** (6절)

- ○ 검수표 8개 항목 중 6개 항목이 과거 실행 기록에서 그대로 다시 계산됐고, 컨테이너 예측만 6.1로 바꾸자 통과 항목이 6개에서 5개로 줄어 판정이 중단으로 바뀌었다.
- ○ 나머지 2개 항목은 파일이 있는지로 판정하므로 파일이 없는 컴퓨터에서 결과가 뒤집혔다. 판정 근거를 측정값에 두어야 다른 컴퓨터에서도 결과가 같다.
- ○ 줄 끝 표시만 바꾼 파일은 줄 내용이 같은데도 sha256이 달랐다. “같은 코드”라는 말로는 이 차이를 걸러 내지 못한다.

8. 과제

☐ 실습 넷을 실행해 만든 산출물 네 개를 LMS에 제출한다

1. `practice/chapter10/data/output/ch10_batch_vs_online.json`
2. `practice/chapter10/data/output/ch10_serving_contract.json`
3. `practice/chapter10/data/output/ch10_shadow_compare.json`
4. `practice/chapter10/data/output/ch10_release_gate.json`

☐ 이어서 네 가지를 각각 세 문장 이내로 쓴다

1. 본인 산출물 `ch10_batch_vs_online.json`의 `batch_failure.errors`와 `online_failure.errors`를 그대로 옮겨 적고, 두 값이 다른 것이 왜 배치 쪽이 더 위험하다는 뜻인지 쓴다.
2. `ch10_serving_contract.json`의 `summary`에서 `rejected_422`와 `accepted_but_unknown_district`를 나란히 적고, 스키마 계약이 막아 준 것과 막아 주지 못한 것을 구분해 쓴다.
3. `ch10_shadow_compare.json`의 `reevaluation`과 `blast_radius`를 옮겨 적고, 후보를 승격하지 않기로 한 판단의 근거가 이 두 값에서 어떻게 나오는지 쓴다.
4. 저장소에 포함된 `practice/chapter10/data/output/ch10_deploy_report.json`에서 `consistency.host_forecast`·`consistency.container_forecast`와 두 환경의 `health.model_source`를 옮겨 적고, 같은 답이 나왔는데도 출처를 증명하는 방식이 다른 이유를 쓴다.

☐ 값을 지어내지 않는다. 실행이 안 되면 어디서 막혔는지 그대로 쓴다

☐ 수업일 포함 7일 이내에 제출한다

9. 더 알아보기

☐ 실습을 더 해 보려면 `practice/chapter10/`에서 다음을 시도함

- ○ `10-2-batch-vs-online.py`의 배치 표를 champion 대신 challenger로만 만들어, 낡은 표의 오차가 어느 자치구에서 먼저 눈에 띄는지 확인함

- `10-3-serving-contract.py`의 `CASES`에 요청을 더 넣어, 어떤 입력이 스키마를 통과해 모델까지 가는지 찾음
- `10-4-shadow-compare.py`에서 champion과 challenger를 맞바꿔 보고, 이용자가 받는 값과 재평가 결론이 어떻게 달라지는지 확인함
- `10-5-release-gate.py`의 검수표에서 파일 존재로 판정하는 두 항목을 측정값 판정으로 바꿔 보고, 다른 기계에서도 같은 결과가 나오는지 따져 봄
- 패키지와 Docker를 설치할 수 있으면 `10-1-model-api/`의 서빙 API를 직접 띄워 6절의 컨테이너 값을 본인 기계에서 다시 만듦

☐ 뒤 주차에서 이어지는 내용

- 배포한 모델이 데이터 변화로 낡아 가는 것을 어떻게 잡는지는 11주차에서 실행함
- 피처와 모델의 변경을 누가 승인하고 어디에 남기는지는 12주차, 이 장의 서빙을 다른 구성요소와 묶는 통합은 13주차, 언어 모델 운영은 14주차에서 다룸

☐ 원문을 직접 보고 싶다면 다음 두 편이 출발점임

- Google Cloud, 「MLOps: Continuous delivery and automation pipelines in machine learning」 — 배포 자동화 단계 구분. https://cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning
- Martin Fowler, 「BlueGreenDeployment」 — 서버를 두 벌 두고 새 버전으로 바꾸거나 이전 버전으로 되돌리는 방법. https://martinfowler.com/bliki/BlueGreenDeployment.html