

11주차 배포한 모델은 어떻게 낚고, 언제 다시 배워야 할까

11주차 · 모니터링

- 10장에서 모델은 컨테이너에 실려 검증을 통과하고 배포됐음
 - 그런데 배포는 모델 생애의 끝이 아니라 시작이다
 - 코드가 한 줄도 바뀌지 않아도 세상이 변하면 예측은 조용히 어긋나기 시작함
 - 그 어긋남은 서버 로그에 오류로 남지 않음
- 이 장은 그 어긋남을 무엇으로 감시하고, 신호가 났을 때 무엇을 확인한 뒤 재학습할지 정하는 방법을 다룬다

1. 오늘의 질문

- 서버가 멀쩡한데 모델만 틀리기 시작하면 무엇으로 알아차릴까?
- "입력 분포가 변했다"와 "입력과 정답의 관계가 변했다"는 어떻게 다를까?
- 지표 두 개가 서로 다른 답을 내면 어느 쪽을 믿어야 할까?
- 드리프트(drift) 알림이 났다. 바로 재학습해도 될까?

2. 건강검진으로 보는 이 장

- 배포된 모델을 감시하는 일은 사람의 건강을 검진하는 절차와 단계가 하나씩 대응한다

건강검진	모델 감시
진료실에서 바로 재는 체온·혈압	시스템 지표 — 요청 단위로 즉시 나온다
며칠 뒤 나오는 혈액검사 결과	모델 지표 — 정답이 도착해야 확정된다
검사 두 종이 다른 답을 내면 둘을 함께 읽는다	KS와 PSI가 엇갈리면 조합 규칙으로 판정한다
수치 하나가 기준을 넘어도 바로 수술하지 않는다	알림은 확인 착수 신호이지 재학습 명령이 아니다
검사 기기가 고장 났으면 치료가 아니라 재검사가 먼저다	원인이 데이터 결함이면 재학습이 아니라 수리가 먼저다

□ 특히 마지막 두 줄이 이 장의 결론에 해당함

○ 검사 결과에서 조치까지는 한 걸음이 아니라 두 걸음이며, 그사이에 원인 확인이 들어간다.

□ 비유가 깨지는 지점이 하나 있음

○ 사람은 아프면 스스로 증상을 느끼고 병원에 가지만, 모델은 틀린 답을 내면서도 200 OK로 정상 응답함

○ 모델은 자기가 아프다는 신호를 보내지 않으므로, 감시 장치를 밖에서 따로 세워야 함

3. 감시는 두 층이다 — 살아 있는가와 옳은 답인가

□ 모델 감시를 이야기하기 전에 순서를 지켜야 함

○ 예측이 틀리는 것보다 먼저, 그리고 훨씬 자주, 서비스 자체가 느려지거나 멈춤

○ 응답하지 않는 API 앞에서 예측 품질은 논점이 아님

□ 그래서 감시의 1층은 모델과 무관한 세 질문으로 시작함

○ 요청이 얼마나 걸리는가(지연)

○ 얼마나 많이 오는가(처리량)

○ 얼마나 실패하는가(오류율)

□ 지연은 평균으로 보면 안 됨

○ 4장 Kafka 실측에서 200건 전송의 지연은 평균 3.5ms였지만 최대는 110.7ms였고, 그것도 첫 레코드였음

○ 평균만 보면 "3.5ms짜리 서비스"지만 첫 요청을 보낸 이용자는 30배를 기다린 셈임

– 그러므로 운영 감시는 평균 대신 분위수(p50-p95-p99)를 나란히 봄

□ 처리량은 급증만 신호가 아니라 급락도 신호임

○ 민원 접수가 평소의 10분의 1로 떨어졌다면 민원이 줄어든 것이 아니라 상류의 접수 채널이나 수집 파이프라인이 멈췄을 가능성을 먼저 의심함

□ 오류율은 4xx와 5xx를 나눠 셈

○ 10장에서 잘못된 입력(`x_prev_count=-1`)이 422로 거절된 것은 서비스의 실패가 아니라 계약이 정상 작동한 결과임

– 그러므로 오류율 0이 목표가 아님

○ 다만 422가 갑자기 급증하면 호출자들이 일제히 틀리기 시작했다는 뜻이니 상류의 스키마 변경(2장)을 의심해야 함

2층이 필요한 이유 — 조용한 고장

□ 문제는 이 세 지표가 전부 정상인 채로 모델이 틀리기 시작하는 상황임

○ 서버는 빠르고 오류율은 0이고 `/health` 는 ok인데 예측만 세상과 어긋남

○ 1층 감시로는 이 고장이 잡히지 않으므로, "옳은 답을 내는가"를 묻는 2층을 따로 세움

□ 2층에서 가장 정확한 지표는 성능임

○ 예측과 정답을 대조해 MAE를 계산하면 됨

○ 그런데 정답이 늦게 옴

- 민원 건수 예측의 정답은 다음 날이 되어야 확정되므로 오늘의 성능을 오늘 알 수 없음
- 심사 결과나 재방문 여부처럼 며칠에서 몇 주가 걸리는 과제도 흔함
- 이 **레이블 지연** 때문에 모델 감시는 도착 순서대로 층을 이룸
 - 정답 없이 지금 볼 수 있는 것은 입력 분포와 예측 분포임
 - 정답이 도착하면 지연된 성능 평가로 확정 판정을 내림
 - 그래서 감시 설계의 첫 질문은 "어떤 지표를 볼까"가 아니라 ****이 과제의 정답은 언제 도착하는가*****다
 - 금융 사기 탐지처럼 정답 확정에 몇 달이 걸리는 과제에서는 입력 분포가 사실상 유일하게 볼 수 있는 신호가 됨
- 입력 분포와 예측 분포 중 어느 쪽을 볼지도 모델이 정함
 - 9장 champion은 입력이 무엇이든 6.0을 답하는 평균 예측기라서, 입력 분포가 아무리 변해도 예측 분포는 상수로 남음
 - **입력에 둔감한 모델일수록 예측 분포가 아니라 입력 분포를 직접 감시해야 한다.**
 - 이 장의 실습이 하는 일이 바로 그것임

4. 두 가지 방식으로 낚는다

- 모델은 학습 당시의 데이터가 담고 있던 세상을 전제로 동작함
 - 그 전제가 깨지는 방식이 두 가지이고, 둘은 감지 방법부터 다름
- **데이터 드리프트**는 입력의 분포 $P(X)$ 가 변하는 것이다
 - 휴가철이 되어 지역구별 민원 건수 자체가 커지면 모델이 받는 질문의 분포가 변한 것이며, 입력과 정답의 관계는 그대로일 수도 있음
 - 입력 로그만 있으면 감지되므로 정답을 기다릴 필요가 없음
- **컨셉 드리프트**는 입력과 정답의 관계 $P(Y|X)$ 가 변하는 것이다
 - 새 제도가 시행되어 같은 "전일 9건"에서 기대되는 다음 날 건수가 달라지면, 질문은 같은데 정답이 변한 것임
 - 관계의 변화이므로 원칙적으로 정답을 확보해야 확인되고, 3절의 레이블 지연이 그대로 병목이 됨
- 이 비대칭에서 두 가지 함정이 나옴
 - 하나는 입력 분포가 그대로여도 컨셉은 변할 수 있다는 것으로, 입력 감시만으로는 보이지 않는 사각지대임
 - 다른 하나는 반대 방향인데, 입력 분포가 변해도 성능은 멀쩡할 수 있음
 - 앞서 본 champion처럼 모델이 둔감한 방향의 변화라면 그러함
- 두 함정을 합치면 이 장에서 가장 중요한 설계 원칙이 나옴
 - **드리프트 알림은 "성능이 떨어졌다"는 확정이 아니라 "확인에 착수하라"는 신호로 설계한다.**
 - 6절의 판단표가 이 원칙을 절차로 옮긴 것임
- 변화의 시간적 양상 중에서는 계절처럼 주기적으로 돌아오는 **재발형**을 따로 기억해야 함
 - 매년 여름의 같은 변화를 매년 "이상"으로 경보하면 알림 피로만 쌓임
 - 재발형은 경보로 소모할 것이 아니라 계절 피쳐로 모델에 흡수시키거나 임계를 계절에 맞춰 조정하는 편이 좋음
 - 2장에서 말한 "감지했다고 항상 경보하지는 않는다"가 정확히 이 이야기임

5. KS와 PSI는 다른 질문에 답한다

- ☐ 입력 분포가 변했는지 재는 도구는 하나가 아님
 - 이 장은 두 개를 함께 쓰는데, 성격이 달라서 하나를 골라 쓰는 것이 아니라 둘 다 계산한 뒤 조합해 판정함
- ☐ **KS 2표본 검정**은 2장에서 이미 다뤘음
 - 두 표본의 누적분포 최대 간격(통계량 D)을 재고, "같은 분포에서 나왔다"는 가정 아래 그 간격이 우연히 나올 확률(p-value)을 돌려줌
 - 2장의 결론을 그대로 가져옴
 - p-value가 크다고 "분포가 같다"가 아니라 "다르다고 볼 증거가 부족하다"는 뜻이라는 것
 - 그리고 결과가 표본 크기에 좌우된다는 것
- ☐ ****PSI(Population Stability Index, 모집단 안정성 지수)****는 이 장에서 새로 배우는 지표임
 - 기준 분포를 분위수로 잘라 구간을 만들고, 구간마다 비율이 얼마나 이동했는지를 더함

$$PSI = \sum (\text{현재비율} - \text{기준비율}) \times \ln(\text{현재비율} / \text{기준비율})$$

- ☐ 두 항의 부호가 곱해져 언제나 양수가 되므로, 비율이 늘어난 구간과 줄어든 구간이 모두 값을 키움
- ☐ 신용평가 업계에서 모집단이 흔들렸는지 점검하려고 쓰던 지표임
 - 관행 임계는 0.1을 주의, 0.25를 경보로 봄
 - 다만 이 임계에 통계적 근거가 약하다는 지적이 있음(Yurdakul, 2018)
 - 관행 임계는 출발점이지 법칙이 아니다.

두 지표는 다른 질문에 답한다

- ☐ KS는 "이 차이를 우연으로 보기 어려운가"에 답하고, PSI는 "이동의 크기가 얼마인가"에 답함
 - 질문이 다르므로 답이 엇갈릴 수 있고, 실제로 실습에서 엇갈림
- ☐ 표본이 크면 사소한 차이도 KS에서 전부 "유의"로 나오기 때문에 실질 판단은 거리 지표인 PSI가 맞음
- ☐ 반대로 표본이 작으면 PSI가 몇 건의 이동에도 출렁이므로, 이번에는 KS가 제동 장치가 됨
 - **두 지표를 함께 요구하는 알림 규칙은 이 두 방향의 오판을 한 번에 막으려는 설계다.**
- ☐ 이 장의 실습이 쓰는 조합 규칙은 세 줄로 끝남

```
if ks_significant and psi >= PSI_ALERT:      # p<0.05 그리고 PSI>=0.25
    level = "경보"
elif ks_significant or psi >= PSI_WATCH:    # 둘 중 하나만
    level = "주의"
else:
    level = "정상"
```

□ 경보에 KS 유의와 PSI 0.25를 **AND**로 묶은 것이 핵심임

○ OR로 묶었다면 둘 중 하나만 걸려도 경보가 되어 사람을 부르게 되고, 소표본에서 PSI가 흔들릴 때마다 헛경보가 나감

○ 헛경보를 서른 번 겪은 담당자는 서른한 번째를 확인하지 않으므로, 사람 호출은 가장 높은 등급에만 불임

6. 알림은 명령이 아니다 — 재학습 판단

□ 경보가 났다고 재학습 버튼부터 누르면 안 됨

○ 알림과 조치 사이에는 두 개의 확인이 들어감

□ 첫째는 **원인 분류**다

○ 2장에서 드리프트의 원인을 정책 변화·계절성·외부 이벤트·시스템 변경으로 나눴는데, 운영에서는 여기에 하나가 더 붙음

○ 상류 파이프라인이 깨져 단위가 바뀌었거나 결측이 급증한 **데이터 결함**임

– 이 경우 필요한 조치는 재학습이 아니라 수리인데, 손상된 데이터로 다시 배우면 손상된 상태를 학습한 모델이 나오기 때문임

○ 원인이 계절 재발이라면 임계 보정이나 계절 피쳐 추가가 답임

○ 정책 시행 같은 진짜 세상의 변화일 때에만 재학습이 후보가 됨

□ 둘째는 **성능 확인**이다

○ 4절에서 봤듯 입력 분포의 변화가 성능 저하를 보장하지 않음

○ 정답이 도착하는 과제라면 지연된 성능 평가로 저하를 확인한 뒤 움직임

□ 두 확인이 실제로 어떻게 흐르는지 월요일 아침 상황으로 봄

○ 드리프트 대시보드에 강남구 입력 분포가 경보로 표시됐다면, 당직자는 먼저 세 곳을 확인함

– 상류 수집 로그에서 주말 배치가 정상 종료했는지 봄(데이터 결함 여부)

– 달력에서 직전이 연휴였는지 봄(계절 재발 여부)

– 정책 공지에서 새 제도가 그 주에 시행됐는지 봄

○ 다른 축인 성능 확인은 이 아침에 비어 있는데, 어제 실제 건수는 오늘 밤에야 확정되기 때문임

○ 그래서 아침의 조치는 재학습 결재가 아니라 원인 분류 착수와 로그 축적에 머뭇

표 11.5 재학습 트리거 판단표

드리프트 알림	성능 저하(정답 확인)	원인 분류	조치
정상	—	—	기준선 유지, 정기 감시
주의	미확인(정답 대기)	착수	감시 강화, 로그 축적 — 사람 호출 없음
경보	확인됨	데이터 결함	수리(재학습 금지 — 깨진 세상을 학습하게 된다)
경보	확인됨	계절 재발	임계 보정·계절 피쳐 검토
경보	확인됨	실제 변화(정책 등)	재학습 → challenger 등록 → 9장 게이트
경보	저하 없음	실제 변화	감시 지속 — 모델이 둔감한 방향의 변화

□ 재학습을 언제 돌릴지 정하는 방식은 셋임

- 정기 트리거는 주기마다 무조건 재학습하므로 단순하지만 변화가 없어도 비용이 듭
- 이벤트 트리거는 판단표가 경보를 확정할 때만 움직이므로 효율적이지만 감시 인프라가 선행 투자임
- 실무의 기본값은 둘을 섞어 정기 재학습으로 바닥을 깔고 경보 시 조기 실행하는 방식임

□ 어느 경로든 착지점은 같음

- 재학습된 모델은 champion을 곧바로 교체하지 않고 **challenger로 등록되어 9장의 승격 게이트를 다시 통과해야 하며**, 통과하면 10장의 배포 절차를 다시 밟음
- 급하다고 게이트를 건너뛰면 9장에서 세운 감사 가능성이 그 지점에서 끊김
- 데이터(4~8장) → 훈련·등록(9장) → 배포(10장) → 감시(11장) → 재학습 → 다시 9장으로 돌아오는 이 순환이 MLOps를 파이프라인이 아니라 루프라고 부르는 이유다

7. 실습 11.1 기준 데이터와 현재 데이터의 분포 비교 (난이도

★★★★☆)

실습 목표

- 서울 40개 측정소 PM10 실측 스냅샷(snapshot) 세 종류로 KS와 PSI를 계산하고, 두 지표가 엇갈리는 것을 실데이터로 확인한다
- 5절의 조합 규칙이 그 엇갈림을 어떤 등급으로 확정하는지 산출물에서 읽는다

입력 데이터와 비교창 정렬

- 기준은 2026-06-28 22:00 스냅샷임
 - 비교 A는 1시간 뒤인 같은 날 23:00임
 - 비교 B는 9일 뒤인 2026-07-07 22:00임
 - 기준과 비교 A는 2장에서 수집해 커밋한 스냅샷의 복사본임
- 비교 B가 **같은 22:00**인 것은 우연이 아니라 설계다

- PM10은 하루 안에서도 오르내리므로 기준 22:00과 현재 14:00을 비교하면 "9일의 변화"와 "시각의 변화"가 섞여 어느 쪽이 신호인지 알 수 없게 됨
- 기준 창과 비교 창을 같은 조건으로 맞추는 것이 드리프트 감시의 기본기임
- 정렬하지 않은 비교가 만드는 것은 신호가 아니라 교란임

실행 명령

```
cd practice/chapter11
python3 -m venv venv && source venv/bin/activate
pip install -r code/requirements.txt
python run_chapter11.py
```

핵심 코드

- 판정 규칙은 5절에서 본 세 줄이 전부임
 - 이 규칙 문장 자체도 산출물의 `alert_rule` 에 기록됨

```
if ks_significant and psi >= PSI_ALERT:      #  $p < 0.05$  그리고  $PSI > 0.25$ 
    level = "경보"
elif ks_significant or psi >= PSI_WATCH:     # 둘 중 하나만
    level = "주의"
```

전체 코드는 `practice/chapter11/code/11-1-drift-monitoring.py` 참고

실행 결과와 대조

- 마지막 줄이 `CH11_RUN_PASS` 인지 먼저 확인함
- 비교 A에서 2장 실측이 재현되어 `comparison_a_matches_ch2: true` 가 나오는지 먼저 확인함

표 11.6 분포 비교 실측(기준: 2026-06-28 22:00, n=40, 평균 20.025)

항목	비교 A: 1시간 뒤(6/28 23:00)	비교 B: 9일 뒤(7/7 22:00)
현재 평균	20.775	17.75
KS 통계량 / p-value	0.175 / 0.5786	0.225 / 0.2657
PSI(기준 분위수 5구간)	0.1193	0.3324
KL(기준→현재 / 현재→기준)	0.0646 / 0.0548	0.1826 / 0.1497
KS 유의($\alpha=0.05$) / PSI 대역	False / 주의	False / 경보
알림 등급	주의	주의

☐ 여기서 읽어야 할 것이 세 가지다

☐ **1시간 간격에도 PSI는 주의 대역에 들어갔다.**

○ 비교 A는 2장에서 "값은 변해도 구조는 같다"로 판정된 쌍인데, PSI는 0.1193으로 관행 임계 0.1을 넘었음

○ 원인은 소표본임

– 5구간에 40건이면 구간당 기대 8건이므로 측정소 두세 곳이 구간 경계를 넘나들기만 해도 비율이 5%p씩 흔들림

○ 관행 임계를 소표본에 그대로 적용하면 평시에도 매시간 주의가 발생한다는 것을 실데이터가 보여 준 셈임

☐ **9일 뒤에는 두 지표가 다른 답을 냈다.**

○ 평균이 20.025에서 17.75로 내려갔음

○ 구간별 측정소 수를 보면 최하 구간(17 미만)이 7개소에서 13개소로 늘고 최상 구간(22 이상)이 13개소에서 4개소로 줄어 분포 전체가 아래로 이동했음

○ 이 이동을 PSI는 0.3324로 경보 대역이라 답했지만, KS는 $D=0.225$ 에 $p=0.2657$ 로 유의하지 않았음

– $n=40$ 끼리의 비교에서 유의 판정이 나오려면 D 가 대략 0.304를 넘어야 하는데 0.225가 거기에 미치지 못한 것임

○ ***이동의 크기는 경보 수준인데 이 표본 크기에서는 우연을 배제할 수 없다***가 두 지표를 함께 읽은 결론임

○ AND 규칙은 그래서 경보가 아니라 주의로 확정했음

☐ **간격이 늘자 모든 지표가 같은 방향으로 커졌다.**

○ 1시간에서 9일로 가며 KS는 0.175에서 0.225로, PSI는 0.1193에서 0.3324로, KL(기준→현재)은 0.0646에서 0.1826으로 커졌음

○ 그런데 원인이 무엇인지는 지표가 답하지 않음

○ 6월 말에서 7월 초로 넘어가는 계절 요인이 유력한 후보지만, 그 판정에는 기상 기록이나 측정소 공지 같은 분포 밖의 정보가 필요함

○ 알림 다음이 재학습이 아니라 원인 분류인 이유가 여기서도 확인됨

8. 핵심 요약

☐ 1. 감시는 두 층이고, 2층이 없으면 조용한 고장을 놓친다.

○ 지연·처리량·오류율은 "서비스가 살아 있는가"에 답할 뿐이며, 서버가 멀쩡한 채 예측만 틀리는 고장은 여기에 잡히지 않음

○ 지연은 평균 3.5ms와 최대 110.7ms가 함께 나타날 수 있으므로 분위수로 봄

○ 422 거절 급증은 상류 스키마 변경의 조기 신호로 읽음

☐ 2. 정답이 언제 도착하는가가 1차 신호를 정한다.

○ 민원 건수 예측의 정답은 다음 날 확정되므로 오늘의 성능은 오늘 알 수 없고, 그동안 볼 수 있는 것은 입력 분포와 예측 분포임

○ champion처럼 입력에 둔감한 모델은 예측 분포가 상수라 신호를 만들지 않으므로 입력 분포를 직접 감시함

☐ 3. 데이터 드리프트와 컨셉 드리프트는 감지 재료가 다르다.

○ 입력 분포 $P(X)$ 의 변화는 정답 없이 오늘 감지되지만, 관계 $P(Y|X)$ 의 변화는 원칙적으로 정답이 있어야 확인됨

○ 입력이 변해도 성능이 버틸 수 있고 입력이 그대로여도 관계가 변할 수 있으므로, 알림은 확정이 아니라 확인 착수 신호임

☐ 4. KS와 PSI는 다른 질문에 답하므로 함께 요구한다.

○ KS는 "우연인가", PSI는 "얼마나 큰가"에 답함

○ 9일 비교에서 PSI 0.3324는 경보 대역인데 KS는 $p=0.2657$ 로 유의하지 않았고, AND 규칙이 이를 주의로 확정했음

○ OR로 묶었다면 소표본이 흔들릴 때마다 사람이 호출됐을 것임

☐ 5. 경보와 재학습 사이에는 두 개의 확인이 있다.

○ 원인이 데이터 결함이면 재학습이 아니라 수리이고, 계절 재발이면 임계 보정임

○ 정답으로 성능 저하까지 확인된 실제 변화일 때에만 재학습이 후보가 됨

○ 재학습된 모델도 challenger로 9장 게이트를 다시 통과함

9. 과제

☐ 실습을 실행해 생성된 `practice/chapter11/data/output/ch11_drift_report.json` 을 LMS에 업로드한다

☐ 이어서 세 가지를 각각 세 문장 이내로 쓴다

1. 본인 산출물의 두 비교에서 `ks_significant` 와 `psi_band` 가 어떻게 엇갈렸는지 값으로 적는다. ○ 그럼에도 `alert_level` 이 그렇게 정해진 과정을 `alert_rule` 의 `combine` 규칙으로 재현한다

2. `combine` 규칙이 KS와 PSI를 AND로 묶은 이유를 쓴다. ○ OR로 묶었다면 운영에서 무엇이 달라졌을지 쓴다

3. 드리프트 경보와 성능 저하가 함께 확인됐는데 원인이 데이터 결함으로 밝혀졌다면 왜 재학습을 실행하면 안 되는지, 어떤 모델이 나오는지로 설명한다.

□ 수업일 포함 7일 이내에 제출한다

10. 더 알아보기

□ 이 장에서 다루지 않은 내용은 실무교재 `lecture/docs/chapter11.md` 에 있다

○ **골든 시그널과 모니터링 지표 설계표** — 지표마다 수집 지점·기준선·임계·대응을 붙이는 설계:

`lecture/docs/chapter11.md` §11.1~§11.2

○ **KL divergence와 PSI의 항등식** — $PSI = KL(\text{기준} \parallel \text{현재}) + KL(\text{현재} \parallel \text{기준})$ 의 손 계산과 스무딩 (smoothing) 처리: §11.3

○ **재학습의 재료와 알림 수신 구조** — 누적 전체·최근 창·가중 혼합의 트레이드오프, 당직과 결재선의 분리: §11.4

○ **실습 산출물 전체** — 비교별 지표 파일과 수집 로그: `practice/chapter11/data/output/`