

16장 잘 작동하는 시스템은 정당한 시스템인가

12주차 · 피쳐 거버넌스

9장부터 14장까지 모델을 만들고, 배포하고, 감시하고, 하나로 통합했다. 그 장들이 던진 질문은 모두 "잘 작동하는가"였다. 이 장은 다른 것을 묻는다 — **정당한가**. 응답이 빠르고 전체 정확도가 높아도 특정 지역을 체계적으로 불리하게 예측한다면, 그 시스템은 공공에 쓸 수 없다.

이 장에는 새로 만든 수치가 하나도 없다. 9장이 이미 남긴 예측을 지역별로 나눠 본 결과가 전부다.

1. 오늘의 질문

- 전체 오차가 작은 모델이 특정 지역에는 크게 틀릴 수 있을까?
- 오차의 크기와 방향 중 어느 쪽이 정책 결정에 더 중요할까?
- "왜 이렇게 예측했는가"에 답하지 못하는 모델을 공공 서비스에 써도 될까?
- 시민이 자동화된 결정에 이의를 제기하면, 기관은 무엇을 근거로 답하는가?

2. 건강검진 결과지로 보는 이 장

이 장의 네 주제는 건강검진 결과지의 구성에 하나씩 대응한다.

건강검진 결과지	이 장
맨 앞의 종합 소견 한 줄 "정상"	전체 성능 지표 하나(MAE 1.0)
뒤에 붙는 항목별 수치표	그룹으로 나눈 성능(강남·마포·관악)
기준치보다 높은가 낮은가	편향의 부호 — 과대예측인가 과소예측인가
어떤 기기로 언제 했는지 적힌 난	모델 카드(model card)
결과가 이상하면 재검사를 요청하는 절차	자동화된 결정에 대한 이의제기

대응의 핵심은 첫 두 줄이다. 종합 소견이 "정상"이어도 항목별 표에서 한 수치만 기준치를 크게 벗어나 있을 수 있고, 그때 위험한 것은 종합 소견이 아니라 그 한 항목이다. 성능 지표도 마찬가지여서, 전체를 요약한 숫자 하나는 특정 집단에 몰린 오차를 평균 안으로 흡수해 버린다.

비유가 깨지는 지점은 분해의 단위다. 검진 결과지는 **한 사람의 몸을** 항목으로 쪼갠 것이지만, 이 장의 분해는 **여러 사람**을 집단으로 쪼갠 것이다. 한 건의 예측만 아무리 들여다봐도 집단 간 격차는 보이지 않는다. 편향은 개별 예측이 아니라 그룹 전체를 모아야 드러난다.

3. 전체 지표 하나가 그룹 편향을 감춘다

9장에서 승격된 배포 모델 champion은 `baseline_mean`, 즉 **어떤 입력이 들어와도 상수 6.0을 예측하는 모델**이다. 이 모델의 전체 훈련 MAE는 1.0이었다. "평균 1건 오차"는 얼핏 무난해 보인다.

그런데 이 하나의 숫자는 세 지역에 오차가 어떻게 나뉘어 있는지를 말해 주지 않는다. 훈련에 쓴 6쌍(3지역 × 2쌍)을 지역별로 나누어 다시 계산하면 다음과 같다.

표 16.1 champion 그룹별 성능(실측 — `ch16_fairness_report.json`)

지역	실측값	예측	MAE	편향(평균 부호오차)	실측평균 → 예측평균
강남구	9, 6	6.0	1.5	-1.5	7.5 → 6.0
마포구	5, 6	6.0	0.5	+0.5	5.5 → 6.0
관악구	5, 5	6.0	1.0	+1.0	5.0 → 6.0

손으로 계산할 수 있는 크기다. 강남은 실측 9와 6에 예측이 모두 6이므로 오차가 -3과 0이고, 절댓값 평균은 $(3+0)/2 = 1.5$ 다. 여섯 개를 모두 모으면 $(3+0+1+0+1+1)/6 = 1.0$ 이 되어 9장의 전체 MAE와 정확히 일치한다. 같은 예측을 다르게 묶었을 뿐인데, 최악 그룹(강남 1.5)과 최선 그룹(마포 0.5)의 **격차는 1.0, 비율은 3.0**이다. 강남의 오차가 마포의 세 배라는 사실은 전체 MAE 1.0으로는 결코 보이지 않는다.

여기서 무엇으로 나눌지를 정하는 축을 **그룹축**이라고 부른다. 이 장은 지역구를 그룹축으로 썼다. 지역은 **성별·연령·장애 같은 법적 보호속성이 아니라 운영상의 구분**이지만, 지역 형평은 공공에서 실재하는 관심사이고 무엇보다 **분해해서 격차를 보는 방법 자체는 그룹축의 종류와 무관하게 같다**. 지역으로 익히면 성별이나 연령으로 그대로 옮길 수 있다.

동시에 그룹축을 고른다는 것은 무엇을 안 볼지 고르는 일이기도 하다. 지역으로만 쪼갠 평가는 "고령층이 불리하다"를 끝내 발견하지 못한다. 나누지 않은 축의 편향은 평가에 잡히지 않으므로, 어떤 축으로 나눴고 어떤 축을 뺐는지를 함께 기록해야 한다.

한 가지는 정직하게 밝혀 둔다. 이 실측의 표본은 6개뿐이라 강남의 편향이 우연인지 구조인지 단정할 수 없다. 이 절의 목적은 "강남이 차별받는다"는 주장이 아니라, 하나의 지표를 그룹으로 나누는 절차와 그 절차가 드러내는 것을 보이는 데 있다. 표본이 수천 개가 되어도 절차는 똑같고, 그때 비로소 통계적 유의성을 말할 수 있다.

4. 편향은 크기가 아니라 방향에서 정책이 된다

표 16.1에는 MAE 옆에 편향이라는 열이 하나 더 있다. MAE가 오차의 절댓값 평균이라면, 편향은 부호를 그대로 살린 평균이다. 예측에서 실측을 뺀 값이므로 음수면 실제보다 낮게 예측한 것이고 양수면 높게 예측한 것이다.

이 부호가 정책에서는 크기보다 결정적이다. champion으로 지역별 민원 대응 인력을 배정한다고 하자. 강남은 실제로 하루 평균 7.5건이 들어오는데 모델은 6.0으로 예측하므로, **민원이 많은 지역에 인력이 덜 배정된다**. 마포와 관악은 반대로 과대예측되어 상대적으로 여유가 생긴다. MAE만 보면 "강남이 부정확하다"에서 끝나지만, 부호까지 보면 "강남이 체계적으로 과소 배분된다"는 방향 있는 불이익이 드러난다.

그렇다면 상수 모델이라서 생긴 문제일까. 9장에서 승격이 반려된 후보 challenger(선형 모델)에 같은 분해를 적용하면 강남 MAE 1.9091·편향 -0.9545, 마포 0.5+0.2273, 관악 0.7273+0.7273이 나온다. 크기는 달라졌지만 **부호는 그대로다** — 어느 모델을 쓰든 강남은 과소, 마포와 관악은 과대다. 심지어 선형 모델은 강남 MAE가 1.9091로 상수 모델의 1.5보다 크고, 그룹 격차 비율도 3.8182로 더 벌어진다. 더 정교한 모델을 쓰면 편향이 사라진다는 기대는 여기서 성립하지 않는다.

원인은 모델이 아니라 자료에 있다. 이 모델이 쓸 수 있는 피처는 전일 민원 건수 하나뿐이고, 그 하나로는 강남의 실제 수준이 왜 높은지를 설명할 신호가 나오지 않는다. **편향의 뿌리가 데이터와 피처에 있으면 모델을 바꿔도 방향은 유지된다**.

한 가지가 더 따라 나온다. 형평을 무엇으로 잴지 정하는 순간 두 모델의 우열이 뒤집힌다는 사실이다. 그룹 MAE의 비로 채점하면 champion(3.0)이 challenger(3.8182)보다 낫지만, 최악 그룹의 편향 절댓값으로 채점하면 champion 1.5가 challenger 0.9545보다 커서 순서가 반대가 된다. 같은 실측에서 다른 결론이 나오는 것이다. 그러므로 **형평성 지표는 모델의 성질을 재는 도구가 아니라 무엇을 불이익으로 볼지 정하는 규칙**이며, 어느 쪽이 옳은지는 데이터가 아니라 그 예측의 쓰임새가 정한다. 인력 배정처럼 절대 건수가 곧 불이익이면 차를, 승인과 탈락처럼 비율이 곧 불이익이면 비를 쓴다.

5. 설명하지 못하는 모델은 편향의 원인을 짚지 못한다

3절과 4절은 champion이 강남을 과소예측한다는 **현상**을 보였다. 설명 가능한 AI(explainable AI, XAI)는 그 **원인**을 묻는다.

원인을 재는 도구 하나가 permutation importance(순열 중요도)다. 한 피처의 값을 무작위로 뒤섞은 뒤 성능이 얼마나 나빠지는지로 그 피처의 기여를 잰다. 모델이 그 피처에 의존하면 뒤섞을 때 성능이 크게 떨어지고, 의존하지 않으면 아무 변화가 없다.

champion의 permutation importance는 정확히 **0.0**이다. 상수 모델은 입력을 아예 보지 않으니 피처를 어떻게 뒤섞어도 예측이 6.0 그대로다. 이 0.0 하나에 앞 절 편향의 원인이 그대로 들어 있다. 모델이 지역을 구분하는 어떤 신호도 쓰지 않았기 때문에, 실제로는 7.5·5.5·5.0으로 갈리는 세 지역이 하나의 상수 6.0으로 뭉개진 것이다. 설명할 것이 없다는 사실 자체가 편향의 원인이다.

challenger는 조금 다르다. 계수 slope가 0.4091이므로 "전일 민원이 1건 늘면 익일 예측이 0.4091건는다"가 곧 설명이 된다. 그런데 이 모델의 permutation importance는 -0.0455로 음수다. 피처를 뒤섞었더니 오차가 오히려 줄었다는 뜻이고, 이 극소 표본에서 전일 건수가 익일 예측에 도움이 되지 않았다는 말이다. 9장에서 이 모델이 baseline보다 MAE가 높아(1.0455 > 1.0) 승격 반려된 사실과 어긋나지 않는다.

설명 결과는 문서로 남을 때 비로소 쓸모가 생긴다. 그 문서 양식이 모델 카드(model card)다. 모델의 이름과 버전, 의도된 용도, 평가한 그룹측, 지표, 평가·훈련 데이터, 그룹별 정량 분석, 윤리적 고려, 주의와 권고까지 아홉 절로 정리한다. 실습에서 만드는 카드는 이 아홉 절을 사람이 쓰는 것이 아니라 9장 실험 증거와 이 장 실측에서 자동으로 채운다.

아홉 절 중 8절과 9절이 특히 중요하다. 8절에는 "champion이 강남을 과소예측하므로 자원배분에 쓰면 위험하다"가, 9절에는 "표본이 6개라 성능을 주장하지 않으며 지역 특성 피처로 형평을 개선하라"가 들어간다. 이 두 절이 빠지면 모델 카드는 자랑 문서가 되고, 들어가면 검수에 쓸 수 있는 자산이 된다.

여기서 1장의 원칙이 회수된다. **재현할 수 없으면 증거가 아니다**. 사고가 난 뒤 사람이 기억을 더듬어 쓴 해명문은 근거가 되지 못하고, 실행 중에 자동으로 남긴 기록이라야 근거가 된다. 그래서 실습은 훈련 데이터의 지문(fingerprint) 96f6b6b3ce9dcdd1 을 다시 계산해 9장 것과 같은지 대조하고, 증거 파일을 두 번 실행해도 바이트가 같은지 확인한다. 이 두 확인을 통과해야 모델 카드의 숫자가 "그 시점의 그 모델이 실제로 낸 값"이라고 말할 수 있다.

6. 왜 법이 설명과 이의제기를 요구하는가

민간 추천 서비스가 틀리면 매출이 줄어든다. 공공에서 자동화된 결정이 틀리면 시민이 불이익을 받고, 기관에는 그 결정을 설명할 의무가 생긴다. 편향이 있다는 것을 알면서 자동으로 적용하는데 다룰 통로가 없다면, 불이익을 받은 쪽은 이유조차 알 수 없다. 개인정보 보호법 제37조의2(2024년 3월 시행)가 자동화된 결정에 대한 거부권과 설명요구권을 정한 이유가 여기에 있다.

요구는 다섯 가지 통로로 정리된다.

- **고지** — 어떤 기준과 절차로 결정하는지 미리 공개한다.
- **거부권** — 권리·의무에 중대한 영향을 주는 자동 결정을 거부할 수 있게 한다.
- **설명요구권** — 왜 그런 결정이 나왔는지 설명을 요구할 수 있게 한다.
- **인적 개입** — 정당한 사유가 없으면 사람이 다시 처리하거나 설명한다.
- **기록** — 요구와 조치를 로그로 남겨 나중에 감사에 답한다.

강남구 담당자가 "우리 구는 늘 인력이 부족하다"며 이의를 제기하는 상황을 놓고 보면 다섯 단계가 무엇을 요구하는지 분명해진다. 기관은 먼저 "전일 민원 건수만 보고 배정하며 지역 특성은 반영하지 않는다"를 공개해 두었어야 한다. 그래야 담당자가 무엇에 이의를 제기할지 알 수 있다. 그다음 "왜 강남이 6.0으로 배정되었는가"에 답해야 하는데, 이 답이 바로 5절의 permutation importance 0.0이고 3절의 MAE 1.5·편향 -1.5다. 사전에 만들어 둔 편향 실측과 설명 문서가 없으면 기관은 "시스템이 그렇게 판정했다"밖에 말할 수 없다.

마지막 단계인 기록은 13장에서 이미 만들어 두었다. 13장의 접근 정책은 역할과 행위 단위로 권한을 쪼개 목적 밖 조회를 거부했고, 허용된 조회든 거부된 조회든 접근 이력을 로그로 남겼다. 그 구조가 여기서 그대로 쓰인다 — 이의제기를 언제 누가 받았고 무엇을 다시 처리했는지가 같은 방식으로 로그에 남아야, 감사에서 "이 사람의 이의제기에 무엇을 했는가"에 답할 수 있다. **13장이 만든 것은 접근 통제 기능이 아니라 답변 가능성이다.**

세 절이 하나의 흐름이라는 점이 이 장의 결론이다. 사전에 그룹별로 편향을 재고(3·4절), 그 결과와 한계를 문서로 남기고(5절), 사후에 이의제기를 받아 사람이 재처리한다(6절). 앞의 둘이 없으면 마지막이 성립하지 않는다.

7. 실습 16.1 그룹별 성능 분해와 설명 결과 생성

9장 산출물 스냅샷(snapshot)만으로 champion과 challenger를 다시 만들어, 그룹별 MAE·편향을 실측하고 permutation importance로 편향의 원인을 확인한다. 서버도 컨테이너도 필요 없다. 실행하기 전에 세 지역의 MAE와 편향 부호를 각자 예측해 적어 둔다.

실행

```
cd practice/chapter16
python3 -m venv venv
source venv/bin/activate          # macOS/Linux
# Windows: venv\Scripts\activate
pip install -r code/requirements.txt
python run_chapter16.py
```

핵심 코드

그룹 편향의 뼈대는 세 줄이다. 부호를 살린 오차를 모아 크기와 방향을 따로 낸다.

```
err = pred - actual                # 부호오차: 음수 = 과소예측
mae = np.abs(err).mean()           # 크기
bias = err.mean()                  # 방향
```

전체 코드는 `practice/chapter16/code/16-1-fairness-xai.py` 참고

실행 결과와 대조

먼저 표 16.1과 맞춰 본다. 강남 MAE 1.5·편향 -1.5, 마포 0.5·+0.5, 관악 1.0·+1.0이고 그룹 MAE 격차 1.0·비율 3.0이면 맞다. champion의 permutation importance가 0.0인지, 훈련 데이터 지문이 96f6b6b3ce9dcdd1 로 9장과 일치하는지도 확인한다. 마지막에 공공 AI 검토 체크리스트가 12항목 전부 통과하고 CH16_RUN_PASS 가 출력된다.

그다음 두 모델을 형평성 지표별로 다시 채점해 본다.

표 16.2 지표를 바꾸면 결론이 바뀐다(실측)

형평성 지표	champion	challenger
그룹 MAE의 차(최악 - 최선)	1.0	1.4091
그룹 MAE의 비(최악 ÷ 최선)	3.0	3.8182
최악 그룹의 편향 절댓값	1.5(강남)	0.9545(강남)
(참고) 전체 MAE	1.0	1.0455

9장은 전체 MAE만 보고 champion을 승격하고 challenger를 반려했다. 그런데 "강남이 얼마나 덜 배정받는가"를 형평의 정의로 잡으면 반려된 쪽이 낫다. 성능 게이트와 형평 게이트가 다른 답을 낼 수 있으며, 그때 무엇을 우선할지는 코드가 아니라 정책이 정한다.

8. 핵심 요약

1. 전체 성능 지표 하나는 그룹 편향을 감춘다. champion의 전체 MAE는 1.0이지만 지역으로 나누면 강남 1.5, 마포 0.5로 오차가 세 배 벌어진다. 같은 예측을 다르게 묶었을 뿐인데 보이지 않던 격차가 드러나므로, 배포 전 점검은 전체 지표가 아니라 그룹별 분해로 한다.

2. 편향의 방향이 크기만큼 중요하다. 강남의 편향 -1.5는 실제 7.5건인 지역을 6.0으로 낮게 예측한다는 뜻이고, 이 예측으로 인력을 배정하면 민원이 많은 지역에 인력이 덜 간다. MAE만 보면 부정확에서 끝나지만 부호까지 보면 누가 체계적으로 불리한지가 드러난다.

3. 편향의 뿌리가 피처에 있으면 모델을 바꿔도 방향은 유지된다. 상수 모델이든 선형 모델이든 강남은 과소, 마포·관악은 과대로 부호가 같고, 선형 모델은 강남 MAE가 1.9091로 오히려 더 나쁘다. 전일 민원 건수 하나로는 지역 차이를 설명할 신호가 나오지 않기 때문이다.

4. 설명은 편향의 현상을 원인으로 바꾼다. champion의 permutation importance 0.0은 모델이 피처를 전혀 쓰지 않는다는 뜻이고, 그래서 7.5·5.5·5.0으로 갈리는 세 지역이 상수 6.0으로 뭉개졌다. 이 설명 결과와 그룹별 실측을 모델 카드 8·9절에 자동으로 채워 남긴다.

5. 사전 실측과 문서가 없으면 사후 이의제기에 답할 수 없다. 자동화된 결정에는 고지·거부·설명·인적 개입 기록의 통로가 있어야 하고(개인정보 보호법 제37조의2), 그 설명의 재료는 3~5절이 남긴 기록이다. 1장의 "재현할 수 없으면 증거가 아니다"와 13장의 접근 이력이 여기서 함께 회수된다.

9. 과제

실습 16.1을 실행해 만든 `ch16_fairness_report.json` 을 첨부하고, 다음 세 가지를 각각 세 문장 이내로 쓴다.

1. 실행 전에 적어 둔 세 지역의 MAE·편향 부호 예측 중 어긋난 항목 하나와, 왜 그렇게 예측했는지.
2. 표 16.2의 네 지표 중 이 발주 조건(예측 건수에 비례해 인력을 배정한다)에서 무엇을 형평성 지표로 고를지와, 그 근거. "기본값이라서"나 "보통 그렇게 한다"는 근거로 인정하지 않는다.
3. 자기가 고른 지표로 채점하면 champion을 배포해도 되는지, 그리고 그 판정에서 무엇을 양보한 것인지. 값을 지어내지 않는다. 실행이 안 되면 어디서 막혔는지 그대로 쓴다. 수업일 포함 7일 이내에 LMS로 제출한다.

10. 더 알아보기

이 장에서는 실측으로 확인할 수 있는 것만 다뤘다. 아래 내용은 실무교재 `docs/chapter16.md` 에 있으며 관심 있는 학생만 읽으면 된다.

- **공공 AI 다섯 원칙과 대응 장치** — 공정성·투명성·책임성·프라이버시·안전성이 각각 어느 장의 장치에 걸리는지: §16.1
- **집단 공정성의 세 정의와 불가능성** — 인구통계 동등성·균등 오즈·캘리브레이션(calibration)을 동시에 만족할 수 없는 이유: §16.1
- **민간의 알고리즘 공정성 감사** — 신용대출·채용 선별에서 쓰는 감사 기준과 공공으로 옮길 때 달라지는 것: §16.2
- **정책 AI 평가 루브릭(rubric)과 LLM 채점의 한계** — 법적 정합성·중립성·유해성 3기준, 실습 산출물 `ch16_policy_rubric.json`: §16.4
- **개인정보 영향평가와 조문 구분** — 제18·23·33조가 각각 무엇을 규율하는지, 평가 절차 다섯 단계: §16.5
- **국내외 규제 비교** — GDPR 제22조, EU AI Act, AI 기본법의 고영향 분류: §16.6과 보충

원문을 직접 보고 싶다면 다음 두 편이 출발점이다.

- Mitchell 외, 「Model Cards for Model Reporting」 — 5절 모델 카드 아홉 절의 원안. <https://arxiv.org/abs/1810.03993>
- Barocas, Hardt, Narayanan, 『Fairness and Machine Learning』 — 공정성 지표 선택의 트레이드오프를 다룬 무료 공개 교재. <https://fairmlbook.org/>