

chapter11

제11장 모니터링과 드리프트 관리

10장에서 모델은 컨테이너에 실려 검증 파이프라인을 통과해 배포되었다. 그러나 배포는 모델 생애의 시작이지 끝이 아니다 — 서빙되는 모델은 시간이 지나며 조용히 낡는다. CI는 push가 있어야 실행되지만, 드리프트는 push 없이 발생한다: 코드가 한 줄도 바뀌지 않아도 입력 데이터의 분포가 변하고, 세상과 모델의 관계 자체가 변한다. 이 장은 그 감시의 층을 두 겹으로 세운다. 1층은 시스템 모니터링으로 서비스가 살아 있는가를 보며(지연·처리량·오류율), 2층은 모델 모니터링으로 서비스가 옳은 답을 내는가를 본다(예측 분포·성능·신뢰도). 그리고 2층의 핵심 신호인 드리프트를 데이터 드리프트와 컨셉 드리프트로 구분하고, 알림이 떴을 때 “언제 재학습하는가”의 판단 기준을 설계한다. 실습(★★☆☆☆)은 2장에서 개념으로 배운 분포 비교를 운영형으로 확장한다 — 같은 서울 40개 측정소의 PM10을 같은 시각(22:00)·9일 간격의 두 실측 스냅샷으로 비교해, KS(Kolmogorov–Smirnov) 검정·PSI·KL divergence를 계산하고 알림 판정과 권고 조치를 분리해 기록한다.

학습 목표

시스템 지표와 모델 지표를 구분하고, 각각이 잡는 고장의 형태를 설명한다.
데이터 드리프트($P(X)$ 의 변화)와 컨셉 드리프트($P(Y|X)$ 의 변화)의 차이를 설명한다.
드리프트 지표(KS·PSI·KL)의 적용 조건을 알고, 재학습 트리거 조건을 설계한다.

11.1 시스템 모니터링: 지연, 처리량, 오류율

학습 목표

감시의 1층(서비스 생존)을 구성하는 세 지표와 수집 지점을 안다.
평균 지연의 주의점과 분위수(p95)가 필요한 이유를 실측으로 이해한다.

직관: 모델이 틀리기 전에 서비스가 죽는다

모델 감시를 이야기하기 전에 순서를 지켜야 한다 — 예측이 틀리는 것보다 먼저, 그리고 훨씬 자주, 서비스 자체가 느려지거나 중단된다. 응답하지 않는 API 앞에서 예측 품질은 논점이 아니다. 그래서 감시의 1층은 모델과 무관한 세 질문이다: 요청이 얼마나 걸리는가(지연), 얼마나 많이 오는가(처리량), 얼마나 실패하는가(오류율). 이 셋은 Google SRE의 “골든 시그널” 네 가지(지연·트래픽·오류·포화) 중 앞의 셋과 같다 — 넷째인 포화(자원이 얼마나 차 있는가)는 부하의 문제이므로 12장에서 다룬다.

골든 시그널은 관측 대상을 고르는 체계다. Google SRE 팀은 분산 시스템에서 무한히 많은 지표 중 무엇을 먼저 볼지의 문제를 네 가지로 압축했다 — 지연, 트래픽, 오류, 포화(Beyer et al., 2016, Ch. 6). 이 네 가지의 장점은 “증상 우선”이다: CPU 사용률 같은 원인 지표를 백 개 늘어놓는 대신, 이용자가 실제로 겪는 증상(느린가·많은가·실패하는가·한계에 가까운가)을 먼저 잡고 원인은 그 다음에 파고든다. 이 장의 1층은 그중 앞의 셋을 이 교재의 실측 위에 얹은 것이고, 넷째 포화는 부하의 문제라 12장에서 실측으로 다룬다.

평균 지연만 사용하면 일부 요청의 긴 지연을 확인하기 어렵다. 4장 Kafka 실측을 기준으로 보면 — 200건 전송의 지연은 평균 3.5ms였지만 최대는 110.7ms, 그것도 첫 레코드였다(연결 초기화 비용, 콜드스타트(cold start)). 평균만 보면 “3.5ms짜리 서비스”지만, 첫 요청을 보낸 이용자는 30배를 기다렸다. 그래서 운영 감시는 평균이 아니라 분위수를 본다 — p50(중앙값)과 p95-p99(꼬리)를 나란히 두면 “대부분은 빠르는데 일부가 느리다”가 보인다. SRE의 조언 하나를 덧붙이면, 오류의 지연은 따로 추적해야 한다 — 즉시 실패하는 요청은 빠르므로, 오류를 섞어 평균을 내면 지연이 실제보다 낮게 보이는 왜곡이 발생한다.

처리량(throughput)은 수요의 지표다(초당 요청 수·분당 건수). 급증만 신호가 아니다 — 급락도 신호다. 민원 접수가 평소의 10분의 1로 감소했다면 민원이 줄어든 것이 아니라 상류(접수 채널·수집 파이프라인)가 중단되었을 가능성이 먼저다. 7장에서 입력 파일이 없던 날 배치가 실패로 전파되던 것과 같은 구조다 — 데이터가 유입되지 않는 것은 조용한 장애이며, 처리량 감시가 그것을 가시화한다.

오류율(error rate)은 반드시 두 갈래로 나눠 계수한다. 4xx(호출자 쪽 문제)와 5xx(서비스 쪽 문제)는 다른 고장이다. 10장 실측에서 잘못된 입력(x_prev_count=-1)은 422로 거절되었다 — 이것은 서비스의 실패가 아니라 계약의 정상 작동이다. 오류율 0이 목표가 아닌 이유가 여기 있다: 잘못된 입력은 거절되어야 정상이고, 목표는 “거절이 정확히 일어나는 것”이다. 다만 422가 갑자기 급증하면 이야기가 다르다 — 호출자들이 일제히 틀리기 시작했다는 뜻이므로, 상류의 스키마 변경(2장에서 본 위험)을 의심해야 한다. 오류율은 시스템 지표이면서 동시에 데이터 품질의 조기 신호다.

이미 세워 둔 감시 장치의 회수

이 교재는 사실 시스템 모니터링을 이미 여러 번 만들었다. 7장의 `_SUCCESS` 마커는 배치 세계의 감시다 — “산출물이 확정되었는가”를 마커 존재로 답한다. 10장의 `/health`는 온라인 세계의 감시다 — “살아 있는가”에 더해 “무엇을 서빙 중인가”(모델 이름·버전·출처)까지 답한다. 3장 로컬 스택에 포함했던 Grafana가 바로 이 지표들이 모이는 자리였다(모니터링 계층). 이 장이 새로 추가하는 것은 장치가 아니라 **관점**이다: 그 장치들이 답하는 질문(살아 있는가)과 아직 답하지 못하는 질문(옳은 답인가)의 경계를 긋는 것.

표 11.1 시스템 지표와 모델 지표의 구분

비교 축	시스템 지표(1층)	모델 지표(2층)
답하는 질문	서비스가 살아 있는가	서비스가 옳은 답을 내는가
대표 지표	지연 p95, 처리량, 오류율 (4xx/5xx)	입력 분포, 예측 분포, (지연된) 성능
고장의 형태	응답 불가·느림·5xx — 즉시 드러난다	200 OK인데 틀린 답 — 조용하다
신호의 속도	즉시(요청 단위)	느림(분포는 누적, 성능은 레이블 대기)
이 교재의 장치	7장 _SUCCESS, 10장 /health	10장 shadow 로그, 이 장 실습
주 대응	인프라 점검·롤백(10장)·부하 (12장)	원인 분류·재학습 판단(11.4)

민간의 실시간 감시를 공공으로 옮기면

시스템 모니터링은 민간이 훨씬 먼저, 훨씬 촘촘하게 발전시킨 영역이다 — 초 단위로 돈이 오가는 서비스에서는 1초의 지연·1%의 오류가 곧 매출이기 때문이다. 그 현장의 실시간 감시는 대략 세 모습이다. 첫째, **실시간 사업 지표 대시보드** — 광고 서버가 초당 노출·클릭·전환을 집계해 대형 화면에 흘리고, 운영자는 곡선의 형태로 서비스 상태를 판단한다. 둘째, **이상 탐지 알림** — 전환율이 평소 밴드(band, 정상 변동 범위)를 벗어나 급락하면 규칙(임계)이나 통계 모델이 자동으로 경보를 발생시킨다. 셋째, **모델 성능 실시간 추적** — 추천 모델의 클릭률(CTR)을 실시간으로 따라가며, 새 모델이 배포된 뒤 지표가 저하되면 즉시 되돌린다.

이 셋을 공공으로 옮기면 대응물이 자연스럽게 잡힌다. 실시간 사업 지표 대시보드는 **민원 현황판**이 된다 — 접수·처리·미결 건수가 부서별·유형별로 실시간으로 흐르고, 미결이 누적되는 곡선은 곧 처리 지연의 전조다. 이상 탐지 알림은 **대기질 등급 감시**로 적용된다 — 측정소별 PM10이 '나쁨' 등급을 넘어서는 순간 담당 부서와 시민에게 경보가 나가는 구조는, 전환율 급락 경보와 계산의 골격이 같다(밴드를 벗어나는 순간을 잡는다). 모델 성능 실시간 추적은 **정책 지표 대시보드**가 된다 — 정책 효과 지표(예: 특정 지원사업의 신청·집행률)를 시계열로 두고 급변을 감시한다. 골든 시그널의 세 질문(느린가·많은가·실패하는가)은 민원 현황판에도 그대로 얹힌다: 처리 지연(latency), 접수량 급증·급락(traffic), 처리 오류·반려율(error).

적용이 그대로 복사가 아닌 지점이 알림의 **수신 구조**다. 민간은 24/7 on-call 로테이션 — 한 엔지니어가 정해진 기간 모든 경보를 받고, 심각도별로 즉시 대응하거나 다음 근무로 넘긴다. PagerDuty·Opsgenie 같은 인시던트(incident) 도구에 순번과 심각도(severity)별 상신 경로를 규칙으로 등록해 두면, 경보가 발생할 때 그 규칙대로 호출이 이루어진다. 공공은 교대 근무와 직제상 책임이 결합한다: 야간·주말 경보는 당직 체계로 가지만, "재학습을 승인할 권한"이나 "시민 공지를 낼 권한"은 당직자가 아니라 직제상의 결재선에 있다. 그래서 공공에서 알림 설계는 두 유형으로 나뉜다 — 즉시 조치(서버 재기동 등)는 당직 교대에, 판단이 필요한 조치(재학습·공지·정책 대응)는 결재선에 연결되어야 한다. 여기에 알림 피로가 겹치면 문제가 공공 특유의 형태를 띤다: 경보가 특정 당직 시간대에 집중되면 그 근무자만 소진되고, 반대로 책임이 여러 부서에 분산되면 "누군가는 봤겠지"라며 아무도 대응하지 않는 책임 공백이 생긴다(보충: 알림 피로). 이 장의 실습이

“주의” 등급에 사람 호출을 붙이지 않고 최상 등급에만 붙이는 규칙(표 11.5)은, 바로 이 소진과 공백을 함께 막으려는 설계의 축소판이다. 이 규칙은 도메인을 가리지 않는다 — 오경보가 누적되면 담당자는 경보 자체를 확인하지 않게 되므로, 경보를 늘리는 쪽보다 줄이는 쪽이 안전할 때가 있다. 임계는 한 번 정하고 끝나는 상수가 아니라, 오경보 이력과 함께 정기적으로 다시 세우는 운영 파라미터다.

공공 사례

공공 민원 시스템의 장애 보고서에는 “몇 시부터 몇 시까지 응답 불가”는 반드시 남지만, “그 기간 예측이 얼마나 틀렸는가”는 남지 않는 경우가 많다 — 1층 감시만 있고 2층이 없는 조직의 전형이다. 검수 관점에서 두 층의 존재는 각각 다른 증거를 요구한다: 1층은 지표 대시보드·알림 이력, 2층은 분포 비교 기록과 재학습 판단 이력(이 장의 산출물이 그 원형이다). - 감시의 1층은 자연·처리량·오류율 — 골든 시그널의 앞 셋이며, 넷째(포화)는 12장의 주제다. - 자연은 평균이 아니라 분위수로 본다: 4장 실측처럼 평균 3.5ms와 최대 110.7ms가 함께 나타날 수 있다. - 오류율은 4xx/5xx를 분리해 센다 — 422 거절은 계약의 정상 작동이고, 그 급증은 상류 스키마 변경의 조기 신호다.

11.2 모델 모니터링: 예측 분포, 성능, 신뢰도

학습 목표

“200 OK인데 틀린 답”이 시스템 지표에 잡히지 않는 이유를 안다.
레이블 자연 아래에서 먼저 볼 수 있는 신호(입력 분포·예측 분포·신뢰도)를 구분한다.

직관: 레이블은 하루 늦게 도착한다

시스템 지표가 전부 정상인 채로 모델이 틀리기 시작하는 것 — 이것이 ML 서비스 고유의 고장이다. 서버는 빠르고, 오류율은 0이고, /health는 ok인데, 예측이 세상과 어긋난다. 코드는 그대로인데 세상이 변했기 때문이다. ML 시스템의 유지 부담이 코드가 아니라 데이터 의존성과 세상의 변화에서 온다는 것은 이 분야의 고전적 관찰이다(Sculley et al., 2015).

그렇다면 “틀리기 시작했다”를 어떻게 아는가? 직접적인 방법은 성능 측정이다 — 예측과 정답을 대조해 MAE를 계산하면 된다. 문제는 정답(레이블)이 늦게 온다는 것이다. 민원 건수 예측의 정답은 다음 날이 되어야 확정된다 — 오늘의 성능을 오늘 알 수 없다. 레이블 지연이 며칠·몇 주인 과제(심사 결과, 재방문 여부)도 흔하다. 그래서 모델 모니터링은 도착 순서대로 층을 이룬다: **지금 볼 수 있는 것**(입력 분포, 예측 분포, 신뢰도)을 먼저 감시하고, **레이블이 도착하면**(지연된 성능 평가) 확정 판정을 내린다.

레이블이 늦는 정도는 과제가 정한다. 민간 추천 서비스에서는 추천을 띄운 직후에 클릭 여부가 확정되므로, CTR(Click-Through Rate, 클릭률)이 사실상 실시간 성능 지표다. 그래서 추천 모델의 감시는 입력 분포가 아니라 CTR 하락을 1차 신호로 삼고, 하락이 확인되면 곧바로 재학습을 시작한다. 반대편 끝에는 금융 사기 탐지가 있다 — 사기 확정까지 수일에서 수개월이 걸리므로,

그동안은 입력 분포가 유일하게 볼 수 있는 신호다. 민원 건수 예측은 그 사이(하루)에 있다. 감시를 설계할 때 먼저 답해야 할 질문이 여기서 나온다: 어떤 지표를 볼 것인가가 아니라, 이 과제의 레이블이 언제 도착하는가다. 그 답이 1차 신호가 무엇인지를 정한다.

레이블 없이 보는 세 가지

입력 분포: 모델에 들어오는 값들의 분포가 학습 당시와 같은가. 이것이 데이터 드리프트 감시이며 (11.3), 레이블이 전혀 필요 없어 가장 먼저 가동할 수 있다. 이 장의 실습이 바로 이것이다.

예측 분포: 모델이 내놓는 값들의 분포가 평소와 같은가. 입력을 저장하기 어려운 환경에서도 응답 로그만으로 계산할 수 있다. 단, 한계는 다음과 같다 — 9장의 champion(v1)은 평균 예측기라 입력이 무엇이든 6.0을 답한다. 이 모델의 예측 분포는 상수이므로 입력 분포가 변해도 달라지지 않는다. 예측 분포 감시는 **모델이 입력에 반응할 때만** 신호를 만든다: 입력에 둔감한 모델일수록 입력 분포를 직접 봐야 한다.

신뢰도: 분류 모델이라면 확률 출력의 분포가 신호다 — 확신에 찬 예측(0.9 이상)의 비중이 줄고 경계 사례(0.5 부근)가 늘면, 모델이 학습 분포 밖의 입력을 받고 있다는 뜻이다. 이 교재의 회귀 실습 모델은 예측 구간을 산출하지 않으므로 이 신호가 없다 — 신뢰도 감시를 원한다면 모델이 불확실성을 출력하도록 설계 단계에서 준비해야 한다는 교훈으로 새겨 둔다.

10장 shadow 로그 — 감시 자료의 원형

10장 실습이 남긴 shadow 로그 한 줄을 다시 확인한다: 같은 입력(강남구, 전일 건수 9)에 대해 응답에 쓰인 champion은 **6.0**, 로그에만 남은 challenger는 **7.3636**(표 9.2의 계수로 손 계산: $3.6818 + 0.4091 \times 9 = 81/11$). 이 한 줄이 모델 모니터링의 원형이다. 관측 1건은 아직 분포가 아니다 — 그러나 운영에서 이 로그가 쌓이면 두 모델의 **예측 분포 비교**가 되고, 다음 날 실제 건수(레이블)가 도착하면 **지연된 성능 비교**가 된다. 9장에서 훈련 오차 6쌍으로 반려된 v2가 실제 요청 위에서 재심을 받는 절차(10.2)가, 이 장의 언어로는 “레이블 지연 아래의 모델 모니터링”인 것이다.

현장은 무엇으로 이 감시를 하는가

이 감시를 직접 코드로 짜는 조직도 있지만, 현장에는 이 일을 전담하는 오픈소스·상용 도구가 자리를 잡았다. 두 부류를 파악하면 실습의 통계 계산이 운영에서 어디에 위치하는지가 드러난다. 첫째는 **드리프트 리포트 도구**다 — Evidently(오픈소스)는 기준 데이터와 현재 데이터를 놓으면 컬럼별로 이 장의 실습이 수작업으로 계산한 것과 같은 지표(분포 검정·PSI류 거리)를 자동으로 계산해 표·그래프 리포트를 생성한다. 실습 11.1이 만드는 `ch11_drift_report.json`은 이런 도구가 내는 리포트의 최소 골격이라고 보면 된다. 둘째는 **레이블 없는 성능 추정 도구**다 — NannyML은 정답이 도착하기 전에 모델 자신의 출력 성질로 성능을 근사하는 기법(분류의 CBPE, 회귀의 DLE)을 구현한다. 11.2가 짚은 레이블 지연 문제를 정면으로 겨냥한 것으로, 원리는 공통이다: 모델의 확신도·오차 구조로 성능을 추정하되 레이블이 도착하면 반드시 사후 검증한다(보충 참조). (적용 자격: 두 도구 모두 민간 ML 운영을 겨냥한 도구 문서·구현이며 공공 직접 선례는 아니다 — 방법이 그대로 이식되므로 방법론 차용으로 표기한다.) 도구를 쓰든 직접 짜든 남아야 하는 것은 같다: 어떤 지표를 어떤 임계로 왜 그렇게 판정했는가의 기록.

모니터링 지표 설계표(정보 산출물)

지표는 나열이 아니라 설계다 — 각 지표에 수집 지점·기준선·임계·대응이 붙어야 감시가 된다. 아래 표는 이 교재의 민원 예측 서비스(10장 배포 형태)를 기준으로 한 설계이며, 실습 11.1은 이 중 “입력 분포” 행을 실데이터로 시연한다.

표 11.2 모니터링 지표 설계표(민원 예측 서비스 기준)

지표	층	수집 지점	기준선	임계(예)	경보 시 1차 대응
응답 지연 p95	시스템	API 접근 로그	배포 직후 안정 구간	기준선 대비 배수 지속	인프라·부하 점검(12장)
처리량(분당 요청)	시스템	API 접근 로그	요일·시간대 패턴	패턴 대비 급증·급락	급락이면 상류 생존 확인
오류율(4xx/5xx 분리)	시스템	API 접근 로그	평시 비율	5xx>0 지속, 422 급증	5xx는 서비스, 422 급증은 상류 스키마 의심
서빙 신원	시스템	10장 /health	champion 버전	기대 버전 불일치	배포 사고 — 즉시 롤백 판단(10장)
입력 분포(전일 건수)	모델	요청 로그	학습 데이터 분포	KS $p<0.05$, PSI 0.1/0.25	원인 분류 착수(11.4)
예측 분포(champion·challenger)	모델	shadow 로그(10장)	초기 관찰 창	두 분포의 괴리 확대	challenger 재심 평가(10.2)
지연된 성능(MAE)	모델	레이블 도착 후 배치 대조	승격 당시 지표(9장)	게이트 값(1.05) 지속 초과	재학습 판단표 가동(11.4)

임계 열이 모두 “예”로 표기된 이유는 다음과 같다 — 임계값은 서비스의 트래픽·비용·위험에 따라 조정되는 운영 파라미터이지 상수가 아니다(보충: 알림 피로). 기준선 열이 모두 “과거의 자기 자신”인 것도 확인해야 한다: 감시는 절대 기준이 아니라 기준선 대비 변화를 본다.

민간 현장에서는 이 표에 층이 하나 더 붙는다. 시스템과 모델 위에 매출·전환·이탈 같은 사업 지표 층을 쌓아 3층으로 본다. 층을 나란히 두는 목적은 원인을 구분하는 데 있다 — 매출이 떨어졌을 때 모델이 낡아서인지 시장 자체가 변해서인지는, 모델 지표와 사업 지표를 같은 화면에서 함께 읽어와 구분할 수 있다. 공공에도 셋째 층의 대응물이 있다. 민원 처리 지연, 미결 적체, 지원사업 집행을 같은 업무 지표가 그것이며, 이 층이 답하는 질문은 매출이 아니라 “서비스가 시민에게 실제로 도달했는가”다. 감시의 우선순위도 도메인에 따라 달라진다 — 공공은 입력 데이터의 분포 자체가 1차 감시 대상이지만, 민간은 수익 지표의 변화를 먼저 보고 입력 분포는 그 원인을 분석할 때 확인한다.

공공 사례

AI 기반 민원 자동분류를 도입한 기관이 “정확도 95%”를 검수 시점에 확인했다 해도, 그 수치는 검수 당일의 것이다. 6개월 뒤에도 95%인지는 아무 문서도 보장하지 않는다 — 보장하는 장치는 이 표 같은 감시 설계뿐이다. 발주·검수 문서에 “모델 성능의 사후 감시 지표·주기·임계·대응 절차”를 요구하는 것이, 납품 시점 성능 수치를 요구하는 것보다 더 오래 유효하다. - 모델 고장은 조용하다: 시스템 지표 전부 정상인 채 예측만 어긋난다 — 별도의 2층 감시가 필요한 이유다. - 레이블은 늦게 온다: 입력 분포·예측 분포·신뢰도를 먼저 감시하고, 레이블 도착 후 지연된 성능 평가로 확정한다. - 지표는 설계다: 수집 지점·기준선·임계·대응이 붙어야 감시이며(표 11.2), 임계값은 상수가 아니라 운영 파라미터다.

11.3 데이터 드리프트와 컨셉 드리프트

학습 목표

드리프트를 $P(X)$ 의 변화와 $P(Y|X)$ 의 변화로 구분한다.
드리프트 지표 3종(KS·PSI·KL)의 계산 원리와 적용 조건을 안다.

직관: 두 가지 방식으로 낚는다

모델은 학습 당시의 데이터가 담고 있던 세상을 전제로 동작한다(2장). 그 전제가 깨지는 방식이 두 가지다. 입력과 정답의 결합을 $P(X, Y)$ 라 할 때 —

데이터 드리프트: 입력의 분포 $P(X)$ 가 변한다. 휴가철이 되어 지역구별 민원 건수 자체가 커지는 것 — 모델이 받는 질문의 분포가 변했다. 관계 $P(Y|X)$ 는 그대로일 수도 있다.

컨셉 드리프트: 입력과 정답의 관계 $P(Y|X)$ 가 변한다. 새 제도의 시행으로, 같은 “전일 9건”이라도 다음 날 기대 건수가 달라지는 것 — 질문은 같은데 정답이 변했다. 문헌은 이를 real concept drift라 부르고, $P(X)$ 만의 변화와 구분한다(Gama et al., 2014).

구분이 중요한 이유는 **감지 재료의 비대칭** 때문이다. 데이터 드리프트는 입력만 있으면 감지된다 — 레이블 불필요, 오늘 당장 가능(이 장의 실습). 컨셉 드리프트는 관계의 변화라서 원칙적으로 레이블이 있어야 확인된다 — 즉 11.2의 레이블 지연이 그대로 병목이 된다. 여기서는 두 가지 한계를 구분해야 한다. 첫째, 입력 분포가 그대로여도 컨셉은 변할 수 있다 — 입력 감시만으로는 보이지 않는 사각이다. 둘째, 입력 분포가 변해도 성능은 멀쩡할 수 있다 — 모델이 둔감한 방향의 변화라면 그렇다(9장 champion은 평균 예측기라 어지간한 입력 변화에 성능이 흔들리지 않는다). 그래서 드리프트 알림은 “성능 저하 확정”이 아니라 “확인 착수”의 신호로 설계한다(11.4).

변화의 시간적 양상에 따라 대응 방식도 달라진다. Lu 외(2019)의 드리프트 리뷰는 이를 네 유형으로 구분한다 — 급격(sudden: 정책 시행일에 계단식 변화)·증분(incremental: 여러 중간 상태를 거쳐 새 분포로)·점진(gradual: 옛 분포와 새 분포가 한동안 번갈아 나타나며)·재발(recurring: 계절처럼 주기적으로 돌아옴). 이 중 증분과 점진은 “서서히 변한다”는 운영 대응이 사실상 같아, 이 교재는

둘을 묶어 다룬다(2장도 같은 문헌을 같은 방식으로 소개했다 — 적용 자격: 드리프트 일반 이론의 배경 원칙 차용). 재발형이 특히 중요하다 — 매년 여름의 변화를 매년 “이상”으로 경보하면 알림 피로만 누적된다(2장의 “감지≠항상 경보”가 정확히 이 이야기였다). 재발형은 경보로 소진할 것이 아니라 계절 피쳐로 모델에 흡수시키거나 임계를 계절에 맞춰 조정하는 편이 적절하다(11.4의 재학습 재료 논의로 이어진다).

표 11.3 데이터 드리프트와 컨셉 드리프트

비교 축	데이터 드리프트	컨셉 드리프트
정의	입력 분포 $P(X)$ 의 변화	관계 $P(Y X)$ 의 변화
민원 예측의 예	휴가철 건수 분포 이동	새 제도로 전일→익일 관계 변화
감지 재료	입력 로그만으로 가능	원칙적으로 레이블 필요
감지 시점	즉시(누적되는 대로)	레이블 지연만큼 늦음
성능과의 관계	저하 “가능성”의 신호	저하의 직접 원인
대표 대응	원인 분류 → 필요 시 재학습	재학습(관계 자체를 다시 배움)

두 유형의 구분은 도메인과 관계없이 적용된다. 민간의 이탈 예측이 같은 구조를 보여준다 — 경쟁 서비스가 등장하거나 요금 정책이 바뀌면, 로그인 빈도·사용 시간 같은 행동 피쳐(X)가 그대로여도 이탈 여부(Y)와의 관계가 달라진다. 컨셉 드리프트이고, 예측 정밀도가 조용히 떨어진다. 반면 신규 이용자가 몰려 행동 피쳐의 분포 자체가 이동하는 것은 데이터 드리프트이며, 이쪽은 레이블 없이 곧바로 확인할 수 있다. 필요한 조치도 다르다 — 전자는 관계를 다시 학습해야 하고, 후자는 먼저 원인을 확인해야 한다.

지표 3종: 같은 질문, 다른 성격

“두 분포가 다른가”를 측정하는 도구로 이 교재는 셋을 쓴다. 성격이 다르므로 하나를 선택해 사용하는 것이 아니라 **함께 확인한다**.

KS 2표본 검정(2장 재등장): 두 표본의 누적분포 최대 간격(통계량 D)을 측정하고, “같은 분포에서 나왔다”는 가설 아래 그 간격이 우연히 나올 확률(p -value)을 답한다. 분포 가정이 없고 연속형에 적합하다. 단 p -value는 표본 크기의 함수다 — 표본이 크면 사소한 차이도 유의해지고, 작으면(이 실습의 $n=40$) 진짜 변화도 놓친다(검정력 부족).

D 를 아주 작은 예로 계산한다. 기준 표본이 {1, 2, 3}, 현재 표본이 {2, 3, 4}라고 가정한다. 경험적 누적분포(그 값 이하인 표본의 비율)를 값마다 대조하면 —

- $x=1$ 에서: 기준 1/3, 현재 0 → 간격 1/3
- $x=2$ 에서: 기준 2/3, 현재 1/3 → 간격 1/3
- $x=3$ 에서: 기준 3/3, 현재 2/3 → 간격 1/3
- $x=4$ 에서: 기준 1, 현재 1 → 간격 0

최대 간격이 $D = 1/3 \approx 0.333$ 이다. “분포가 한 칸 오른쪽으로 밀렸다”가 누적분포의 수직 간격으로 계량되는 것 — 이것이 KS의 전부다. 실습의 $D=0.175$ (비교 A)- 0.225 (비교 B)도 같은 계산이며, 40개 값의 누적분포를 겹쳐 그린 간격이다.

PSI(Population Stability Index): 기준 분포를 분위수 구간으로 자르고, 구간별 비율의 이동을 합산한다 — $PSI = \sum (\text{현재}\% - \text{기준}\%) \cdot \ln(\text{현재}\% / \text{기준}\%)$. 신용평가 업계에서 모집단 안정성 점검용으로 정착한 지표로, 관행 임계는 0.1 (주의)- 0.25 (경보)다. 이 관행이 오류율에 대한 통계적 근거 없이 사용되어 왔다는 지적(Yurdakul, 2018)까지 함께 기억해야 한다 — 관행 임계는 출발점이지 법칙이 아니다.

수작업으로 한 번 계산해 보면 지표의 성격을 이해할 수 있다. 구간이 둘뿐이고 기준이 50% - 50% , 현재가 70% - 30% 로 이동했다면 — $PSI = (0.7 - 0.5) \cdot \ln(0.7/0.5) + (0.3 - 0.5) \cdot \ln(0.3/0.5) = 0.2 \times 0.3365 + (-0.2) \times (-0.5108) = 0.0673 + 0.1022 = \mathbf{0.1695}$. 20% p의 이동이 “주의(0.1)와 경보(0.25) 사이”로 계산된다. 두 항이 모두 양수임에 주목한다 — 비율이 증가한 구간도 감소한 구간도 값을 키우는 대칭 구조다.

KL divergence: 같은 구간 확률로 $KL(P||Q) = \sum p \cdot \ln(p/q)$ 를 계산한다. 비대칭이라 방향에 따라 값이 다르고(기준→현재 $\neq$ 현재→기준), 상대가 0인 구간에서 발산하므로 스무딩(smoothing)이 필수다. PSI와의 관계가 깔끔하다 — 같은 구간 확률에서 **$PSI = KL(\text{기준}||\text{현재}) + KL(\text{현재}||\text{기준})$** , 즉 PSI는 KL의 대칭화다(실습이 이 항등식을 수치로 확인한다).

이 항등식을 바로 앞의 PSI 손 계산과 같은 수치로 확인하면 KL의 성격이 분명해진다. 기준 $P=[0.5, 0.5]$, 현재 $Q=[0.7, 0.3]$ 일 때 — $KL(P||Q) = 0.5 \cdot \ln(0.5/0.7) + 0.5 \cdot \ln(0.5/0.3) = -0.1682 + 0.2554 = \mathbf{0.0872}$, 반대 방향 $KL(Q||P) = 0.7 \cdot \ln(0.7/0.5) + 0.3 \cdot \ln(0.3/0.5) = 0.2355 + (-0.1532) = \mathbf{0.0823}$ 이다. 두 값이 다른 것이 비대칭이고, 그 합 $0.0872 + 0.0823 = \mathbf{0.1695}$ 가 바로 앞에서 계산한 PSI와 같다 — PSI가 KL의 대칭화(양방향 합)라는 말의 수치적 실체다. 방향에 따라 값이 달라지므로 “무엇을 기준으로 무엇을 측정하는가”를 고정해 기록해야 하고(기준→현재로 통일하는 식), 어느 구간이든 확률이 0이면 $\ln$ 안이 발산하니 아주 작은 값을 더하는 스무딩이 실무의 기본 처리다.

표 11.4 KS·PSI·KL의 적용 조건(보충 연계)

항목	KS 검정	PSI	KL divergence
답의 형태	p-value(우연인가)	거리(얼마나 큰가)	거리(방향 있음)
구간화	불필요	필요(기준 분위수 권장)	필요(동일 구간)
표본 크기 민감성	크면 과민, 작으면 둔감	구간당 빈도가 작으면 불안정	PSI와 동일 + 0빈도 발산
0빈도 처리	해당 없음	스무딩 필요	스무딩 필수
관행 임계	유의수준(예: 0.05)	$0.1 / 0.25$ (업계 관행)	합의된 관행 없음
이 실습의 역할	2장 재현·통계 신호	운영 임계 판정	PSI의 해부(항등식 확인)

검정과 거리는 다른 질문에 답한다는 것이 표의 요지다 — KS는 “우연으로 보기 어려운가”를, PSI는 “이동의 크기가 얼마인가”를 답한다. 표본이 크면 KS만으로는 전부 “유의”가 되어 거리 지표가 실질 판단을 맡고, 표본이 작으면 반대로 거리 지표가 불안정해져 검정이 제동 장치가 된다. 실습의 알림 규칙이 둘을 함께 요구하는 이유다(11.4).

지표를 **무엇의 분포에 걸 것인가**도 설계 결정이다. 이 장은 입력 변수(PM10)의 분포에 KS·PSI를 걸지만, 같은 계산을 예측 오차의 분포에 걸 수도 있다. 민간의 수요 예측이 그렇게 사용한다 — 예측 오차의 부호와 크기는 재고 과잉과 품질 위험을 판단하는 핵심 입력이므로, 실측이 도착할 때마다 오차 분포를 기준 구간과 대조해 오차가 한쪽으로 밀렸는지 본다. 오차 분포의 이동은 입력 분포가 그대로여도 나타날 수 있어, 레이블이 도착하는 과제에서 컨셉 드리프트의 신호가 된다. 공공에서도 같은 적용이 가능하다 — 민원 건수 예측의 일별 오차를 쌓아 그 분포를 감시하면, 표 11.2의 마지막 행(지연된 성능)이 단일 MAE 값에서 분포로 넓어진다.

공공 사례

법정동 코드 개편(2장의 “코드 체계 변경”)은 하루아침에 특정 코드의 빈도를 0으로 만들고 새 코드를 등장시킨다 — 입력 분포의 급격 드리프트로 즉시 감지된다. 반면 온라인 민원 채널 이용층이 서서히 고령화되어 같은 민원 텍스트라도 긴급도의 의미가 달라지는 변화는 컨셉 드리프트다 — 입력 감시에 잡히지 않고, 레이블(실제 처리 결과)과 대조해야 드러난다. 감사 관점의 질문은 그래서 둘이다: “입력 분포 감시를 하는가”와 “레이블 대조를 언제·어떻게 하는가”. - 데이터 드리프트는 $P(X)$ 의 변화(레이블 없이 감지 가능), 컨셉 드리프트는 $P(Y|X)$ 의 변화(원칙적으로 레이블 필요) — 감지 재료의 비대칭에 따라 감시 설계가 달라진다. - 입력이 변해도 성능이 버틸 수 있고, 입력이 그대로여도 컨셉이 변할 수 있다 — 드리프트 알림은 “확인 착수” 신호로 설계한다. - KS는 “우연인가”, PSI·KL은 “얼마나 큰가”에 답한다 — PSI는 KL의 대칭화(합)이며, 관행 임계 0.1/0.25는 출발점이지 법칙이 아니다.

11.4 재학습 판단 기준

학습 목표

알림에서 재학습까지의 판단 단계(원인 분류·레이블 확인)를 설계한다.
재학습 트리거 방식(정기·이벤트·혼합)을 비교하고, 재학습의 착지점이 9장 게이트임을 안다.

직관: 알림은 질문이지 명령이 아니다

드리프트 알림이 떴다고 곧바로 재학습을 실행해서는 안 된다. 알림과 조치 사이에는 두 개의 확인이 있어야 한다.

첫째, **원인 분류**. 2장에서 드리프트의 원인을 정책·계절·이벤트·시스템 변경으로 나눴다 — 운영에서는 하나가 더 붙는다: 데이터 결함. 상류 파이프라인이 깨져 단위가 바뀌었거나 결측이 급증한 것이라면, 필요한 조치는 재학습이 아니라 **수리**다. 손상된 데이터로 재학습하면 손상된

상태를 학습한 모델이 산출된다 — 드리프트 대응 중 가장 나쁜 대응이다. 계절 재발이라면 재학습 대신 임계 보정이나 계절 피쳐 추가가 답일 수 있다. 진짜 세상의 변화(정책 시행, 구조적 수요 변화) 일 때에만 재학습이 후보가 된다.

둘째, **성능 확인**. 11.3에서 봤듯 입력 분포 변화가 성능 저하를 보장하지 않는다. 레이블이 도착하는 과제라면 지연된 성능 평가(표 11.2 마지막 행)로 저하를 확인한 뒤 움직이는 것이 원칙이다. 레이블이 아주 늦거나 없는 과제라면 — 그때가 드리프트 신호만으로 판단해야 하는 예외 상황이며, 보수적으로 움직인다(보충: 레이블 지연의 성능 추정).

이 두 확인이 실제로 어떻게 흐르는지 구체적인 상황으로 설명한다. 어느 월요일 아침, 민원 예측 서비스의 드리프트 대시보드에 강남구 전일 민원 건수 입력 분포가 **경보**로 표시된다 — KS가 유의하고($p < 0.05$) PSI도 0.25를 넘어, 조합 규칙이 등급을 경보로 확정한 경우다(실습 비교 B는 PSI만 경보 대역이고 KS가 유의하지 못해 등급이 “주의”에 그쳤음을 참고한다 — 대역과 등급은 다르며, 여기서는 요청 로그 표본이 크고 KS까지 유의해 등급 자체가 경보인 상황을 상정한다). 경보가 발생했다고 당직자가 재학습 버튼부터 찾지는 않는다 — 표 11.5가 요구하는 두 확인을 먼저 채운다. 하나는 원인 분류이고, 이를 위해 세 곳을 본다. ① 상류 수집 로그(7장의 `_SUCCESS` 총계 보존): 주말 배치가 정상 종료했는가, 단위나 결측률이 급변하지 않았는가 — 여기서 이상이 확인되면 데이터 결함이고 조치는 재학습이 아니라 수리다(표 11.5 셋째 행). ② 달력: 직전이 연휴였는가 — 연휴 뒤 민원 급증은 매년 오는 재발형이라 재학습 대신 임계 보정·계절 피쳐가 답일 수 있다(넷째 행). ③ 정책 공지: 새 제도·수수료 개편이 그 주에 시행됐는가 — 진짜 세상의 변화 후보다. 다른 한 축인 성능 확인은 이 아침엔 비어 있다 — 레이블(어제 실제 건수)은 오늘 밤에야 확정되기 때문이다. 그래서 경보가 떠도 아침의 조치는 재학습 결재가 아니라 원인 분류 착수와 로그 축적에 머문다. 결재선이 작동하는 것은 밤에 레이블이 도착해 성능 저하가 확인되고, 원인이 데이터 결함도 계절 재발도 아닌 실제 변화로 좁혀진 뒤다 — 그때 비로소 표 11.5의 “경보 · 확인됨 · 실제 변화” 행에 도달해 재학습이 후보가 되고, challenger로 등록되어 9장 게이트를 향한다. 경보 한 건과 재학습 사이에 이만한 거리가 있다.

표 11.5 재학습 트리거 판단표

드리프트 알림	성능 저하(레이블 확인)	원인 분류	조치
정상	—	—	기준선 유지, 정기 감시
주의	미확인(레이블 대기)	착수	감시 강화, 로그 추적 — 사람 호출 없음
경보	확인됨	데이터 결함	수리 (재학습 금지 — 깨진 세상을 학습하게 된다)
경보	확인됨	계절 재발	임계 보정·계절 피쳐 검토(매년 경보 반복 방지)
경보	확인됨	실제 변화(정책 등)	재학습 → challenger 등록 → 9장 게이트
경보	저하 없음	실제 변화	감시 지속 — 모델이 둔감한 방향의 변화, 재학습 보류 가능

트리거 방식: 정기, 이벤트, 혼합

재학습을 “언제” 돌리는가의 방식은 셋이다. **정기 트리거**는 주기(매주·매월)로 무조건 재학습한다 — 단순하고 예측 가능하지만, 변화가 없어도 비용을 소모하고 변화가 주기 사이에 발생하면 대응이 늦는다. **이벤트 트리거**는 표 11.5 같은 판단표가 경보를 확정할 때만 재학습한다 — 필요할 때만 움직이지만, 판단 로직과 감시 인프라가 선행 투자다. **혼합**이 실무의 기본값이다: 정기 재학습으로 기본 주기를 확보하고(계절 등 점진 변화 흡수), 이벤트 경보 시 조기 실행한다. 어느 방식이든 재학습 이력(언제·왜·어떤 데이터로)은 기록되어야 한다 — 9장의 언어로, 재학습도 run이다.

같은 혼합 트리거라도 실행 경로는 도메인에 따라 달라진다. 민간에서는 판단표의 조건이 충족되면 파이프라인이 사람의 개입 없이 재학습·평가·배포까지 수행하는 경우가 많다 — 경보에서 새 모델 서빙까지 몇 시간 안에 끝난다. 공공은 그 사이에 결재가 들어간다. 재학습은 검수 시점의 성능 근거를 무효화하는 변경이라, 승인권자의 판단이 파이프라인의 한 단계로 포함되어야 한다(11.1에서 즉시 조치와 승인 조치를 구분했던 것과 같은 구조다). 자동화 수준은 이렇게 다르지만 한 가지는 같다 — 어느 쪽이든 재학습된 모델은 기존 승격 게이트를 다시 통과한다. 자동화는 게이트를 건너뛰는 것이 아니라, 게이트를 사람의 개입 없이 통과시키는 것이다.

재학습의 재료: 어떤 데이터로 다시 배우는가

재학습을 결정했다면 다음 질문이 바로 따라온다 — 어느 구간의 데이터로 배우는가. 선택지와 트레이드오프는 드리프트의 유형(11.3)에 묶인다.

누적 전체: 지금까지의 모든 데이터. 표본이 가장 많고 안정적이지만, 낡은 관계가 새 관계를 희석한다 — 급격 드리프트 후라면 “변화 전의 데이터”가 다수를 차지해 재학습의 목적이 훼손된다.

최근 창(sliding window): 최근 N일·N주만. 새 관계를 가장 빠르게 반영하지만 표본이 작아지고, 창보다 긴 주기의 계절성은 창 안에 아예 없다.

가중·혼합: 전체를 쓰되 최근에 가중치를 두거나, 재발형(계절) 드리프트라면 “지난해 같은 계절” 구간을 명시적으로 포함한다 — 매년 여름의 재학습이 여름 데이터를 학습하지 못한 모델을 만들지 않도록.

변화 시점 이후만: 원인 분류가 “정책 시행일부터의 급격 변화”로 확정된 경우의 선택 — 시행일 이전 데이터는 다른 조건에서 생성된 기록이다.

어느 선택이든 재학습 데이터의 구성은 8장의 규율을 다시 통과해야 한다: 피쳐는 “그 시점에 알 수 있었던 값”으로 조인되어야 하고(point-in-time), 데이터 지문과 구간이 run에 기록되어야 한다(9장) — 재학습이 감사 가능하려면 “언제 데이터로 언제 배웠는가”가 값으로 남아야 한다.

루프의 완성: 재학습은 처음으로 돌아가는 것

재학습의 착지점을 분명히 한다. 재학습된 모델은 champion을 바로 교체하지 않는다 — **challenger로 등록되어 9장의 승격 게이트(절대 게이트 + champion 대비 개선)를 통과해야 하고**, 통과하면 10장의 배포 절차(테스트 층·카나리 또는 shadow)를 다시 밟는다. 급하다고 게이트를 건너뛰면 9장에서 세운 감사 가능성이 그 지점에서 끊긴다. 이로써 교재의 루프가 닫힌다: 데이터(4~8장) → 훈련·등록(9장) → 배포(10장) → 감시(11장) → 재학습 → 다시 9장. MLOps가 “파이프라인”이 아니라 “루프”인 이유가 이 장에 있다.

역방향: 이 장의 감시 설계를 민간 현장에 옮기면

지금까지는 민간의 감시 관행을 공공 대응물로 옮겼다. 반대 방향도 성립한다 — 이 장에서 세운 2층 감시와 재학습 판단표를 그대로 민간 현장에 적용하면 무엇이 바뀌고 무엇이 유지되는지 세 현장에서 확인한다.

추천 서비스의 실시간 CTR 감시는 10장 shadow 로그와 골격이 같다. 새 모델과 기존 모델의 출력을 같은 요청 위에서 비교하고, 새 모델 쪽 지표가 저하되면 되돌린다. 바뀌는 것은 판단의 속도다. 레이블(클릭)이 즉시 도착하므로 표 11.5의 “성능 저하 확인” 칸을 몇 분 만에 채울 수 있고, 그래서 롤백을 자동으로 걸어도 된다. 민원 예측에서 같은 자동 롤백을 걸 수 없는 이유도 이 대비로 분명해진다 — 레이블이 하루 늦는 과제에서 자동 롤백은 하루 늦은 근거로 실행되는 셈이다.

광고 클릭 예측의 계절 드리프트는 11.3의 재발형(recurring)이 그대로 재현되는 현장이다. 연말·휴가철마다 클릭률 분포가 크게 이동하는데, 매년 경보를 발생시키면 알림 피로만 누적된다. 대응 순서도 이 장 그대로다 — 원인 분류에서 “계절 재발”로 판정하고(표 11.5 넷째 행), 재학습 대신 계절 피쳐를 모델에 넣거나 시기별로 다른 임계를 쓴다. 여름철 대기질이나 연휴 뒤 민원 급증에 같은 판정이 내려지는 것과 계산이 같다.

금융 사기 탐지는 컨셉 드리프트가 주가 되는 현장이다. 사기 수법이 바뀌면 같은 거래 패턴(X)에서 사기 여부(Y)의 관계가 달라진다 — $P(Y|X)$ 의 변화다. 여기서는 레이블 지연이 민원 예측보다 훨씬 길어(사기 확정까지 수일에서 수개월), “레이블 없이 입력 분포를 먼저 감시한다”는 11.2의 전략이

선택이 아니라 유일한 수단이 된다. 거래 패턴 분포를 PSI로 감시하다 급변하면 전문가 검토를 거쳐 재학습하는 흐름은 표 11.5의 “경보 → 원인 분류 → 재학습” 경로와 같다. 재학습 승인이 규제 준수 심사와 묶인다는 점에서는 오히려 공공의 결재선을 닮았다.

세 현장을 관통하는 것은 하나다. 감시를 시스템과 모델 두 층으로 나누는 것, 레이블 도착 시점으로 1차 신호를 정하는 것, 알림을 명령이 아니라 원인 분류의 착수 신호로 두는 것, 재학습 모델을 게이트에 다시 태우는 것 — 이 네 결정은 어느 도메인에서도 똑같이 내려야 하고, **근거만 도메인에 따라 달라진다**. 공공에서 그 근거가 감사·형평성·법적 의무라면, 민간에서는 매출·비용·SLA다. 근거가 다르면 임계의 값과 결재의 유무가 달라질 뿐, 판단의 순서는 달라지지 않는다. 마지막 한 가지도 공통이다 — 층을 나란히 놓고 함께 검토해야 원인을 구분할 수 있다. 매출 대시보드와 드리프트 대시보드를 나란히 두어야 “모델이 낡아서 떨어진 것인지 시장이 변한 것인지”를 구분할 수 있듯, 민원 현황판과 분포 비교 기록을 나란히 두어야 “예측이 틀린 것인지 세상이 변한 것인지”를 구분할 수 있다.

공공 사례

공공 AI 운영 지침에서 재학습은 기술 작업이 아니라 **변경 관리**다 — 재학습으로 모델이 바뀌면 검수 시점의 성능 근거가 무효화되므로, 재학습 조건·승인 절차·재검증 방법이 운영 계획서에 미리 명시되어야 한다. 표 11.5는 그 조항의 초안 어휘다: “드리프트 경보와 성능 저하가 함께 확인되고 원인이 데이터 결함이 아닐 때, 승인권자의 결재를 거쳐 재학습을 실시하며, 결과 모델은 기존 승격 게이트를 재통과해야 한다.” - 알림→재학습 사이에 두 확인이 선다: 원인 분류(결함이면 수리, 계절이면 보정)와 성능 확인(레이블 도착 후). - 트리거는 정기(바닥)+이벤트(조기 실행)의 혼합이 실무 기본값이며, 재학습 이력도 run으로 기록된다. - 재학습 모델은 challenger로 등록되어 9장 게이트와 10장 배포를 재통과한다 — MLOps는 파이프라인이 아니라 루프다.

실습 11.1 기준 데이터와 현재 데이터의 분포 비교(★★☆☆☆)

실습 목표

실측 스냅샷 두 쌍으로 KS·PSI·KL을 계산하고, 알림 판정과 권고 조치를 분리해 기록한다.
2장 실습 2.2의 실측(KS 0.175, p 0.5786)을 이 장의 코드가 재현하는지 교차 검증한다.
드리프트 알림 평가 보고서(정본 산출물)를 생성한다.

입력 데이터

기준과 비교 A는 2장이 수집해 커밋한 실측 스냅샷의 복사본이다(서울 40개 측정소 PM10, dateTime 2026-06-28 22:00과 23:00). 비교 B는 이 장을 위해 실제 수집했다 — 동봉한 수집기(11-0-collect-snapshot.py)가 에어코리아 API를 폴링해, 응답의 dateTime이 **2026-07-07 22:00**이 되는 순간의 원본 응답을 그대로 저장했다(정시 데이터가 정시보다 늦게 게시되므로 로컬 시계가 아니라 응답 내용으로 확인한다 — 2장 수집 때 실측한 게시 지연 대응). 이번 수집에서도 폴링

4회까지는 21:00 데이터만 보였고 5회째에 22:00이 포착되었다

(data/output/ch11_collect_log.txt). n=40의 소표본이고 변수 하나(PM10)라는 축소는 그대로 유지된다 — 관찰 대상은 분포 비교·판정 절차이지 대기질 분석이 아니다.

비교창 정렬 — 이 실습의 설계 결정

비교 B의 두 스냅샷은 **같은 시각(22:00)** 이다. 우연이 아니라 설계다: PM10은 하루 안에서도 오르내리므로, 기준 22:00과 현재 14:00을 비교하면 "9일의 변화"와 "시각의 변화"가 섞여 어느 쪽이 신호인지 알 수 없게 된다. 기준 창과 비교 창을 같은 조건(같은 시각, 같은 요일, 같은 집계 단위)으로 정렬하는 것은 운영 드리프트 감시의 기본기다 — 요일 패턴이 있는 민원 데이터라면 "지난 4주의 월요일 vs 이번 월요일"처럼 정렬한다. 정렬하지 않은 비교가 만드는 것은 드리프트 신호가 아니라 교란이다.

선수 조건과 실행

```
cd practice/chapter11
python3 -m venv venv && source venv/bin/activate # (Windows: venv\Scripts\activate)
pip install -r code/requirements.txt
python run_chapter11.py
```

스냅샷 3종이 동봉되어 있으므로 API 키 없이 완주된다. 새 스냅샷을 직접 수집하려면(선택) `.env` 에 1장의 `DATA_GO_KR_API_KEY` 를 두고 `11-0-collect-snapshot.py` 를 실행한다. 이 장의 실측 환경: Python 3.13 venv, numpy 2.5.1, pandas 3.0.3, scipy 1.18.0 — 서버·컨테이너가 필요 없는, 이 교재 후반부에서 가장 가벼운 실습 환경이다(감시의 계산층은 통계 계산이 전부다).

핵심 코드

알림 규칙 — 검정(우연인가)과 거리(얼마나 큰가)를 함께 요구해 오경보를 억제한다:

```
if ks_significant and psi >= PSI_ALERT:      #  $p < 0.05$  그리고  $PSI \geq 0.25$ 
    level = "경보"
elif ks_significant or psi >= PSI_WATCH:     # 둘 중 하나만
    level = "주의"
else:
    level = "정상"
```

전체 코드는 `practice/chapter11/code/11-1-drift-monitoring.py` 참고

실행 중 확인 체크리스트

- ☐ 스냅샷 3종의 `dataTime`이 기대값(6/28 22:00-23:00, 7/7 22:00)인가 — 파일명이 아니라 내용으로 확인
- ☐ 비교 A에서 2장 실측 재현: `True` 가 출력되는가(불일치면 파싱·결측 규약부터 의심)

- ☐ 두 비교 모두 `psi_equals_kl_sum: true` 인가(PSI=KL 양방향 합의 항등)
- ☐ `ch11_drift_report.json` 이 생성되고, 재실행해도 바이트가 같은가(휘발성 식별자 없음)
- ☐ 마지막 줄이 `CH11_RUN_PASS` 인가

실행 결과(실제)

비교 B의 콘솔 출력 발췌:

```
[기준] 2026-06-28 22:00 n=40 평균 20.025
[현재] 2026-07-07 22:00 n=40 평균 17.75
KS=0.225 p=0.2657 (alpha=0.05) | PSI=0.3324 | KL(b→c)=0.1826 KL(c→b)=0.1497
알림: KS유의=False PSI대역=경보 → 등급 주의
권고: 모니터링 강화 + 원인 분류 착수(계절/정책/시스템 변경/데이터 결함)
```

표 11.6 분포 비교 실측(기준: 2026-06-28 22:00, n=40)

항목	비교 A: 1시간 뒤(6/28 23:00)	비교 B: 9일 뒤(7/7 22:00)
평균	20.025 → 20.775	20.025 → 17.75
KS 통계량 / p-value	0.175 / 0.5786	0.225 / 0.2657
PSI(기준 분위수 5구간)	0.1193	0.3324
KL(기준→현재 / 현재→기준)	0.0646 / 0.0548	0.1826 / 0.1497
KS 유의($\alpha=0.05$) / PSI 대역	False / 주의	False / 경보
알림 등급	주의	주의

분포 이동의 모양은 구간별 측정소 수로 보는 것이 가장 빠르다. 구간은 기준 스냅샷의 분위수 5등분이고(양 끝은 열어 둠), 빈도는 증거 JSON의 `baseline_counts` · `current_counts` 필드 그대로다.

표 11.7 구간별 측정소 수(기준 분위수 5구간, PM10)

구간	기준(6/28 22:00)	1시간 뒤(6/28 23:00)	9일 뒤(7/7 22:00)
17 미만	7	3	13
[17, 19)	5	6	7
[19, 21)	10	12	11
[21, 22)	5	3	5
22 이상	13	16	4

1시간 뒤(비교 A)는 위쪽 구간이 다소 증가한 정도지만, 9일 뒤(비교 B)는 양상이 다르다 — 최하 구간이 7→13개소로 늘고 최상 구간이 13→4개소로 줄어, 분포 전체가 아래로 이동했다.

비교 A의 KS-p-value·평균은 2장 실습 2.2의 실측과 정확히 일치했다(`comparison_a_matches_ch2: true`) — 다른 장의 코드가 같은 데이터에서 같은 값을 내는 것을 확인하는 재현 검증이다. $PSI=KL(기준\parallel 현재)+KL(현재\parallel 기준)$ 의 항등식도 두 비교 모두에서 반올림 전 값으로 확인되었다(`psi_equals_kl_sum: true` — 표의 반올림 값을 더하면 마지막 자리가 ± 0.0001 어긋날 수 있다).

관찰

1시간 간격에도 PSI는 “주의” 대역에 들어갔다. 비교 A는 2장에서 “값은 변하고 구조는 같다”로 판정된 쌍이다 — KS는 그 판정 그대로(유의하지 않음)인데, PSI는 0.1193으로 관행 임계 0.1을 넘었다. 원인은 소표본이다: 5구간에 40건이면 구간당 기대 8건 — 측정소 두세 곳의 값이 구간 경계를 넘나들기만 해도 비율이 5%p씩 변동하고 PSI가 누적된다. 관행 임계(0.1)를 소표본에 그대로 적용하면 **평시에도 매시간 “주의”가 발생한다**는 것을 실데이터가 보여 준 것이다. 이 실습의 알림 규칙이 “주의” 등급에 사람 호출을 붙이지 않고(표 11.5), “경보”에 KS 유의와 PSI 0.25를 **함께** 요구하는 이유가 여기서 실증된다 — 임계와 규칙은 데이터의 크기·출력임에 맞춰 튜닝(tuning)되어야 하는 운영 파라미터다(보충: 알림 피로).

9일 뒤의 분포는 아래로 이동했고, 두 지표는 서로 다른 답을 냈다. 비교 B의 평균은 20.025→17.75로 내려갔고, 구간별 측정소 수를 보면 이동의 모양이 뚜렷하다 — 최하 구간(17 미만)이 7개소에서 13개소로 늘고, 최상 구간(22 이상)이 13개소에서 4개소로 줄었다(현재 최솟값 8.0은 기준 스냅샷의 범위 밖이다 — 구간 양 끝을 열어 둔 설계가 이 값을 놓치지 않고 끝 구간에 잡았다). 이 이동을 PSI는 0.3324로 **경보 대역(≥ 0.25)** 이라 답했다. 그러나 KS는 $D=0.225$, $p=0.2657$ — $n=40$ 끼리의 비교에서 유의 판정이 나오려면 D 가 대략 0.30을 넘어야 하는데(점근 임계 $1.358 \times \sqrt{(2/40)} \approx 0.304$), 0.225는 이에 미치지 못한다. 즉 “이동의 크기는 경보 수준인데, 이 표본 크기에서는 우연을 배제할 수 없다”가 두 지표를 함께 읽은 결론이고, 조합 규칙은 그래서 사람을 부르는 경보가 아니라 **주의**(감시 강화·원인 분류 착수)로 판정했다. 표본이 40이 아니라 400이었다면 같은 D 로도 KS가 유의해져 경보가 성립했을 것이다 — 표 11.4의 “검정이 제동 장치가 된다”는 논지가 실측으로 확인된 셈이다.

간격이 늘자 모든 지표가 같은 방향으로 커졌다. 1시간(비교 A)에서 9일(비교 B)로 가며 KS는 0.175→0.225, PSI는 0.1193→0.3324, $KL(기준\rightarrow 현재)$ 은 0.0646→0.1826 — 2장에서 “며칠~몇 주 간격이면 이 수치가 벌어질 것”이라 예고했던 바로 그 현상이다. 원인은 무엇인가? 지표는 답하지 않는다 — 6월 말에서 7월 초로 넘어가는 계절·기상 요인이 유력한 후보지만, 그 판정은 분포 수치 밖의 맥락 정보(기상 기록·측정소 공지)를 요구한다. 알림 다음이 재학습이 아니라 원인 분류인 이유(11.4)가 여기서도 반복된다.

드리프트 알림 평가 보고서(정본 산출물)

실습이 생성하는 `ch11_drift_report.json` 이 보고서의 실체다 — 비교별 지표·알림 판정·권고 조치에 더해, 판정 규칙 자체(어떤 임계를 왜 썼는가)와 해석 한계(소표본·단일 변수)를 명기한다. 보고서의 요건을 표로 정리하면:

보고서 항목	이 실습의 기록	왜 필요한가
비교 대상·창 정렬	22:00 vs 22:00, 9일 간격	교란 없는 비교임의 증거
지표와 값	KS-p, PSI, KL(양방향)	판정의 근거 수치
판정 규칙	경보=KS유의 AND $PSI \geq 0.25$	같은 값이라도 규칙이 다르면 판정이 다르다
알림 등급과 권고	등급별 분리 기록	알림≠재학습(11.4)
한계	n=40, 단일 변수, 관행 임계 차용	판정의 신뢰 범위

검수 상황을 고려하면 이 보고서의 용도가 분명해진다 — “드리프트 감시를 했는가”라는 질문에 대시보드 화면 캡처가 아니라, 판정 규칙과 이력이 담긴 이 형식의 기록으로 답하는 것이다.

산출물 안내

`data/input/airquality_seoul_2200_0628.json` · `_2300_0628.json`: 2장 커밋 스냅샷의 복사본(기준·비교 A)

`data/input/airquality_seoul_2200_0707.json`: 이 장에서 수집한 시각 정렬 스냅샷(비교 B)

`data/output/ch11_compare_a_1hour.json` · `ch11_compare_b_9days.json`: 비교별 지표·판정

`data/output/ch11_drift_report.json`: 드리프트 알림 평가 보고서(정본 산출물 — 규칙·판정·한계 명기)

`data/output/ch11_collect_log.txt`: 이 장 수집 당시의 폴링 콘솔 기록을 보존한 것(게시 지연의 증거 — 재실행 산출물이 아님)

실습과 운영의 간극(축소 지점 목록)

스냅샷 2개의 1회 비교다 — 운영은 연속 창(매일·매시)의 반복 비교이고, 판정 이력이 시계열로 쌓인다.

변수 하나(PM10)다 — 운영은 모델 입력 전체(다변수)를 각각 감시하고 종합한다.

알림 “판정”까지만 구현했다 — 실제 알림 전송(메신저·문자)·대시보드·on-call 절차는 범위 밖이다.

에어코리아 데이터는 입력 분포 감시의 **시연 재료**다 — 10장 민원 예측 API의 실제 입력(전일 민원 건수) 감시가 되려면 요청 로그 수집이 선행되어야 한다(표 11.2의 수집 지점).

위험 식별(평가표 연계)

위험	이 실습에서의 증거	운영 대응
소표본 과신	1시간 간격에도 PSI 0.1193(주의 대역)	표본 확대·임계 튜닝·검정과 거리의 교차 요구
창 비정렬 교란	22:00 정렬 설계(비교 B)	기준·비교 창의 조건 정렬 규칙 명문화
알림 피로	주의 등급에 사람 호출 없음	등급별 대응 분리(표 11.5), 임계 정기 재검토
원인 미분류 재학습	권고 조치가 원인 분류를 선행 요구	판단표(11.4) 절차화

보충(전문가 트랙 포인터)

KS-PSI-KL의 적용 조건 심화: 대표본에서는 모든 검정이 유의해져 거리 지표가 실질 판단을 말한다 — 표본 크기별 지표 선택 논의는 Evidently AI의 비교 자료가 출발점으로 좋다. PSI 임계의 통계적 성질(오류율 관점의 재해석)은 Yurdakul(2018)을 참고한다.

레이블 지연 상황의 성능 추정: 레이블 도착 전에 성능을 근사하는 기법들이 있다(분류의 confidence 기반 추정, 회귀의 오차 추정 — NannyML 문서의 CBPE-DLE가 구현 예). 원리는 공통이다: 모델 자신의 출력 성질로 성능을 추정하되, 레이블이 도착하면 반드시 사후 검증한다.

알림 피로와 임계값 튜닝: 오경보율을 낮추면 놓침이 늘고, 민감하게 하면 피로가 쌓인다. 간단한 계산으로 확인할 수 있다 — 매시간 KS 판정(하루 24회)을 $\alpha=0.05$ 로 돌리면, 분포에 아무 변화가 없어도 판정당 5% 확률로 “유의”가 나와 기대 오경보가 하루 약 1.2회, 한 달이면 약 36회다(판정 간 독립을 가정한 근사). 오경보 36회를 겪은 담당자는 37회째를 확인하지 않는다 — 그래서 임계는 한 번 정하는 상수가 아니라, 오경보 이력과 함께 정기 재검토되는 운영 파라미터이고, 사람 호출은 최상 등급에만 붙인다(이 실습의 “주의/경보” 분리가 그 축소판이다).

핵심 용어

골든 시그널: 지연·트래픽·오류·포화 — 시스템 감시의 표준 어휘(포화는 12장)

시스템 지표 / 모델 지표: “살아 있는가”와 “옳은 답인가” — 층이 다르면 고장의 형태도 다르다

레이블 지연: 정답이 늦게 도착하는 구조적 제약 — 모델 감시가 층을 이루는 이유

데이터 드리프트: 입력 분포 $P(X)$ 의 변화 — 레이블 없이 감지 가능

컨셉 드리프트: 관계 $P(Y|X)$ 의 변화 — 원칙적으로 레이블 필요

KS 2표본 검정: 누적분포 최대 간격의 비모수 검정 — “우연인가”에 답한다

PSI: 구간 비율 이동의 합산 지표 — “얼마나 큰가”에 답하며, KL의 대칭화(합)와 같다
비교창 정렬: 기준·비교 창을 같은 조건(시각·요일)으로 맞추는 설계 — 교란 제거
재학습 트리거: 정기·이벤트·혼합 — 어느 쪽이든 재학습 모델은 9장 게이트를 재통과한다

검수 질문 한 줄 요약

발주·검수 문서에서 이 장은 세 질문으로 압축된다: ① 시스템 지표와 모델 지표가 **따로** 정의되어 있는가(대시보드에 자연·오류율만 있으면 2층 감시 부재), ② 드리프트 판정의 규칙(지표·임계·창 정렬)과 이력이 기록으로 남는가(화면 캡처는 기록이 아니다), ③ 재학습의 조건·승인·재검증 절차가 명시되어 있고 재학습 모델이 기존 승격 게이트를 재통과하는가(게이트를 건너뛰면 검수 근거가 무효화된다). 셋 다 없으면 그 시스템의 AI는 배포된 날의 성능을 근거로 무기한 신뢰되고 있는 것이다.

다음 장 예고

이 장의 감시는 “이상이 생겼는가”를 사후에 발견하는 층이다. 그런데 골든 시그널의 넷째 — 포화 — 는 아직 다루지 않았다: 트래픽이 지금의 열 배가 되면 이 API는 버티는가, 자연 꼬리(p99)는 어디까지 증가하는가, 병목은 CPU인가 메모리인가 I/O인가. 12장은 이 질문을 사후 발견이 아니라 **사전 실측**으로 바꾼다 — Locust로 부하를 걸어 한계를 재고, 병목 유형을 구분하고, 스케일링 전략을 설계한다. 감시(11장)가 임계를 넘는 순간을 알려 준다면, 부하 테스트(12장)는 그 임계가 어디인지 미리 알려 준다.

참고문헌

- Beyer, B., Jones, C., Petoff, J., & Murphy, N. R. (Eds.). (2016). *Site Reliability Engineering* — Ch. 6: Monitoring Distributed Systems. O'Reilly. <https://sre.google/sre-book/monitoring-distributed-systems/>
- Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4). <https://doi.org/10.1145/2523813>
- Lu, J., Liu, A., Dong, F., Gu, F., Gama, J., & Zhang, G. (2019). Learning under Concept Drift: A Review. *IEEE Transactions on Knowledge and Data Engineering*, 31(12), 2346–2363. <https://doi.org/10.1109/TKDE.2018.2876857> (프리프린트 arXiv:2004.05785 — <https://arxiv.org/abs/2004.05785>)
- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden Technical Debt in Machine Learning Systems. *NeurIPS 2015*. https://papers.nips.cc/paper_files/paper/2015/hash/86df7dcfd896fcdf2674f757a2463eba-Abstract.html
- Yurdakul, B. (2018). *Statistical Properties of Population Stability Index* (PhD dissertation). Western Michigan University. <https://scholarworks.wmich.edu/dissertations/3208/>

SciPy. (n.d.). *scipy.stats.ks_2samp* — *SciPy Manual*.

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ks_2samp.html

Evidently AI. (n.d.). *Data drift detection for large datasets*.

<https://www.evidentlyai.com/blog/data-drift-detection-large-datasets>

NannyML. (n.d.). *NannyML — Post-deployment data science*. <https://www.nannyml.com/>