

chapter16

제16장 공공 AI 윤리와 규제

9장부터 14장까지 모델을 만들고(9장) 배포하고(10장) 감시하고(11장) 부하를 견디게 하고(12장) 피처를 거버넌스하고(13장) 하나로 통합했다(14장). 이 장이 묻는 질문은 다르다 — 잘 작동하는가가 아니라 **정당한가**. 지연 시간이 낮고 처리량이 높아도, 특정 지역을 체계적으로 불리하게 예측한다면 그 시스템은 공공에 쓰기에 정당하지 않다. 이 장은 공공 AI의 다섯 원칙(공정성·투명성·책임성·프라이버시·안전성)을 이미 만든 장치에 대응시키고, 그중 공정성과 투명성을 9장의 **실제 배포 모델**에서 실측으로 시연한다. 임의로 작성한 그룹 성능은 하나도 없다 — 9장 champion 모델이 세 지역구를 실제로 어떻게 예측하는지를 그룹별로 분해하면, 편향은 저절로 드러난다. 이어 정책 AI 평가 기준(법적 정합성·중립성·유해성)을 루브릭으로, 개인정보 영향평가와 자동화된 의사결정 이의제기를 국내법 조문에 걸어 검토 지점으로 정리한다. 실습(★★★☆☆)은 9장 산출물 스냅샷(snapshot)만으로 서버 없이 완주한다.

학습 목표

공공 AI의 다섯 원칙이 각각 어떤 장치로 구현되는지, 구호가 아니라 앞 장에서 만든 기제와 짝지어 설명할 수 있다.
그룹측 형평성 지표·배포 차단 임계값을 스스로 정하고 그 근거를 밝힐 수 있다.
편향성 평가(그룹별 성능 분해)와 설명 가능성(계수·permutation importance), 모델 카드 작성의 기본 방법을 실제 모델에 적용할 수 있다.
정책 AI 평가 루브릭(법적 정합성·중립성·유해성)을 설계하고, 개인정보 영향평가·자동화된 결정 이의제기의 법적 검토 지점을 정리할 수 있다.

16.1 공정성, 투명성, 책임성, 프라이버시, 안전성

학습 목표

공공 AI의 다섯 원칙을 정의하고, 각 원칙이 이 책에서 이미 만든 장치에 어떻게 대응하는지 안다.
집단 공정성의 세 정의(demographic parity·equalized odds·calibration)를 개념으로 구분한다.

직관: 원칙은 구호가 아니라 이미 만든 장치다

공공 AI 윤리 문서는 대개 다섯 단어로 요약된다 — 공정성(fairness), 투명성(transparency), 책임성(accountability), 프라이버시(privacy), 안전성(safety). 문제는 이 단어들이 선언에 그치기 쉽다는 것이다. “우리 시스템은 공정합니다”라는 문장은 검증할 수 없으면 구호일 뿐이다. 이 책의 관점은 다르다 — 다섯 원칙은 저마다 **이미 만든 기제**에 대응하며, 그 기제가 남긴 실측 기록이 원칙의 증거가 된다.

표 16.1 공공 AI 다섯 원칙과 대응 장치(장 간 회수)

원칙	답하는 질문	대응 장치(이 책)	이 장의 실측
공정성	특정 집단을 체계적으로 불리하게 하는가	그룹별 성능 분해	16.2 champion 그룹 MAE·편향
투명성	왜 이렇게 예측했는지 설명·문서화되는가	계수·permutation importance, 모델 카드	16.3 설명 결과·모델 카드 9절
책임성	누가 언제 무엇을 했는지 추적되는가	접근 로그(13장)·데이터 지문(9장)	지문 96f6b6b3 교차 확인
프라이버시	목적 밖 이용·민감정보를 통제하는가	목적 제한·등급(13장)·영향평가	16.5 PIPA 제18·23·33조
안전성	배포 전 게이트·배포 후 감시가 있는가	승격 게이트(10장)·드리프트 감시(11장)	층 구분(16.2 vs 11장)

이 표는 각 원칙을 어느 절과 실습에서 확인하는지 보여 준다. 공정성과 투명성은 16.2~16.3에서 실제 모델로 시연하고, 책임성은 9장 지문과 13장 로그를 사용해 확인한다. 프라이버시와 안전성은 각각 16.5와 11·10장에서 다룬다. 이 장은 앞 장의 장치를 공정성·투명성·책임성·프라이버시·안전성 기준으로 다시 분류한다.

핵심 개념: 집단 공정성의 세 정의

공정성에는 여러 수학적 정의가 있고, 그중 분류(classification) 문제에서 널리 쓰이는 집단 공정성 세 가지를 먼저 개념으로 정리한다. 셋은 서로 다른 것을 요구하며, 동시에 만족하기 어렵다는 것이 공정성 연구의 핵심 발견이다.

표 16.2 집단 공정성 세 정의(분류 기준 — 개념)

정의	요구 조건	직관
인구통계 동등성(demographic parity)	긍정 판정 비율이 그룹 간 같다: $P(\hat{Y}=1 A=a)$ 동일	결과의 몫이 그룹 간 같다
균등 기회·균등 오즈(equalized odds)	참·거짓 양성률(TPR·FPR)이 그룹 간 같다	실제로 맞는 사람 안에서 판정률이 같다
그룹 캘리브레이션(calibration)	같은 점수의 실제 정답률이 그룹 간 같다	점수의 의미가 그룹 간 같다

세 정의는 Hardt, Price, Srebro(2016)가 제안한 균등 오즈를 포함해 분류 문제에서 정립되었다. 여기서 적용 자격을 명시해야 한다 — 이 정의들은 **분류 기원**이고, 우리 프로젝트의 `complaint_daily_forecaster` 는 건수를 예측하는 **회귀** 모델이다. 그래서 이 장은 분류 지표를 그대로 가져다 쓰지 않고(방법론 차용이지 직접 선례가 아니다), 회귀에 맞는 유사지표 — 그룹별 오차(MAE), 그룹별 편향(평균 부호오차), 그룹 캘리브레이션(그룹 예측평균 대 실측평균) — 로 번역해 실측한다. 개념은 분류에서 배우되, 실측은 우리 모델이 지지하는 회귀 지표로 한다.

왜 셋을 동시에 만족할 수 없는가 — 공정성 불가능성 정리

“세 정의는 동시에 만족하기 어렵다”는 문장은 경험칙이 아니라 **증명된 수학적 사실**이다. Kleinberg, Mullainathan, Raghavan(2016)은 위험 점수가 그룹 간 **캘리브레이션**(같은 점수의 실제 정답률이 같음)과 **균형**(양성·음성 집단의 평균 점수가 그룹 간 같음)을 동시에 만족하려면, 두 그룹의 기저율(base rate)이 애초에 같거나 예측이 완벽한 두 극단을 빼고는 **불가능함**을 보였다. Chouldechova(2017)는 같은 충돌을 미국 재범 예측 도구 COMPAS에서 구체화했다 — 두 집단의 재범 기저율이 다르고 예측이 완벽하지 않은 한, 도구가 그룹 캘리브레이션을 만족하면 오탐률(FPR)·미탐률(FNR)이 그룹 간 어긋난다. 엄밀히 하면 이 불가능성은 표 16.2의 세 정의 전체가 아니라 **캘리브레이션과 오류율 균형(균등 오즈 계열) 사이의 충돌**을 가리킨다 — 셋을 동시에 세우려는 시도가 바로 이 충돌에 걸리는 것이다. 두 연구 모두 적용 자격을 명시해야 한다 — Kleinberg et al. 은 분류·점수 기원이므로 우리 회귀 모델의 직접 선례가 아니라 **왜 공정성 정의가 상충하는지**의 배경 원리로 인용하며, Chouldechova는 형사사법 도메인이라 민원 예측의 선례가 아니라 배경 사례다.

이 불가능성이 실무에 주는 함의는 분명하다 — “완벽하게 공정한 모델”은 존재하지 않으므로, 시스템은 **어떤 공정성을 우선하고 어떤 것을 양보하는지**를 명시적 정책 결정으로 밝혀야 한다. 이 트레이드오프를 체계적으로 다룬 표준 교재가 Barocas, Hardt, Narayanan의 *Fairness and Machine Learning*(fairmlbook.org, 온라인 무료 공개)이며, 이 장은 그 교재의 개념 틀을 배경 원리로 차용해 회귀 유사지표로 번역한다.

공공 사례

복지 급여 심사 모델이 지역별로 승인율이 다르다고 가정한다. demographic parity는 “지역 간 승인율이 같아야 한다”를, equalized odds는 “실제 자격이 있는 사람 중 승인 비율이 지역 간 같아야 한다”를, calibration은 “같은 위험 점수의 실제 부정수급률이 지역 간 같아야 한다”를 요구한다. 셋은 종종 상충한다 — 그래서 공공 시스템은 “어떤 공정성을 택했는가”를 먼저 밝혀야 하며, 그 선택

자체가 정책 결정이다. ### 핵심 정리 - 공공 AI 다섯 원칙은 구호가 아니라 이미 만든 장치(그룹 분해·모델 카드·로그·지문·게이트·감시)에 대응한다. - 집단 공정성 세 정의(parity-odds-calibration)는 서로 다른 것을 요구하며, 특히 **캘리브레이션과 오류율 균형**은 기저율이 다르면 동시 만족이 **수학적으로 불가능**하다(Kleinberg et al. 2016·Chouldechova 2017) — 그래서 “무엇을 우선하는가”가 정책 결정이 된다. - 분류 기원 지표는 개념으로 배우고, 회귀 모델은 그룹 MAE·편향·캘리브레이션의 유사지표로 실측한다.

16.2 편향성 평가의 기본 개념

학습 목표

보호속성과 운영 그룹축을 구분하고, 회귀 공정성 지표를 실제 모델에 적용한다.
편향의 방향(부호)이 왜 크기만큼 중요한지 이해한다.

직관: 전체 성능이 좋아도 그룹을 나누면 편향이 보인다

9장의 champion 모델은 전체 훈련 MAE가 1.0이었다. 얼핏 “평균 1건 오차”는 무난해 보인다. 그러나 이 하나의 숫자는 그룹 간 차이를 감춘다. champion은 baseline_mean — 즉 **모든 입력에 상수 6.0을 예측**하는 모델이다(9장에서 승격된 v1). 상수 예측값 6.0이 세 지역의 실제값과 얼마나 차이 나는지 지역별로 계산하면, 전체 평균에서 확인하기 어려운 편향이 나타난다.

편향 평가의 출발점은 **그룹축(protected attribute 또는 group)**을 정하는 것이다. 여기서는 지역구(강남·마포·관악)를 그룹축으로 쓴다. 명시하면 지역은 성별·연령·장애 같은 법적 보호속성이 아니라 **운영 그룹축**이다. 그러나 지역 형평(균형발전)은 실재하는 공공 공정성 관심사이고, 무엇보다 편향 평가의 **방법** — 그룹별로 성능을 분해해 격차를 보는 것 — 은 그룹축의 종류와 무관하게 동일하다. 지역으로 방법을 익히면 성별·연령으로 그대로 옮길 수 있다.

워크드 예제: 하나의 MAE 1.0에 가려진 3배 격차

실습은 9장 훈련 쌍 6개(3지역 × 2쌍)에 champion(상수 6.0)을 적용하고, 그룹별로 세 지표를 산출했다. 모든 값은 실제 예측에서 나오며 수작업으로 검산된다.

표 16.3 그룹별 편향 평가(실측 — champion, ch12_fairness_report.json)

지역(그룹)	실측 y	예측	MAE	편향(평균 부호오차)	실측평균 → 예측평균
강남구	9, 6	6.0	1.5	-1.5(과소)	7.5 → 6.0
마포구	5, 6	6.0	0.5	+0.5(과대)	5.5 → 6.0
관악구	5, 5	6.0	1.0	+1.0(과대)	5.0 → 6.0

세 가지를 확인한다. 첫째, **그룹 MAE 격차**다. 최악(강남 1.5)과 최선(마포 0.5)의 차이는 격차 1.0, 비율 3.0이다 — 강남의 오차가 마포의 세 배다. 전체 MAE 1.0이라는 하나의 수치로는 확인할 수 없던 사실이다. 둘째, **편향의 방향**이다. 강남은 편향 -1.5 로 **체계적 과소예측**(실측평균 7.5인데 6.0으로 낮게), 마포·관악은 양수로 과대예측이다. 셋째, **그룹 캘리브레이션**이다 — 예측평균은 세 지역 모두 6.0(상수라서)인데 실측평균은 각각 7.5/5.5/5.0이다. 예측이 지역의 실제 수준을 반영하지 못한다.

수작업으로 계산하면 다음과 같다. 강남 실측 [9, 6], 예측 [6, 6]. 오차(예측-실측) = $[-3, 0]$. $MAE = (3+0)/2 = 1.5$, 편향 = $(-3+0)/2 = -1.5$. 마포 [5,6]→[6,6]: 오차 [+1,0], MAE 0.5, 편향 +0.5. 관악 [5,5]→[6,6]: 오차 [+1,+1], MAE 1.0, 편향 +1.0. 전체 = $(3+0+1+0+1+1)/6 = 6/6 = 1.0$ — 9장 baseline 훈련 MAE와 정확히 일치한다(14장 자연 MAE 1.0과도 같은 교차값). 편향 평가는 새 데이터를 만들지 않고, 9장이 이미 남긴 예측을 그룹으로 나눠 보는 것뿐이다.

편향은 특정 모델의 결함이 아니다 — 챌린저도 강남을 과소예측한다

“champion(상수 모델)의 성능이 낮아서 강남이 불리한 것 아닌가”라는 반론이 제기될 수 있다. 그래서 9장의 탈락 후보 challenger(선형 모델)에 같은 그룹 분해를 적용해 보면, 편향이 특정 모델의 결함이 아니라 **구조적임**이 드러난다.

표 16.4 champion vs challenger 그룹 편향 비교(실측 — `ch12_fairness_report.json`)

지역(그룹)	champion MAE·편향	challenger MAE·편향	두 모델 공통
강남구	1.5 · -1.5	1.9091 · -0.9545	둘 다 과소예측 (부호 $-$)
마포구	0.5 · $+0.5$	0.5 · $+0.2273$	둘 다 과대예측
관악구	1.0 · $+1.0$	0.7273 · $+0.7273$	둘 다 과대예측
(그룹 격차·비율)	1.0 · 3.0	1.4091 · 3.8182	강남이 최악 그룹

핵심은 부호의 일치다. 상수 모델(champion)이든 전일 건수를 쓰는 선형 모델(challenger)이든, **강남은 음의 편향(과소예측), 마포·관악은 양의 편향(과대예측)**으로 방향이 같다. 심지어 선형 모델은 강남 MAE가 1.9091로 상수 모델(1.5)보다 오차가 크고(선형의 전체 MAE는 1.0455로 9장 반려 당시 값과 일치한다) 그룹 격차 비율도 3.8182로 더 벌어진다. 이는 “더 정교한 모델을 쓰면 편향이 사라진다”는 흔한 기대가 여기서는 성립하지 않음을 뜻한다 — 주어진 피쳐(전일 민원 건수)로는 강남의 높은 실제 수준을 예측할 신호 자체가 부족하기 때문이다. 16.3에서는 permutation importance로 모델이 피쳐를 사용하는 정도를 확인해 이 원인을 분석한다.

왜 방향이 크기만큼 중요한가

편향의 부호가 정책적으로 결정적이다. champion을 지역별 민원 대응 인력 배분에 쓴다고 가정한다. 강남은 실제로 하루 평균 7.5건인데 모델은 6.0으로 과소예측한다 — 즉 **고민원 지역에 인력이 덜 배정된다**. 반대로 관악·마포는 과대예측되어 상대적으로 여유가 생긴다. 오차 크기(MAE)만 보면 “강남이 부정확하다”에서 그치지만, 부호까지 보면 “강남이 체계적으로 과소 배분된다”는 방향성 있는 불이익이 드러난다. 공정성 평가가 절댓값 오차뿐 아니라 부호 있는 편향을 함께 보는 이유다.

무엇을 형평으로 잴 것인가 — 그룹측·지표·임계값의 선택

여기까지는 지표를 정해 놓고 계산하는 순서였다. 실제 발주에서는 그 앞에 세 가지 결정이 온다 — 어떤 측으로 그룹을 나눌 것인가, 형평을 무엇으로 잴 것인가, 격차가 얼마부터 배포를 막을 것인가.

첫째, 그룹측이다. 이 장은 지역구로 나뉘었지만 연령·소득분위·장애 여부·접수 채널로 나눌 수도 있다. 나누지 않은 측의 편향은 평가에 잡히지 않는다 — 지역으로만 쪼갰 평가는 “고령층이 불리하다”를 발견하지 못한다. 그래서 그룹측 선택은 무엇을 볼지의 선택이자 동시에 **무엇을 안 볼지의 선택**이다. 근거는 두 갈래에서 온다. 법이 보호하는 속성(성별·연령·장애)과 정책이 정의한 형평 측(지역 균형발전·취약계층)이다. 둘 중 어느 쪽도 아닌 측을 골랐다면, 그 측이 이 결정에서 왜 형평 문제를 일으키는지를 적어야 한다.

둘째, 지표다. 같은 실측에서도 형평을 무엇으로 재느냐에 따라 결론이 달라진다. 표 16.3의 champion 결과 하나에서 최소 네 가지를 뽑을 수 있다 — 그룹 MAE의 차($1.5 - 0.5 = 1.0$), 그룹 MAE의 비($1.5 \div 0.5 = 3.0$), 최악 그룹의 편향 절댓값(강남 1.5), 그룹 캘리브레이션 격차(실측평균 7.5·5.5·5.0 대 예측 6.0). 차와 비는 특히 다르게 반응한다. 오차의 절대 수준이 낮으면 비는 작은 변화에도 크게 뛰고, 차는 반대로 오차가 큰 영역에서 그룹 간 불이익을 과소평가한다. 어느 쪽을 쓸지는 결정의 성격이 정한다 — 인력 배정처럼 **절대 건수**가 곧 불이익이면 차가, 승인·탈락처럼 **비율**이 곧 불이익이면 비가 맞다.

셋째, 임계값이다. 미국 고용 선발의 이른바 4/5 규칙(다음 절)처럼 굳어진 관행값이 있지만, 근거 없이 차용하면 규칙을 지킨 것이지 형평을 측정한 것이 아니다. 임계값은 결정의 결과에서 역산한다 — 이 예측이 인력 배정에 쓰인다면, 편향 1건이 인력 몇 명의 차이가 되고 그 인력 차가 민원 처리 시간을 얼마나 늘리는지, 어느 지점부터 시민이 실제 불이익을 겪는지가 임계값의 근거가 된다. 역산에 사용할 값이 아직 없다면 “임계값 미정, 근거 확보 후 확정”이라고 적는 편이 임의의 숫자를 적는 것보다 낫다.

여기에 16.1의 불가능성이 제약으로 걸린다. 세 지역의 실측평균은 7.5·5.5·5.0으로 서로 다르다 — 기저율이 다르다는 뜻이다. 그러면 캘리브레이션과 오류율 균형을 동시에 통과 조건으로 거는 게이트는 어떤 모델도 통과하지 못한다. 형평성 게이트에 “모든 지표를 다 만족”을 조건으로 쓰지 않는 이유가 여기 있다. 우선할 지표 하나를 정하고, 양보한 지표는 무엇을 얼마나 양보했는지 함께 보고한다.

이 게이트를 배포 파이프라인에 붙이면 통과 여부 자체가 관리 지표가 된다. 민간에서는 배포 전 공정성 게이트(그룹 격차 임계 이내)를 통과한 모델의 비율을 **공정성 감사 통과율**로 추적하고 CI/CD에 자동화한다. 공공에서도 형태는 같되, 통과율이 낮을 때 배포를 미루는 근거가 매출·일정이 아니라 형평 의무라는 점이 다르다.

민간의 알고리즘 공정성 감사를 공공으로 적용하기

그룹별 성능 분해는 공공만의 발명이 아니라, 민간이 규제·소송 압박 속에서 먼저 정교화한 방법이다. 민간에서 이 방법이 어떻게 쓰이는지를 알면, 같은 절차를 공공 맥락으로 옮기기 쉽다.

민간의 대표 두 사례는 이렇다. 첫째, **신용대출 심사**다. 미국의 공정대출 감독·감사에서는 보호집단(인종·성별 등)에 대한 **차별적 영향(disparate impact)** — 의도와 무관하게 특정 집단의 승인율·조건이 체계적으로 불리해지는 결과 — 분석이 핵심 도구로 쓰인다. 은행의 모델 위험관리팀은 신용 모델을 배포하기 전 승인율·부도예측 오차를 집단별로 분해해, 특정 집단이 체계적으로 불리하지 않은지를 점검한다. 둘째, **채용 스크리닝**이다. 미국 고용 선발에서는 어느 집단의 선발률이 최대 선발 집단의 80% 미만이면 차별적 영향을 의심하는 “4/5 규칙”이 오랜 감사 기준으로 쓰인다. 이력서 자동 선별 모델도 같은 기준으로 특정 성별·학교의 통과율을 체계적으로 낮추는지 감사하는데, 과거 채용 데이터에 담긴 편향을 모델이 학습·증폭한 실패 사례가 반복 보고되어 왔다(대표적으로 한 대형 기술기업의 이력서 선별 실험이 여성 지원자를 불리하게 평가해 폐기된 일이 널리 알려졌다). 두 경우 모두 결과를 집단별로 나누고 집단별 승인율과 오차를 비교한다.

이 방법을 공공으로 옮기면 세 가지가 달라진다. 첫째, **대응물의 치환**이다. 민간의 “대출 승인/거부”, “채용 통과/탈락”은 공공에서 “민원 대응 우선순위 배정”, “복지 급여 심사 승인”으로 바뀐다. 이 장의 실습이 지역별 민원 예측 오차를 분해한 것이 바로 민간 감사의 공공판이다. 둘째, **법적 의무의 강도**다. 민간의 공정성 감사는 상당 부분 규제 준수·평판 관리의 자율 영역이지만, 공공의 자동화 심사는 개인정보 보호법 제33조(영향평가)와 제37조의2(자동화된 결정에 대한 설명·거부권)로 **법적 직접 요구**한다 — 즉 공공에서는 “감사할 것인가”가 선택이 아니라 의무에 가깝다(16.5·16.6에서 상술). 셋째, **형평의 정의**다. 민간이 주로 법정 보호집단(인종·성별)에 초점을 두는 반면, 공공은 지역 균형발전·취약계층 배려처럼 정책이 정의하는 형평 축까지 감사 대상에 넣는다. 이 장이 지역구를 그룹축으로 삼은 것은 그래서 자연스럽다. 방법(그룹 분해)은 민간에서 배우되, 무엇을 그룹으로 볼지와 왜 반드시 해야 하는지는 공공의 법·정책이 규정한다.

축소 지점: 표본이 6개라는 것

이 평가는 3지역 × 2쌍, 총 6개 표본에서 산출되었다. 통계적 유의성을 주장하기에는 지나치게 작다 — 강남의 편향 -1.5가 우연인지 구조인지 이 표본만으로는 단정할 수 없다. 그래서 이 절의 목적은 “강남이 차별받는다”는 실세계 주장이 아니라, **편향 평가의 구조를 실제 모델로 시연**하는 것이다(11장의 소표본 KS 검정, 13장의 “개수가 아니라 구조” 논지와 같은 태도). 요점은 수치의 크기가 아니라, 하나의 전체 MAE를 그룹으로 나누는 절차와 그것이 드러내는 편향의 방향이다. 표본이 수천 개가 되어도 이 절차는 똑같고, 그때 비로소 유의성을 논할 수 있다.

공공 사례

채용·복지·치안 예측 모델이 전체 정확도만 보고했다가, 사후 감사에서 특정 집단의 오류율이 몇 배 높았음이 드러나는 사례가 반복된다. 전체 지표는 다수 집단의 결과에 크게 좌우되므로 소수 집단의 편향을 확인하기 어렵다. 검수 관점의 질문은 단순하다 — “이 모델의 성능이 그룹별로 분해되어 보고되었는가, 그리고 특정 그룹이 체계적으로(부호 있게) 불리하지 않은가.” ### 핵심 정리 - 전체 성능 지표는 그룹 편향을 감춘다 — 그룹별로 분해해야 격차(강남/마포 비율 3.0)가 보인다. - 편향은 크기(MAE)와 방향(부호)을 함께 본다 — 강남 편향 -1.5는 고민원 지역의 체계적 과소 배분을 뜻한다. - 소표본(n=6)이라 유의성이 아니라 편향 평가의 구조를 시연한다 — 절차는 규모와 무관하게 같다. - 그룹축·지표·임계값은 계산 이전의 설계 결정이다 — 같은 실측에서도 차를 쓰느냐 비를 쓰느냐로 결론이 갈리고, 기저율이 다르면 전 지표 동시 통과를 조건으로 걸 수 없다.

16.3 설명 가능한 AI와 모델 카드

학습 목표

계수와 permutation importance로 모델의 예측 근거를 설명한다.
편향의 근본 원인을 설명가능성으로 규명하고, 모델 카드로 문서화한다.

직관: “왜 강남을 과소예측하나”에 설명이 답한다

16.2는 champion이 강남을 과소예측한다는 **현상**을 보였다. 설명 가능한 AI(explainable AI, XAI)는 그 **원인**을 묻는다. champion은 baseline_mean, 즉 상수 6.0을 내는 모델이다. 상수 모델은 입력을 전혀 쓰지 않는다 — 강남의 전일 건수가 8이든 관악이 5이든 똑같이 6.0을 낸다. 그러니 지역 차이를 반영할 방법이 애초에 없다. **편향의 근본 원인은 모델이 피처를 무시한다는 것이며, 이것을 정량으로 보이는 도구가 permutation importance(순열 중요도)다.**

permutation importance는 한 피처의 값을 무작위로 뒤섞었을 때 성능이 얼마나 저하되는지로 그 피처의 기여를 측정한다. 모델이 그 피처에 의존하면 뒤섞을 때 성능이 크게 저하되고(중요도 높음), 의존하지 않으면 변화가 없다(중요도 0).

설명 방법은 크게 둘로 나뉜다. permutation importance처럼 “이 모델이 전체적으로 어떤 피처에 의존하는가”를 보는 **전역(global) 설명**과, “이 한 건의 예측이 왜 이렇게 나왔는가”를 보는 **국소(local) 설명**(현장에서는 SHAP·LIME 같은 도구가 대표적)이다. 이 장이 전역 방법을 택한 이유는 두 가지다 — 첫째, 편향은 개별 예측이 아니라 그룹 전체에 걸친 계통적 현상이라 전역 설명이 맞다. 둘째, 우리 champion은 상수 모델이라 국소 설명조차 퇴화한다: 입력이 무엇이든 예측이 6.0으로 고정되니, 어떤 피처가 이 예측을 밀거나 당겼다고 말할 국소적 기여 자체가 존재하지 않는다. 상수 모델에서는 전역이든 국소든 “설명할 것이 없다”는 사실이 곧 편향의 원인을 가리킨다. 모델을 개선해 피처를 실제로 쓰게 되면, 그때 비로소 국소 설명이 “이 민원 예측이 왜 높았는가”를 사건 단위로 답할 수 있고, 이는 제37조의2 설명요구권(16.6)에 응답하는 기술적 토대가 된다.

표 16.5 설명 결과(실측 — 계수·permutation importance)

모델	계수(slope)	permutation importance	설명
champion(상수 6.0)	없음	0.0	피처를 쓰지 않음 → 지역 차이 반영 불가 (편향의 근본 원인)
challenger(선형)	0.4091	-0.0455	계수가 곧 설명이나, 이 표본에서 피처 기여가 약함

champion의 permutation importance는 정확히 0.0이다 — 상수 모델은 피처를 뒤섞어도 예측이 안 변하니 당연하다. 이 0.0에 16.2 편향의 원인이 그대로 나타난다: 모델이 지역을 구분하는 어떤 신호도 쓰지 않았기 때문에, 지역별로 다른 실제 수준(7.5/5.5/5.0)을 단일 상수(6.0)로 축약한 것이다.

challenger(9장 v2 선형 모델)는 다르다. 계수 slope 0.4091은 그 자체로 설명이 된다 — 전일 민원이 1건 증가하면 익일 예측이 0.4091만큼 증가한다. 선형 모델은 계수를 읽는 것이 곧 설명이라는 점에서 본래 투명하다. 그런데 이 모델의 permutation importance는 -0.0455로 음수다. 피처를 뒤섞었더니 오히려 오차가 줄었다는 뜻이다. 이는 이 극소 표본에서 전일 건수가 익일을 예측하는데 사실상 도움이 되지 않았음을 말한다 — 9장에서 선형 모델이 baseline보다 MAE가 높아(1.0455 > 1.0) 승격 반려되었던 사실과 정확히 일관된다. 설명가능성이 “이 후보를 왜 떨어뜨렸는가”의 근거를 사후에 제공하는 셈이다.

편향과 설명의 연결

두 모델의 설명을 나란히 놓으면 편향의 구조가 보인다. champion은 피처를 안 써서(중요도 0) 지역을 못 나누고, challenger는 피처를 쓰지만 그 피처(전일 건수)에 강남의 높은 실제 수준을 예측할 신호가 부족하다(중요도 음수). 즉 **강남 편향은 특정 모델의 결함이 아니라, 주어진 피처로는 강남의 높은 민원을 예측하기 어렵다는 구조적 한계**다. 설명가능성이 없었다면 “더 좋은 모델을 쓰자”로 끝났겠지만, 설명은 “피처를 바꿔야 한다 — 지역 특성을 담은 새 피처가 필요하다”는 진짜 처방을 가리킨다(모델 카드의 권고 절과 연결).

모델 카드: 문서도 자동 생성한다

투명성은 설명 결과를 **문서로 남길** 때 완성된다. 모델 카드(model card)는 Mitchell et al.(2019)이 제안한 표준 문서 양식으로, 모델의 용도·지표·평가 데이터·윤리적 고려·한계를 아홉 절로 정리한다. 13장이 감사 점검표를 로그에서 자동 생성했듯, 실습은 모델 카드 9절을 9장 실험 증거와 16장 그룹 편향 실측에서 **자동 생성**한다 — 사람이 임의로 작성하는 자리가 없다.

표 16.6 모델 카드 9절(Mitchell et al. 2019)과 채움 근거

절	내용	채움 근거
1 모델 상세	이름·버전·소유자·지문	9장 레지스트리(registry)·지문 96f6b6b3
2 의도된 용도	용도·범위 밖	지역 예측(교육용), 자동 결정 금지
3 요인	평가 그룹측	지역구(운영 그룹측)
4 지표	그룹 MAE·편향	전체 MAE 1.0
5 평가 데이터	표본·원천	6쌍, 7장 확정 집계
6 훈련 데이터	동일 6쌍·지문	8장 피처 스냅샷
7 정량 분석	그룹별 실측	강남 MAE 1.5 등
8 윤리적 고려	편향·위험	강남 과소예측·자동 결정 금지
9 주의와 권고	한계·개선	n=6 소표본, 피처 개선 권고

모델 카드의 8절(윤리적 고려)과 9절(주의와 권고)이 특히 중요하다 — 전자는 “champion이 강남 그룹을 과소예측해 자원배분에 쓰면 위험하다”를, 후자는 “소표본이라 성능을 주장하지 않으며, 지역 특성 피쳐로 형평을 개선하라”를 명시한다. 이 두 절이 없으면 모델 카드는 홍보 문서가 되고, 있으면 실질적 검수 자산이 된다. 산출된 카드는 `ch12_model_card.md` (사람용)와

`ch12_model_card.json` (기계용) 두 형태다.

민간도 같은 문서를 다른 이름으로 요구한다. 금융권의 모델 위험관리(Model Risk Management, MRM)는 신용·리스크 모델마다 용도·데이터·성능·한계를 문서로 남기게 하고, 소비자 대상 AI 제품에는 투명성 보고서가 붙는다. 항목은 모델 카드와 크게 다르지 않다. 문서화 수준을 정하는 방식에는 차이가 있다 — 민간 MRM은 모델을 위험 등급으로 나눠 등급이 높을수록 독립 검증·재검증 주기·문서화 수준을 올리고, 공공은 등급 대신 법이 정한 고영향 분류(AI 기본법)와 검수·감리 요구가 그 자리를 대신한다. 두 경우 모두 원리는 하나다 — 결정이 무거울수록 문서와 사람의 개입을 늘린다(보충의 모델 카드 → 데이터시트 → 시스템 카드 계층이 같은 원리다).

공공 사례

공공기관이 AI 모델을 발주·도입할 때 “모델 설명서”를 요구하지만, 실제로는 정확도 한 줄만 담긴 경우가 많다. 모델 카드는 용도·그룹별 성능·윤리적 위험·한계를 강제로 채우게 하여, 도입 심사에서 “이 모델의 편향과 한계를 발주처가 알고 있는가”를 확인 가능하게 만든다. 검수 질문: “제출된 모델 문서에 그룹별 성능과 윤리적 고려·한계 절이 있는가.” ### 핵심 정리 - 설명가능성은 편향의 현상 (16.2)을 원인으로 바꾼다 — champion 중요도 0.0 = 피쳐 무시 = 지역 못 나눔. - 선형 모델의 계수는 그 자체로 설명이며, 음의 permutation importance는 9장 반려와 일관된다. - 모델 카드 9절을 실측 증거에서 자동 생성한다 — 윤리적 고려·한계 절이 검수 자산의 핵심이다.

16.4 정책 AI 평가 기준: 법적 정합성, 중립성, 유해성

학습 목표

정책 AI를 평가하는 세 기준(법적 정합성·중립성·유해성)을 루브릭으로 설계한다.
LLM-as-a-judge의 한계와 독립 검증의 필요를 이해한다.

핵심 개념: 성능 지표로 환원되지 않는 평가

민원 건수 예측처럼 정답이 있는 문제는 MAE로 채점된다. 그러나 정책 질의에 답하거나 정책 효과를 판단하는 AI는 단일 정답이 없다 — “정치적으로 중립인가”, “사회적으로 유해하지 않은가”는 숫자 하나로 환원되지 않는다. 그래서 정책 AI는 성능 지표가 아니라 **루브릭(rubric)**, 즉 기준별 항목과 척도로 평가한다. 실습은 세 기준의 루브릭 초안을 생성했다(4점 척도: 0 부적합 / 1 미흡 / 2 충족 / 3 우수).

표 16.7 정책 AI 평가 루브릭 초안(`ch12_policy_rubric.json` — 3기준)

기준	핵심 질문	대표 항목	이 책의 근거
법적 정합성	근거 법령·목적 제한·이의제기를 충족하는가	근거 법령 명시, 목적 제한, 영향평가, 이의제기 절차	16.5·16.6 조문
정치적 중립성	특정 집단·지역을 체계적으로 불리하게 하지 않는가	그룹 형평 평가, 체계적 불이익 부재, 그룹측 근거	16.2 그룹 편향
사회적 유해성	오류의 방향·규모와 결정의 중대성에 비례하는가	오류 방향·피해 대상, 결정 중대성, 인적 개입	16.2 편향·16.6 이의제기

세 기준이 이 장의 앞 절에 그대로 걸린다는 점이 요점이다. 법적 정합성은 16.5·16.6의 조문으로, 정치적 중립성은 16.2의 그룹 편향 평가로, 사회적 유해성은 편향의 방향(누가 불리한가)과 16.6의 인적 개입 장치로 채워진다. 루브릭은 추상적 가치 선언이 아니라, 앞에서 만든 실측·조문을 채점 항목으로 조직한 것이다.

민간에도 이 자리에 놓이는 장치가 있다. 기업의 AI 윤리 위원회는 신규 AI 제품·기능의 출시 전 심사를 맡고, 심사 기준으로 공정성·투명성·프라이버시·안전성을 열거한 책임 AI 프레임워크를 쓴다. 항목은 표 16.7과 상당히 겹치지만 근거가 다르다 — 공공 루브릭은 법령 조문(제33조·제37조의2)에 직접 걸려 미충족이 곧 위법 소지가 되고, 기업 심사 기준은 자율 규범과 산업 표준(ISO/IEC 42001 등)에 근거해 미충족이 브랜드 위험·소송 비용으로 계산된다. 그래서 공공 루브릭의 “법적 정합성” 기준은 민간 심사표에서 준법 검토 한 항목으로 줄고, 대신 출시 일정·비용을 함께 저울질하는 항목이 붙는다.

LLM-as-a-judge의 한계 — 15장과 총 구분

루브릭 채점을 대규모로 하려면 사람 대신 LLM에게 채점을 맡기고 싶어진다(LLM-as-a-judge). 그러나 정책 AI 평가에서 이는 보조 수단이지 승인 근거가 아니다. LLM 채점기는 스스로 편향을 가질 수 있고, 특히 “정치적 중립성”을 LLM이 판정하게 하면 그 판정의 중립성을 다시 누가 보증하느냐는 순환에 빠진다.

이 “LLM이 스스로 편향을 가진다”는 말은 막연한 경고가 아니라 실증으로 확인된 현상이다. Zheng et al.(2023)은 LLM을 채점기로 쓸 때 세 가지 계통적 편향을 정량으로 보고했다 — **위치 편향**(두 답안을 비교할 때 앞에 놓인 답안을 선호), **장황 편향**(내용이 같아도 더 길게 쓴 답안에 높은 점수), **자기선호 편향**(자기 계열 모델이 생성한 답안을 편애). 적용 자격을 명시하면, 이 연구는 챗봇 답변 품질 평가라는 도메인에서 나온 것이라 정책 AI 채점의 직접 선례가 아니라 **배경 원리**로 인용한다. 그러나 함의는 그대로 옮겨온다 — 정책 AI 평가에서 답안 순서나 분량, 채점기와 피채점 모델의 계열이 점수를 변동시킨다면, 그 점수를 승인 근거로 사용하면 편향이 정책 결정에 직접 반영될 수 있다. 15장이 LLM 서비스의 위험(환각·프롬프트 인젝션·출처)을 다루므로, 여기서는 그 실측을 인용하지 않고 원칙만 짚는다 — **루브릭의 최종 채점은 사람과 독립 검증이 말고, LLM 채점은 1차 선별에 그친다**. 이 총 구분(보조와 승인)이 루브릭 각주의 핵심이며, 독립 검증의 필요는 보충에서 더

다룬다. 민간의 AI 품질 파이프라인도 같은 층 구분을 사용한다 — LLM 자동 평가로 전수를 평가하고 사람이 표본을 검수하되, 검수 비율은 비용에 맞춰 조정한다. 공공에서는 그 비율을 비용이 아니라 결정의 중대성이 정한다.

공공 사례

정책 문서 자동 검토 AI가 “이 보고서는 중립적”이라고 판정했다고 가정한다. 그 판정을 그대로 승인 근거로 쓰면, AI의 잠재 편향이 정책 결정에 직접 반영될 수 있다. 루브릭은 판정을 항목별로 나누어 (법령 근거 있는가·특정 집단 불이익 없는가·인적 개입 있는가), 각 항목을 사람이 확인 가능하게 만든다. 검수 질문: “정책 AI 평가에 법적 정합성·중립성·유해성 기준이 있고, 최종 채점을 사람·독립 검증이 하는가.” ### 핵심 정리 - 정책 AI는 단일 성능 지표가 아니라 기준별 루브릭(법적 정합성·중립성·유해성)으로 평가한다. - 세 기준은 앞 절의 실측·조문(그룹 편향·PIPA·이의제기)을 채점 항목으로 조직한 것이다. - LLM-as-a-judge는 보조이며, 최종 채점은 사람·독립 검증이 맡는다 (15장과 층 구분).

16.5 개인정보보호와 영향평가 검토 지점

학습 목표

개인정보 영향평가(PIA)의 법적 근거와 대상 기준을 안다.
목적 제한·민감정보 통제를 피쳐 등급과 연결한다.

핵심 개념: 공공기관의 개인정보 영향평가

개인정보 보호법 제33조(개인정보 영향평가)는 공공기관의 장이 대통령령으로 정하는 기준에 해당하는 개인정보파일을 운용할 때, 침해 위험요인을 분석하고 개선사항을 도출하는 평가를 실시하도록 정한다. 대상 기준은 대체로 민감정보·고유식별정보가 5만명 이상, 연계로 50만명 이상, 또는 100만명 이상의 정보주체가 포함되는 개인정보파일이다. 영향평가는 시스템을 만들기 전·바꾸기 전에 하는 **사전 검토**이며, 그 결과를 개인정보파일 등록 시 첨부한다.

표 16.8 개인정보 영향평가(PIA) 검토 지점(`ch12_fairness_report.json` — 제33조)

검토 지점	확인 내용
개인정보파일 운용 여부	피처가 개인을 식별 가능한가
영향평가 대상 규모	5만/50만/100만 기준에 해당하는가
목적·보유기간·목적 제한	목적이 명시되고 목적 밖 이용을 막는가(제18조)
민감정보 처리	별도 근거·안전조치가 있는가(제23조)
위험요인 분석·개선	문서화되었는가
결과 첨부	등록 시 영향평가 결과를 첨부하는가

영향평가는 실제로 어떻게 수행되는가

표 16.8이 “무엇을 확인하는가”라면, 실무자는 “절차가 어떤 순서로 진행되는가”를 알아야 한다. 개인정보 보호법 제33조는 영향평가를 기관 내부의 자체 점검으로 끝내지 않고, 공공기관의 장이 **보호위원회가 지정한 평가기관**에 의뢰하도록 정한다 — 자기 시스템을 자기가 평가하는 이해충돌을 구조적으로 줄이는 장치다(16.4의 “독립 검증” 원칙과 같은 정신). 현장의 순서는 대체로 다섯 단계다. 첫째, **대상 판정** — 운용하려는 개인정보파일이 규모 기준(민감·고유식별 5만, 연계 50만, 100만 이상)에 해당하는지 판정한다. 둘째, **자산·흐름 식별** — 어떤 개인정보가 어디서 수집돼 어디로 흐르고 누가 접근하는지를 도식화한다(13장의 접근 정책·소비자 등록이 이 산출물의 원재료가 된다). 셋째, **위험 분석** — 흐름의 각 지점에서 침해 가능성과 영향을 평가한다. 넷째, **개선과제 도출** — 위험별로 통제(암호화·접근제한·목적 제한)를 설계한다. 다섯째, **평가서 제출·이행** — 결과를 보호위원회에 제출하고 개인정보파일 등록에 반영하며 개선과제를 이행한다.

민간에도 같은 절차가 있다. GDPR은 고위험 처리에 DPIA(Data Protection Impact Assessment)를, CCPA(California Consumer Privacy Act) 대응 프로그램은 그에 준하는 사전 점검을 요구한다. 단계는 대상 판정 → 흐름 식별 → 위험 분석 → 통제 설계 → 문서화로 사실상 같다. 평가 주체에는 차이가 있다 — 공공은 보호위원회가 지정한 외부 평가기관에 의뢰하지만, 민간은 개인정보보호 책임자(Data Protection Officer, DPO)가 내부에서 수행하고 위험이 남을 때만 감독기관과 사전 협의한다. 그래서 민간에서는 “DPIA를 했는가”보다 신규 처리 활동 중 DPIA를 마친 비율(DPIA 완료율)이 관리 지표가 되고, 미완료 건이 곧 제재 위험으로 집계된다. 공공에서 이 지표에 대응하는 것은 대상 판정 누락 건수다 — 대상인데 판정하지 않은 파일이 하나라도 있으면 완료율이 아니라 위법이 된다.

이 절차가 코드 이전에 온다는 점이 핵심이다. 민원 예측 시스템을 가구·개인 단위로 확장하려는 순간, 개발자는 모델을 구현하기 전에 “이 파일이 대상인가”를 먼저 판정하고, 대상이면 위 다섯 단계가 개발 일정에 선행 공정으로 들어간다. 영향평가를 배포 후로 미루면 사전 검토 부재 자체가 감사에서 책임 문제가 되며, 이는 10장의 “배포 전 게이트”가 성능뿐 아니라 법적 정합성에도 적용됨을 뜻한다.

13장의 목적 제한·등급을 회수

프라이버시 통제는 13장에서 이미 기술적 골격을 만들었다. 13장의 접근 정책은 목적 밖 값 조회를 거부했고(제18조 목적 외 이용·제공 제한), 피쳐 접근 등급의 최상위는 건강·성생활 등 민감정보로 제23조(민감정보 처리 제한)의 별도 통제를 받았다. 여기서 조문 구분을 다시 강조한다 — **제18조는 개인정보 일반의 목적 제한, 제23조는 민감정보 한정**이다. 민감정보는 개인정보의 부분집합이므로 제23조를 개인정보 전체의 근거로 넓혀 인용하지 않는다. 이 프로젝트의 실습 피쳐는 전부 지역 단위 집계라 개인정보가 없어 영향평가 비대상이지만, 가구·개인 단위 피쳐로 확장되는 순간 제33조 대상 판정이 선행되어야 한다.

국내외 층 구분

개인정보 영향평가(PIA)는 EU의 기본권 영향평가(FRIA, EU AI Act 고위험 시스템)나 AI 기본법(인공지능 발전과 신뢰 기반 조성 등에 관한 기본법, 2026년 1월 시행)의 AI 영향평가와 목적이 겹치되 층이 다르다. PIA는 개인정보 침해 위험을, FRIA·AI 영향평가는 기본권·고위험 AI 위험 전반을 본다. 하나의 공공 AI 시스템이 세 평가의 대상이 될 수 있으므로, 각 평가가 무엇을 보는지 구분해 중복 없이 수행하는 것이 검토 지점의 실무다.

공공 사례

100만 시민의 민원 데이터를 개인 단위로 다루는 시스템을 새로 구축한다면, 코드를 작성하기 전에 제33조 영향평가가 선행되어야 한다. 이를 건너뛰면 배포 후 침해가 드러났을 때 사전 검토 부재 자체가 책임 문제가 된다. 검수 질문: “이 시스템이 영향평가 대상인지 판정했는가, 대상이면 결과를 등록에 첨부했는가.” ### 핵심 정리 - 개인정보 영향평가(제33조)는 공공기관의 사전 검토이며, 규모 기준에 해당하면 의무다. - 목적 제한(제18조)과 민감정보 처리 제한(제23조)은 적용 대상이 다르다 — 13장 통제의 법적 근거. - PIA·FRIA·AI 영향평가는 층이 다르며, 하나의 시스템이 셋의 대상일 수 있다.

16.6 자동화된 의사결정과 이의제기 절차

학습 목표

자동화된 결정에 대한 정보주체의 권리(거부·설명)를 법적 근거와 함께 이해한다.
편향 실측을 이의제기 절차 설계로 잇는다.

직관: 편향이 있다면 이의제기 통로가 있어야 한다

16.2는 champion이 강남을 체계적으로 과소예측함을 보였다. 만약 이 예측이 사람에게 영향을 주는 결정(예: 민원 대응 우선순위, 자원 배분)에 자동으로 사용된다면, 불리해진 쪽에는 그 결정을 **거부하고 설명을 요구할** 통로가 있어야 한다. 이것이 개인정보 보호법 제37조의2(자동화된 결정에 대한 정보주체의 권리 등)의 골자이며, 2024년 3월 시행되었다.

제37조의2는 완전히 자동화된 시스템(AI 포함)의 결정이 정보주체의 권리·의무에 **중대한 영향**을 미치는 경우, 정보주체에게 그 결정을 거부할 권리와 설명을 요구할 권리를 부여한다. 개인정보처리자는 거부·설명 요구가 있으면 정당한 사유가 없는 한 자동화된 결정을 적용하지 않거나 인적 개입에 의한 재처리·설명 등 조치를 해야 하고, 자동화된 결정의 기준·절차·처리 방식을 정보주체가 확인하도록 공개해야 한다. 중대한 영향은 생명·신체 안전, 권리 박탈, 의무 부담, 제한의 지속성·회복가능성을 종합해 판단한다.

표 16.9 자동화된 결정 이의제기 절차(ch12_fairness_report.json — 제37조의2)

단계	내용
고지	자동화된 결정의 기준·절차·처리 방식을 공개
거부권	중대한 영향을 주는 결정을 거부할 수 있게 함
설명요구권	결정에 대해 설명 등을 요구할 수 있게 함
인적 개입	정당한 사유 없으면 인적 재처리·설명 조치
기록	요구·조치를 로그로 남겨 감사에 답함(13장 평행)

편향 실측이 이의제기의 근거가 된다

이 절이 앞 절과 이어지는 지점이 여기서다. 16.2의 그룹 편향 평가는 “누가 불리한가”를 사전에 식별하고, 16.3의 모델 카드는 그 편향과 한계를 문서화한다. 제37조의2의 이의제기는 그 편향의 피해자가 **사후**에 결정을 거부하고 설명을 요구하는 통로다. 세 가지가 한 흐름이다 — 사전 편향 평가(16.2) → 문서화(16.3) → 사후 이의제기(16.6). 편향을 알고도 자동 적용하면서 이의제기 통로를 두지 않는 것은, 세 원칙(공정성·투명성·책임성)을 동시에 저버리는 일이다. 마지막 단계 “기록”이 13장 접근 로그와 평행하다는 점도 주목할 부분이다 — 이의제기와 그 조치가 로그로 남아야 감사에서 “이 사람의 이의제기에 무엇을 했는가”에 답할 수 있다.

워크드 시나리오: 강남 편향이 이의제기 통로를 만나면

표 16.9의 다섯 단계를 이 장의 실측에 얹어 구체화한다. 가정은 다음과 같다 — champion이 지역별 민원 대응 인력 배분을 자동으로 결정하는 데 사용되고, 강남구 담당자가 “우리 구는 늘 인력이 부족하다”고 이의를 제기한다.

고지: 배분 시스템은 “전일 민원 건수 기반 예측으로 인력을 배정하며, 지역 특성은 반영하지 않는다”는 결정 기준을 사전에 공개해야 한다. 이 공개가 없으면 담당자는 무엇에 이의를 제기할지조차 알 수 없다.

거부권: 담당자는 강남에 대한 자동 배정을 거부하고 재검토를 요구한다. 결정이 ‘중대한 영향’(지속적 인력 부족 → 민원 대응 지연)에 해당하는지가 판단 기준이다.

설명요구권: 기관은 “왜 강남이 6.0으로 배정되었는가”에 답해야 한다. 여기서 16.3의 설명 결과가 바로 답이 된다 — 모델이 상수라 지역 차이를 반영하지 못했고(permutation importance 정확히 0.0), 그 결과 실측평균 7.5인 강남을 6.0으로 과소예측했다.

인적 개입: 정당한 사유가 없으면 사람이 재처리한다. 16.2의 편향 실측(강남 MAE 1.5·편향 -1.5)이 “이 자동 결정은 강남을 체계적으로 과소 배분한다”는 정당한 재처리 사유의 증거가 된다.

기록: 이의제기·설명·재처리 전 과정을 로그로 남겨(13장 접근 로그와 동형) 감사에 답한다.

이 시나리오의 요점은 앞 절들이 사후 이의제기에서 **증거로 재활용**된다는 것이다 — 사전에 만든 편향 실측과 설명 문서가 없으면, 기관은 설명요구권에 “시스템이 그렇게 판정했다”밖에 답하지 못하고 이는 제37조의2 위반 소지가 된다.

국내외 정합

자동화된 결정의 통제는 국내법만의 것이 아니다. EU는 GDPR 제22조가 프로파일링 등 자동화된 결정에 대한 정보주체의 권리를 정하고, EU AI Act(Regulation 2024/1689)는 고위험 AI 시스템에 인적 감독(human oversight)을 요구한다. 국내 제37조의2와 이들은 “완전 자동화된 중대한 결정에는 사람의 개입 지점을 둔다”는 공통 원칙을 공유한다. 이 원칙은 10장의 승격 게이트에서 사람이 최종 판단을 내리던 지점과도 평행하다 — 자동화는 판단을 돕되, 중대한 결정의 최종 책임은 사람에게 남긴다. 다만 적용 폭은 다르다. 국내 제37조의2는 ‘중대한 영향’의 판단 요소를 법이 열거하지만, GDPR 제22조의 “법적 효력 또는 그에 준하는 중대한 영향”은 기업이 자기 서비스에 맞춰 해석할 여지가 넓다. 따라서 맞춤 광고나 보험료 산정의 해당 여부는 사업에 따라 달라질 수 있다.

역방향: 이 장의 설계를 민간 현장에 옮기면

지금까지는 공공의 법·정책이 요구하는 것을 정리했다. 반대 방향도 성립한다 — 이 장에서 만든 절차를 그대로 민간 현장에 적용하면 무엇이 유지되고 무엇이 바뀌는지 세 현장에서 확인한다.

채용 이력서 자동 선별에서는 절차가 거의 그대로 옮겨간다. 통과율을 성별·인종·출신학교로 분해하고, 어느 그룹이 최다 통과 그룹의 80%에 못 미치는지를 배포 전에 점검하고, 왜 그 그룹이 불리해졌는지를 설명 결과로 규명한다. 16.2의 그룹 분해와 16.3의 설명이 그 자리에 그대로 들어간다. 바뀌는 것은 둘이다 — 그룹축이 지역이 아니라 법정 보호속성이고, 지표가 회귀 MAE·편향이 아니라 분류 통과율·오류율이다. 방법은 같고 번역만 필요하다.

금융 신용평가 모델 위험관리는 16.4의 “최종 채점은 사람과 독립 검증이 맡는다”를 조직 구조로 굳힌 사례다. 미국 은행 감독은 신용 모델에 개발팀과 분리된 검증팀을 요구하고, 현장은 이를 1선(개발)·2선(검증)·3선(감사) 세 겹으로 나눈다. 공공에서 평가 기준을 설계하는 조직과 게이트를 집행하는 조직을 나누는 것과 같은 구조다. 근거만 다르다 — 공공은 이해충돌 차단과 감사 대응이, 민간은 감독당국 제재와 손실 위험이 분리의 이유다.

자동 프로파일링 거부권 운영은 표 16.9의 다섯 단계가 그대로 재현되는 현장이다. 맞춤 광고나 보험료 산정을 자동으로 결정하는 기업은 결정 기준을 고지하고, 거부를 받고, 설명하고, 사람이 재검토하고, 그 과정을 기록한다. 다른 점은 그다음이다 — 기업은 이 절차를 운영 지표로 바꿔 관리한다. 이의 접수부터 설명 제공까지 걸린 시간을 서비스 수준 계약(Service Level Agreement, SLA)으로 정하고 초과 건을 추적한다. 공공에서도 응답 기한은 관리 대상이지만, 기한을 정하는 근거가 고객 이탈률이 아니라 법이 정한 처리 기한과 시민의 권리 행사 실효성이다.

세 현장을 관통하는 것은 하나다. 그룹측 선택, 형평성 지표와 임계값, 설명·문서화 수준, 사람의 개입 지점 — 이 네 결정은 어느 도메인에서도 똑같이 내려야 하고, **근거만 도메인에 따라 달라진다**. 공공에서 그 근거가 법령 조문·감사 대응·정책 형평이라면, 민간에서는 규제 제재·소송 비용·브랜드 위험이다. 방향은 비대칭이다 — 공공 요구에 맞춰 설계한 시스템을 민간에 도입하면 문서와 검증이 다소 과할 뿐 손실이 없지만, 민간 자율 기준으로 만든 시스템을 공공에 그대로 적용하면 대개 법적 정합성 항목에서 미충족으로 판정된다.

공공 사례

자동 심사로 급여가 거부된 시민이 “왜 거부되었는지”를 물었을 때, 기관이 “시스템이 그렇게 판정했다”로 끝내면 제37조의2 위반 소지가 있다. 설명요구권은 결정의 기준·절차를 설명하고, 거부권은 인적 재처리를 요구할 수 있게 한다. 검수 질문: “자동화된 결정에 고지·거부·설명·인적 개입·기록의 다섯 단계가 구비되어 있는가.” ### 핵심 정리 - 제37조의2는 자동화된 결정에 거부권·설명요구권·인적 개입·공개를 부여한다(2024년 시행). - 편향 평가·문서화·이의제기는 사전→사후로 이어지는 하나의 책임 흐름이다. - 국내외(제37조의2·GDPR 제22조·EU AI Act) 공통 원칙은 중대한 결정에 사람의 개입 지점을 두는 것이다. - 그룹측·형평성 임계값·문서화 수준·사람의 개입 지점이라는 네 결정은 도메인과 무관하게 내려야 하고, 근거만 도메인에 따라 달라진다.

실습 16.1 형평성 기준 설계와 그룹별 성능 검증(★★★★☆☆)

이 실습은 **설계 → 실행 → 대조 → 위험 식별** 네 단계로 진행한다. 순서에 의도가 있다. 이미 정해진 지표로 계산부터 하면 왜 그 지표인지 묻지 않게 되고, 그러면 그룹 MAE 1.5는 “근거 없는 수치”로 남는다. 먼저 무엇을 형평으로 측정할지 자기 판단으로 정하고 결과를 예측한 다음 실측과 대조하면, 어긋난 지점이 곧 자기 기준의 결함이 된다. 감사·체크리스트는 그 뒤 4단계에서 다룬다 — 설계 근거와 실행 증거가 모두 확보되어야 검수 질문에 답할 수 있기 때문이다.

실습 목표

형평성 지표와 배포 차단 임계값을 **스스로 정하고 근거를 적는다**(설계).

9장 배포 모델을 재구성해 그룹별 성능(MAE·편향·캘리브레이션)을 실측하고, 설명 결과(계수·permutation importance)를 생성한다(실행).

자기가 정한 기준을 실측에 적용해 “이 모델은 배포 가능한가”를 판정하고, 지표 선택이 결론을 어떻게 바꾸는지 확인한다(대조).

모델 카드·정책 루브릭·공공 AI 검토 체크리스트를 실측 증거에서 자동 생성하고, 설계·증거를 위험 식별 표로 잇는다(검수).

입력 데이터

입력은 9장 산출물 스냅샷(`ch9_experiment_report.json`)의 훈련 쌍 6개다. 소유자·부서 표기는 9장과 동일하게 가상(시뮬레이션)이며, 지역구는 법적 보호속성이 아니라 운영 그룹측으로 쓴다. 모든 그룹 결과는 재구성한 실제 모델의 예측에서 산출되며(더미 없음), 지문 재계산으로 9장 훈련

데이터와의 동일성(96f6b6b3...)을 교차 확인한다.

1단계 설계 — 형평성 기준 설계표와 그룹 성능 예측

코드를 실행하기 전에 형평의 기준을 확정한다. 아래 요구사항을 읽고 표 16.10의 빈칸을 직접 채운다. 16.2의 서술은 지표의 성질만 설명할 뿐 값을 정해 주지 않으므로, 값과 근거는 스스로 적는다.

요구사항(가상 발주 조건) - 서울시 자치구별로 다음 날 민원 건수를 예측해 대응 인력을 배정한다. 배정 인력은 예측 건수에 비례한다. - 예측이 실제보다 낮으면 그 구의 민원 처리가 늦어지고, 높으면 인력이 남는다. - 자치구마다 평균 민원 수준이 다르다 — 상시 민원이 많은 구와 적은 구가 섞여 있다. - 감사 요구: 배포 전에 “특정 지역이 체계적으로 불리하지 않다”를 증거로 제출해야 한다. - 재검증 주기는 분기 1회이며, 그 사이에 모델은 바뀌지 않는다.

표 16.10 형평성 기준 설계표 — 학습자 작성용

항목	내가 정한 값	근거(요구사항의 어느 문장에서 나왔는가)
그룹측(무엇으로 나누는가)		
형평성 지표(무엇을 형평으로 측정하는가)		
격차의 표현(차 · 비 · 최악 그룹 절댓값)		
배포 차단 임계값		
임계값을 역산한 대상		
양보하는 공정성 정의		
이 설계가 깨지는 조건		

작성할 때 지킬 것이 넷이다. 첫째, 근거 칸에 “기본값이라서”, “보통 그렇게 한다”, “4/5 규칙이니까”를 쓰지 않는다 — 관행값을 골랐다면 그 값이 **이 발주 조건에서** 왜 맞는지를 적는다. 둘째, 임계값은 결정의 결과에서 역산한다(16.2). 역산에 사용할 값이 아직 없으면 무엇을 확인해야 확정할 수 있는지를 근거 칸에 적는다. 셋째, “모든 지표를 다 만족”을 임계값으로 쓰지 않는다 — 기저율이 다르면 통과 불가능한 게이트가 된다(16.1). 넷째, “양보하는 공정성 정의” 칸을 비우지 않는다. 무엇을 포기했는지 적지 않은 설계는 포기한 적이 없는 설계가 아니라, 포기한 줄 모르는 설계다.

그룹 성능 예측: 실행 스크립트는 9장 champion(상수 6.0)과 challenger(선형)를 재구성해 강남·마포·관악 세 그룹의 MAE와 편향을 낸다. 실행하기 전에 아래를 채운다.

	강남	마포	관악
champion MAE 예측			
champion 편향 부호 예측(+ 과대 / - 과소)			
실제(3단계에서 기입)			

한 줄을 더 예측한다 — 내가 1단계에서 고른 지표로 채점하면 **champion**과 **challenger** 중 어느 쪽이 강남에 덜 불리한가. 9장은 전체 MAE로 champion을 승격하고 challenger를 반려했다. 형평성 지표로 다시 채점해도 같은 답이 나올지 실행 전에 적어 둔다.

2단계 실행 — 9장 스냅샷에서 그룹 성능과 설명 재현

Python 3.10 이상(이 실습은 3.13에서 검증)과 scikit-learn·pandas면 된다 — 서버·컨테이너가 없다.

```
cd practice/chapter12
python3 -m venv venv
source venv/bin/activate          # macOS/Linux
# Windows: venv\Scripts\activate
pip install -r code/requirements.txt
python run_fairness.py
```

스크립트는 다음 순서로 진행하며, 각 단계가 절 하나에 대응한다.

단계	내용	대응 절
1	9장 훈련 쌍 로드 → 지문 재계산 .9장 교차 확인	16.1 책임성
2	champion·challenger 재구성	16.2·16.3
3	그룹별 MAE·편향·캘리브레이션 산출	16.2
4	계수·permutation importance 산출	16.3
5	모델 카드 9절 자동 생성	16.3
6	정책 루브릭·PIA·이의제기·공공 AI 체크리스트 생성	16.4·16.5·16.6

핵심 코드

그룹별 부호오차를 모아 MAE와 편향 방향을 계산하는 절차다.

```
err = pred - actual          # 부호오차: 음수 = 과소예측
mae = np.abs(err).mean()     # 크기
bias = err.mean()            # 방향(캘리브레이션)
```

전체 코드는 `practice/chapter12/code/12-2-fairness-xai.py` 참고

결정성 설계

그룹 예측은 재구성한 모델에서 나오고, permutation importance는 `random_state=0` 으로 seed를 고정한다. 증거 JSON은 `sort_keys=True` 로 저장하고 `now()` ·절대경로·휘발성 id를 쓰지 않는다. 그 결과 증거 JSON은 재실행해도 바이트 동일하다 — 두 번 실행해 `shasum` 비교로 확인했다. `.csv` · `.sqlite` 는 전역 무시라 커밋 증거는 JSON·MD뿐이다.

실행 중 확인 체크리스트

- ☐ 훈련 데이터 지문이 9장과 일치(96f6b6b3...)하는가
- ☐ 강남 MAE 1.5·편향 -1.5, 마포 0.5, 관악 1.0이고 그룹 MAE 격차 1.0·비율 3.0인가
- ☐ champion permutation importance가 0.0(상수=피쳐 무시)인가
- ☐ 모델 카드 9절이 모두 채워지고 8·9절(윤리·한계)이 있는가
- ☐ 공공 AI 검토 체크리스트가 12/12 통과하고 마지막 줄이 `CH16_RUN_PASS` 인가
- ☐ 증거 JSON을 재실행해도 바이트 동일한가
- ☐ 실행 전에 1단계 설계표와 그룹 성능 예측을 적어 두었는가(실행 후에 적으면 대조가 성립하지 않는다)

산출물 안내

산출물	내용	용도
<code>ch12_fairness_report.json</code>	그룹 편향·설명·루브릭·PIA·이의제기 통합 증거	이 장 인용 수치의 증거 파일
<code>ch12_model_card.md</code> / <code>.json</code>	모델 카드 9절(자동 생성)	편향성·설명가능성 평가 요약서
<code>ch12_policy_rubric.md</code> / <code>.json</code>	정책 AI 평가 루브릭 초안	16.4 산출물
<code>ch12_public_ai_checklist.json</code>	공공 AI 검토 체크리스트(자동 생성)	발주·검수 자산(12항목)
표 16.10 형평성 기준 설계표 (학습자 작성)	그룹측·지표·임계값과 각각의 근거	형평성 기준 설계표 — 검수 자산, 3단계 대조 후 확정

2단계 실행 결과(실제)

편향 평가: champion 전체 MAE 1.0이지만 그룹으로 나누면 강남 MAE 1.5·편향 -1.5(과소), 마포 0.5·+0.5, 관악 1.0·+1.0 — 그룹 MAE 격차 1.0·비율 3.0(표 16.3).

설명 결과: champion permutation importance 0.0(피쳐 무시 → 편향의 근본 원인), challenger 계수 0.4091·importance -0.0455(9장 반려와 일관) — 표 16.5.

모델 카드: 9절 자동 생성, 8·9절에 윤리적 고려·한계(소표본) 명시.

정책 루브릭: 3기준(법적 정합성·중립성·유해성) 생성. 공공 AI 검토 체크리스트 12/12 통과, `CH16_RUN_PASS` . 증거 JSON 재실행 바이트 동일.

3단계 대조 — 내 기준으로 채점하면 이 모델은 배포 가능한가

1단계 예측표의 “실제” 줄을 표 16.3의 값으로 채운다 — 강남 MAE 1.5·편향 -1.5, 마포 0.5·+0.5, 관악 1.0·+1.0. 그다음 1단계에서 정한 지표와 임계값을 이 실측에 적용해 배포 가능 여부를 판정한다. 지표별로 계산되는 값은 표 16.3·16.4에서 그대로 나온다.

형평성 지표	champion	challenger
그룹 MAE의 차(최악 - 최선)	1.0	1.4091
그룹 MAE의 비(최악 ÷ 최선)	3.0	3.8182
최악 그룹의 편향 절댓값	1.5(강남)	0.9545(강남)
(참고) 전체 MAE	1.0	1.0455

여기서 확인할 것 셋이다.

어느 지표를 선택했느냐에 따라 두 모델의 우열이 뒤집힌다. 그룹 MAE의 차·비로 채점하면 champion(1.0·3.0)이 challenger(1.4091·3.8182)보다 낫다. 그런데 최악 그룹의 편향 절댓값으로 채점하면 순서가 뒤집힌다 — 강남을 얼마나 낮게 예측하는지는 champion 1.5가 challenger 0.9545보다 크다. 1단계에서 “강남이 얼마나 덜 배정받는가”를 형평의 정의로 선택했다면 challenger를, “그룹 간 오차가 얼마나 벌어지는가”를 선택했다면 champion을 택해야 한다. 같은 실측에서 다른 결론이 나온다.

성능 게이트와 형평 게이트가 다른 답을 낼 수 있다. 9장은 전체 MAE(1.0 < 1.0455)로 champion을 승격하고 challenger를 반려했다. 형평을 최악 그룹 편향으로 정의하면 반려된 쪽이 낫다. 두 게이트가 어긋날 때 무엇을 우선할지는 코드가 아니라 정책이 정한다 — 1단계 설계표의 “양보하는 공정성 정의” 칸이 그 정책을 미리 적어 두는 자리다.

캘리브레이션을 선택했다면 champion은 어떤 임계값에서도 차단된다. 세 지역의 실측평균이 7.5·5.5·5.0인데 예측은 전부 6.0이다. 상수 모델이라 캘리브레이션 격차가 지역 간 실제 수준 차이 그대로다. 1단계에서 캘리브레이션을 우선 지표로 선택했다면 이 실측의 판정은 “배포 불가”이고, 그 판정 근거는 실측이 이미 제공한다.

예측이 어긋났다면 대개 한 가지를 빠뜨린 것이다 — **형평성 지표는 모델의 성질을 측정하는 도구가 아니라, 무엇을 불이익으로 볼지를 정의하는 규칙**이다. 편향의 크기를 측정하는 지표와 오차의 격차를 측정하는 지표는 같은 모델에 다른 점수를 준다. 어느 쪽이 옳은지는 데이터가 정하지 않고, 그 예측이 무엇에 쓰이는지가 정한다.

1단계 표 16.10으로 돌아가 “양보하는 공정성 정의”와 “이 설계가 깨지는 조건” 칸을 다시 쓴다. 처음에 비워 두었거나 막연히 적었다면, 지금은 실측을 근거로 작성할 수 있다. **설계표의 최종본은 이 수정을 거친 것이며, 과제로 제출하는 것도 이 최종본이다.**

관찰

모든 그룹 수치가 9장 예측에서 유도된다 — 이 실측은 새 데이터를 만들지 않고, 9장이 남긴 예측을 그룹으로 분해하고 설명·문서화했을 뿐이다.

하나의 전체 MAE(1.0)가 그룹 편향을 감춘다는 것이 이 장의 핵심 관찰이다 — 그룹 분해 없이는 강남의 3배 오차가 보이지 않는다.

설명가능성이 편향의 원인(피쳐 무시)을 규명하고, 그 처방(피쳐 개선)을 모델 카드 권고로 연결한다 — 현상·원인·처방이 한 흐름이다.

소표본이라 유의성이 아니라 구조를 시연한다는 명시가, 8·9·11·13장에서 이어진 “개수가 아니라 구조” 태도의 연장이다.

실습과 운영의 간극(축소 지점 목록)

표본 크기(6쌍 ↔ 수천), 그룹축(지역 ↔ 법적 보호속성), 공정성 지표(회귀 유사지표 ↔ 분류 parity-odds), 채점 주체(자동 체크 ↔ 사람·독립 검증). 축소된 것은 규모와 데이터이지 방법이 아니다 — 그룹 분해·편향 방향·설명·모델 카드·이의제기는 어느 규모에서든 같은 형태로 적용된다.

4단계 위험 식별 — 설계와 증거를 검수 언어로 옮기기

앞 세 단계에서 설계 근거(1단계)와 실행 증거(2·3단계)를 모두 확보했다. 검수·감사가 요구하는 것은 그 둘을 이어 붙인 형태다 — 무엇이 잘못될 수 있는가, 그렇게 판단한 근거가 어느 산출물의 어느 값인가, 무엇으로 막는가. 아래 표의 앞 네 행은 실행 증거에서, 뒤 두 행은 1단계 설계에서 나온다.

위험	실습에서의 근거	대응 방향
전체 지표가 그룹 편향을 은폐	전체 MAE 1.0과 강남 1.5	배포 전 그룹별 성능 게이트
피쳐 무시로 인한 체계적 편향	champion importance 0.0	그룹 특성 반영 피쳐·모델
편향 있는 자동 결정	강남 과소예측 방향성	자동 결정 금지·인적 개입 (제37조의2)
문서 없는 도입	모델 카드 8·9절 자동 생성	발주 시 모델 카드·체크리스트 요구
형평성 지표 선택이 배포 결론을 뒤집음	3단계 대조: 그룹 MAE 비로는 champion(3.0)이, 최악 그룹 편향으로는 challenger(0.9545)가 유리	지표·임계값을 배포 전에 확정해 문서로 남기고, 변경 시 이력과 사유를 기록
보지 않은 그룹축의 편향이 잡히지 않음	1단계 그룹축 선택: 지역으로만 나누면 연령·채널 편향은 평가에 없음	그룹축 선택 근거와 제외한 축을 모델 카드 3절(요인)에 명시

셋째 열이 비어 있거나 “모니터링한다”로 채워지면 그 행은 검수 문서에서 유용하지 않다. 대응 방향에는 **바꿀 임계값이나 바꿀 설계 결정**이 들어가야 한다.

제출물 3종: ① 표 16.10 형평성 기준 설계표(3단계 수정을 반영한 최종본), ②

ch12_fairness_report.json, ③ 위 위험 식별 표. ①이 설계, ②가 증거, ③이 둘을 이은 검수 자산이다. 자동 생성된 모델 카드·정책 루브릭·공공 AI 검토 체크리스트는 ②에 딸린 부속 산출물이다.

보충(전문가 트랙 포인터)

국내외 AI 규제 동향 비교: AI 기본법(인공지능 발전과 신뢰 기반 조성 등에 관한 기본법)은 의료·금융·범죄수사·생체인식 등 국민 권익에 직결된 분야를 **고위험 인공지능**으로 분류하고 위험관리·신뢰성 확보·AI 영향평가를 요구한다. EU AI Act(Reg. 2024/1689)는 Annex III로 고위험 시스템을 열거하고 기본권 영향평가(FRIA)·적합성 평가·인적 감독을 요구한다. 둘의 공통은 “위험이 클수록 문서·평가·사람 개입을 더한다”는 비례 원칙이다.

고위험 AI 문서화 수준: 모델 카드(모델 단위) → 데이터시트(datasheet, 데이터셋 단위) → 시스템 카드(system card, 시스템 단위)로 문서화 범위가 넓어진다. 고위험일수록 모델 하나가 아니라 데이터·시스템 전체를 문서화한다.

LLM-as-a-judge의 한계와 독립 검증: LLM 채점기는 자기 편향·프롬프트 민감성·일관성 부족을 가진다(15장 위험과 연결). 정책 AI의 중대한 판정은 서로 다른 관점의 독립 검증(사람·다른 방법·외부 감사)으로 교차 확인해야 하며, 단일 LLM 판정을 승인 근거로 쓰지 않는다.

핵심 용어

공정성/투명성/책임성/프라이버시/안전성: 공공 AI 다섯 원칙 — 각각 그룹 분해·모델카드·로그·목적제한·게이트에 대응

집단 공정성: demographic parity(결과 몫)·equalized odds(참·거짓 양성률)·calibration(점수 의미) — 셋은 상충 가능

공정성 불가능성 정리: 기저율이 다르면 캘리브레이션과 균형을 동시에 만족할 수 없음 (Kleinberg et al. 2016·Chouldechova 2017) — “무엇을 우선하나”가 정책 결정

전역 설명과 국소 설명: permutation importance(전역 — 모델 전체의 피처 의존)와 SHAP·LIME(국소 — 개별 예측의 근거) — 상수 모델은 둘 다 퇴화

보호속성과 운영 그룹측: 법적 보호속성(성별·연령 등)과 평가 편의상의 그룹(지역) — 방법은 동일

그룹 편향(회귀): 그룹별 MAE(크기)와 편향=평균 부호오차(방향)

형평성 임계값: 격차가 얼마부터 배포를 막는가 — 관행값이 아니라 결정의 결과에서 역산하고, 양보한 지표를 함께 밝힌다

permutation importance: 피처를 뒤섞을 때 성능 하락으로 측정하는 기여 — 상수 모델은 0

모델 카드: 모델 문서 9절 양식(Mitchell et al. 2019) — 용도·지표·윤리·한계

정책 AI 평가 루브릭: 법적 정합성·정치적 중립성·사회적 유해성 × 척도

개인정보 영향평가(PIA): 공공기관 사전 검토(개인정보 보호법 제33조)

목적 제한/민감정보: 제18조(개인정보 일반)/제23조(민감정보 한정) — 구분해 인용

자동화된 결정의 권리: 거부권·설명요구권·인적 개입(개인정보 보호법 제37조의2)

LLM-as-a-judge: LLM에 채점을 맡기는 방식 — 보조이며 단독 승인 근거 아님

검수 질문 한 줄 요약

발주·검수 문서에서 이 장은 다섯 질문으로 압축된다: ① 모델 성능이 그룹별로 분해되어 특정 집단의 체계적 불이익(부호 있는 편향)이 없는가, ② 예측 근거가 설명되고 모델 카드(윤리·한계 포함)로 문서화되는가, ③ 정책 AI 평가에 법적 정합성·중립성·유해성 기준이 있고 최종 채점을 사람이 하는가, ④ 개인정보 영향평가 대상 여부를 판정했는가, ⑤ 자동화된 중대한 결정에 거부·설명·인적 개입·기록 통로가 있는가. 다섯 다 답이 없으면 “윤리적 AI”는 구호일 뿐이다.

다음 장 예고

이 장은 시스템의 정당성을 물었다 — 공정한가·투명한가·책임지는가·프라이버시를 지키는가·안전한가. 17장은 여기서 한 걸음 물러나, 이 모든 장치를 갖춘 DE-MLOps 프로젝트가 **실제로 성공하려면** 무엇이 필요한지 — 성공 요인과 실패 패턴, 비용·품질·책임성의 균형, 포스트모템(postmortem)과 지속 개선, 그리고 평가·검증 조직(Policy Methodology Lab)의 역할 — 을 정리한다. 16장의 평가 기준·루브릭·모델 카드는 그 조직이 관리하는 승인 게이트의 내용물이 된다.

참고문헌

- Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). *Model Cards for Model Reporting*. Proceedings of FAT* '19. <https://arxiv.org/abs/1810.03993>
- Hardt, M., Price, E., & Srebro, N. (2016). *Equality of Opportunity in Supervised Learning*. NeurIPS. <https://arxiv.org/abs/1610.02413>
- Kleinberg, J., Mullainathan, S., & Raghavan, M. (2016). *Inherent Trade-Offs in the Fair Determination of Risk Scores*. arXiv. <https://arxiv.org/abs/1609.05807>
- Chouldechova, A. (2017). *Fair prediction with disparate impact: A study of bias in recidivism prediction instruments*. arXiv. <https://arxiv.org/abs/1610.07524>
- Barocas, S., Hardt, M., & Narayanan, A. (2023). *Fairness and Machine Learning: Limitations and Opportunities*. MIT Press. <https://fairmlbook.org/>
- Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., et al. (2023). *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. arXiv. <https://arxiv.org/abs/2306.05685>
- scikit-learn. (n.d.). *Permutation feature importance*. https://scikit-learn.org/stable/modules/permutation_importance.html
- 법제처. *개인정보 보호법* (제18조 목적 외 이용·제공 제한, 제23조 민감정보 처리 제한, 제33조 개인정보 영향평가, 제37조의2 자동화된 결정에 대한 정보주체의 권리). <https://www.law.go.kr/법령/개인정보보호법>
- 과학기술정보통신부. *인공지능 발전과 신뢰 기반 조성 등에 관한 기본법* (고영향 인공지능·AI 영향평가, 2026년 시행). <https://www.law.go.kr/lsInfoP.do?lsiSeq=268543>
- European Parliament and Council. (2024). *Regulation (EU) 2024/1689 (Artificial Intelligence Act)* (Annex III 고위험·기본권 영향평가·인적 감독). <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>