9주차 이 모델을 어떻게 만들었는지 어떻게 증명하는가

9주차 · 실험과 모델 관리

이 장의 수치는 대부분 `practice/chapter9/`의 코드를 실행해 얻은 값이다. 예시를 위해 지어 낸 숫자는 없다. 인용한 값의 출처 파일은 출력 블록 첫 줄에 적었다.

한 가지 예외가 있다. MLflow가 직접 남긴 실험 기록과 모델 등록 결과는 이 강의 환경에서 다시 돌릴 수 없어 **과거 실행이 남긴 산출물에서 옮긴 값**이며, 그 블록의 출처는 `practice/chapter9/data/output/`으로 적었다.

□ 7주차까지 만든 것은 데이터와 피처였고, 이 장에서 처음으로 **모델 훈련**이 등장함
○ 훈련이 등장하는 순간 따라오는 질문이 하나 있음 — 그 모델을 어느 데이터로, 어느 설정으로, 어느 코드로 만들었는가
○ 이 장은 그 답을 담당자의 기억이 아니라 시스템이 남긴 기록에 두는 방법을 다룸
□ 이 장도 설명과 실습을 나누지 않음
○ 절마다 실행할 명령이 나오고 그 아래에 실제 출력과 해석이 이어짐
○ 순서대로 실행하면 이 장의 수치를 직접 생성함

1. 오늘의 질문

□ 석 달 전에 배포한 모델을 지금 다시 만들 수 있는가. 무엇을 알아야 다시 만들 수 있는가.
□ 훈련 한 번에 무엇을 남겨야 "어떻게 만들었는가"에 답이 되는가.
□ 성능 기준을 통과한 새 모델을 운영에 넣지 않는 것이 옳은 경우가 있는가.
□ "지금 운영 중인 모델이 무엇인가"에 사람이 아니라 시스템이 답하게 하려면 무엇이 필요한가.

2. 이 장에서 실행할 것

□ 훈련을 여러 번 돌리는 일과 그중 하나를 운영에 넣는 일은 서로 다르고, 이 장은 둘을 나누어 다룸
○ 이 장에서 다루는 다섯 항목을 먼저 적음

이 장의 항목	무엇을 기록하거나 정하는가	다루는 절
run 하나 — 파라미터, 메트릭, 아티팩트(artifact)	훈련 한 번의 입력 설정·결과 수치·결과 파일	3
훈련 데이터의 지문(fingerprint) — sha256 해시	그 훈련에 쓴 데이터가 어느 것인지를 64자 값 하나로 고정	3·4
모델 레지스트리(registry)의 이름과 버전	배포 후보를 하나의 이름 아래 번호로 관리	5
champion 별칭(alias)	서빙 코드가 버전 번호 대신 조회하는 역할 이름	5
승격 게이트와 승격 검수 기록	어느 후보를 운영에 넣을지 정하는 규칙과 그 판정의 근거	5·6

표 9.1 이 장의 다섯 항목과 각각이 담당하는 것

□ 다섯 중 셋째와 넷째를 따로 짚어 둠
○ run을 수백 개 쌓아도 그것이 배포 후보 목록이 되지는 않음 — 실험 기록과 배포 승인은 다른 층

이고, 레지스트리가 그 둘을 구분함
○ 서빙 코드는 버전 번호를 쓰지 않고 champion 별칭만 조회하므로, 별칭을 v1에서 v3으로 옮기는 것이 곧 배포 행위임
□ 훈련에서 특히 확인할 것이 하나 있음
○ 코드·데이터·파라미터·환경이 같으면 훈련 결과는 완전히 같아야 함. 돌릴 때마다 값이 조금씩 달라지는 것이 정상인 작업이 아님
○ 그 동일성을 4절에서 숫자로 확인함

□ 실행하기 전에 네 가지를 먼저 적음
○ 남이 만든 산출물을 먼저 보면 거기 적힌 값이 정답으로 보여 “왜 이 값인가”를 묻지 않게 됨

표 9.2 예측표 — 실행하기 **전에** 채운다

예측할 것	내 예측	실제	어긋났다면 원인
단순한 평균 예측기와 선형회귀 중 훈련 오차가 작은 쪽			
원천 자료 한 칸이 1바뀌면 지문 앞 16자 중 그대로인 글자 수			
절대 게이트(오차 1.05 이하)만 두면 더 나쁜 후보가 운영에 들어가는가			
승격 검수 기록 13개 점검 항목 중 통과하는 수			

□ 이 장에서 실행할 코드는 넷이며 순서가 정해져 있음

순서	실행할 파일	하는 일	절	선행 조건
1	`9-2-training-pairs.py`	7주차 확정 집계에서 훈련 쌍과 지문 생성	3	없음
2	`9-3-train-and-rerun.py`	후보 둘 훈련·재실행 대조	4	없음
3	`9-4-gate-matrix.py`	게이트 규칙 셋으로 같은 후보 판정	5	없음
4	`9-5-review-record-check.py`	승격 검수 기록 점검	6	`data/output/ch9_promotion_record.json`(저장소에 포함)
선택	`9-1-mlflow-tracking.py`	같은 절차를 MLflow와 scikit-learn으로	3·5·6	`pip install -r code/requirements.txt`

□ 1~4번은 표준 라이브러리만 쓰므로 설치할 패키지가 없음(실습 검증 환경은 Python 3.13)
○ 선택 실습만 MLflow 3.14.0과 scikit-learn이 필요함

- **선택 실습은 패키지를 설치한 뒤에 돌린다**
- `9-1-mlflow-tracking.py`는 mlflow와 scikit-learn이 있어야 돌아간다. 없으면 아무것도 만들지 못하고 끝난다.
- 실행이 실패해도 다른 실습의 산출물은 남는다. 이 스크립트는 자기가 다시 만드는 실험 기록(`mlflow.db`·`mlruns/`)만 비우고, 산출물 JSON은 계산이 끝난 뒤 덮어쓴다.

3. run 하나에 무엇을 남기는가

□ 기록의 단위는 **run**임
○ 훈련을 한 번 돌리면 run 하나가 생기고, **실험(experiment)** 은 그 run들을 묶는 이름임
○ run 하나에 들어가는 것은 세 종류로 나뉨
□ **파라미터(params)는 훈련의 입력 설정임**
○ 모델 종류, 하이퍼파라미터(hyperparameter), 표본 수가 여기 들어감
○ "무엇을 넣었는가"에 답하는 항목임
□ **메트릭(metrics)은 훈련의 결과 수치임**
○ 이 실습에서는 훈련 MAE(Mean Absolute Error, 평균 절대 오차) 하나임
□ **아티팩트(artifacts)는 결과 파일임**
○ 모델 파일, 훈련 데이터 사본처럼 수치로 줄일 수 없는 실물이 들어감
□ 셋을 굳이 나누는 이유는 찾는 방식이 다르기 때문임
○ "학습률 0.01로 돌린 run 전부"는 파라미터 검색임
○ "오차가 가장 작은 run"은 메트릭 정렬임
○ "그 run의 훈련 데이터를 열어 보자"는 아티팩트 내려받기임
○ 셋이 한 run에 함께 있어야 기록 단위가 완결됨

□ 네 입력 중 셋은 도구가 자동으로 기록하지만 데이터는 자동으로 기록되지 않음
○ 코드는 git이 버전으로 남기고, 파라미터와 메트릭은 기록 도구가 자동으로 남김
○ 그런데 훈련 데이터는 **파일 경로가 같아도 내용이 바뀜** — 7주차의 정정 재실행이 그런 경우임
○ 그래서 훈련 데이터를 정해진 형식의 텍스트로 만든 뒤 sha256 해시를 찍어 **지문**으로 삼고, 그 지문을 파라미터에 넣음
□ 같은 훈련 데이터를 지문과 사본 양쪽으로 남기는 것은 중복이 아니라 용도 분리임
○ 지문은 가볍고 비교가 되므로 "같은 데이터였나"에 즉답함
○ 사본은 무겁지만 실물이라 "그 데이터를 다시 보자"에 답함

□ 첫 번째 코드를 실행함. 7주차 확정 집계에서 훈련 데이터를 만들고 지문을 찍음

```
cd practice/chapter9
python3 code/9-2-training-pairs.py
```

```
# □□: practice/chapter9/results/9-2-training-pairs.log
[1] □□ — 7□□ □□ □□ 3□ × □□ 3□
    □□ practice/chapter7/data/input/ch6_daily/
    □□          □□□(11440)  □□□(11620)  □□□(11680)
    2026-07-01           5           5           8
    2026-07-02           5           5           6
    2026-07-03           6           5           9

[2] □□ □ — (□□ □□ → □□ □□) 6□
    □□              □□ → □□      □□ □□  □□ □□
    □□□(11440)  2026-07-01 → 2026-07-02          5          5
    □□□(11440)  2026-07-02 → 2026-07-03          5          6
    □□□(11620)  2026-07-01 → 2026-07-02          5          5
    □□□(11620)  2026-07-02 → 2026-07-03          5          5
    □□□(11680)  2026-07-02 → 2026-07-03          6          9
    □□□(11680)  2026-07-01 → 2026-07-02          8          6

[3] □□□ CSV□ □□
    □ □         lawd_cd,x_prev_count,y_count
    □ □         6□ + □□□ 1□
    sha256
96f6b6b3ce9dcdd1da62e0284e0ceea1ec2afec24c522f6df3221ad0ab31f49e
    9-1 □□□
96f6b6b3ce9dcdd1da62e0284e0ceea1ec2afec24c522f6df3221ad0ab31f49e
    □□ □□    □ — □□ □□□□

[4] □□ □ □□ □□□ — □□□ 2026-07-03 □□ 6 → 7
    □□ □        (5,6) → (5,7)   □□□ 5□□ □□□
    sha256
07060a30f8e15e7b8b4f92e502f8acaf2403f0a85118cb5de2b096b364abaa34
    □□□□□ □□□□ □□ □  0
```

□ 화면에 나온 값에서 읽을 것
○ **훈련 데이터는 이 장에서 새로 만든 것이 아님** — 6주차 배치가 확정한 지역별 일계를 7주차가 피처로 받았고, 이 장은 그 3일치에서 (전일 → 당일) 쌍 6개를 만들었음. 지역마다 이틀분 전이가 나오므로 3지역 × 2 = 6쌍임
○ **지문은 정규화 형식이 정함** — 열 이름·열 순서·행 순서·줄바꿈을 고정한 CSV 한 덩어리에 해시

를 찍음. 같은 내용을 다른 순서로 적으면 다른 지문이 나오므로, 지문을 쓰려면 직렬화 규칙부터 고정해야 함
○ **과거 MLflow 실행이 남긴 지문과 같음** — 같은 데이터를 서로 다른 코드로 두 번 요약했는데 64자가 전부 일치함. 이 한 줄이 "9-10이 기록한 그 데이터가 지금 저장소에 있는 그 데이터"라는 증거임
○ **한 칸이 바뀌면 지문 전체가 바뀜** — 6을 7로 고쳤을 뿐인데 앞에서부터 일치하는 글자가 하나도 없음. 지문은 "조금 다르다"를 표현하지 못하고 같은가 다른가만 말함. 예측표에 8자나 12자를 적었다면 여기서 어긋남

□ 선택 실습을 돌리면 같은 값이 MLflow 기록에도 들어감

```
pip install -r code/requirements.txt
python3 code/9-1-mlflow-tracking.py
```

```
with mlflow.start_run(run_name="linear") as run:
    mlflow.log_params({"model_type": "LinearRegression", "data_sha256_16":
fp[:16]})
    mlflow.log_metric("train_mae", mae)
    mlflow.log_artifact(str(csv_path), artifact_path="training_data")
    model_info = mlflow.sklearn.log_model(model, name="model")
```

```
# ??: practice/chapter9/data/output/ch9_experiment_report.json
{
  "data_fingerprint_sha256":
"96f6b6b3ce9dcdd1da62e0284e0ceea1ec2afec24c522f6df3221ad0ab31f49e",
  "mlflow_version": "3.14.0",
  "sklearn_version": "1.9.0",
  "runs": {
    "baseline_mean": { "train_mae": 1.0 },
    "linear": { "train_mae": 1.0455, "coef": { "slope": 0.4091, "intercept":
3.6818 } }
  }
}
```

□ 화면에 나온 값에서 읽을 것
○ 파라미터·메트릭·아티팩트를 남기는 API가 각각 따로임 — 코드에서 셋을 구분해 부르는 것이 곧 나중에 셋을 따로 검색하는 근거가 됨
○ 지문은 도구가 자동으로 넣어 주지 않아 `log_params`에 직접 실어 보냈음. **자동으로 남는 것과 사람이 설계해 남기는 것의 경계가 여기임**

4. 훈련도 함수다 — 같은 입력이면 같은 모델

□ 6주차는 배치를 입력의 결정적 함수로 만들었고, 같은 입력이면 산출물 해시까지 같았음
□ 훈련도 같은 관점으로 봄
○ **모델 = f(코드, 데이터, 파라미터, 환경)** 이고, 네 입력이 전부 같으면 같은 모델이 나와야 함
○ 다만 훈련에는 배치에 없던 입력이 하나 더 있고, 코드에 값으로 적히지 않아 눈에 띄지 않음 — 초기화·셔플·샘플링이 난수를 쓰는 알고리즘이라면 seed까지 고정해야 함수가 됨
○ 이 장의 후보 둘은 난수를 쓰지 않는 결정적 알고리즘이라 seed 없이도 같은 값이 나옴
□ 아무것도 기록하지 않으면 재현이 아니라 새 모델이 나옴
○ 석 달 전 모델의 성능이 떨어져 "그때 모델을 다시 만들어 비교하자"고 할 때, 데이터·파라미터·코드 중 하나라도 확실하지 않으면 다시 만든 것은 그 모델이 아님
○ 비교 실험 자체가 성립하지 않음
□ 이것이 게으름의 결과가 아니라는 점이 중요함

○ 실험은 하루에 파라미터를 다섯 번 바꾸고 데이터를 두 번 갈아 끼우는 것이 정상임
○ 그 속도에서 "나중에 정리하자"는 반드시 실패하므로, 기록은 실험 **후**의 문서화가 아니라 실험 **중**의 자동 기록이어야 함

□ 두 번째 코드를 실행함. 후보 둘을 훈련하고 같은 설정으로 한 번 더 훈련함

```
python3 code/9-3-train-and-rerun.py
```

```
# □□: practice/chapter9/results/9-3-train-and-rerun.log
[2] □□ 1 baseline_mean — □□□ □□□□ y □□□ □□□□
    □□□       6.0  (= y □ 36 ÷ 6)
    □□ □□□  [1.0, 0.0, 1.0, 1.0, 3.0, 0.0]
    train_mae    1.0000

[3] □□ 2 linear — □□ □□□ 1□ □□
    slope        0.4091  (= 9/22)
    intercept    3.6818  (= 81/22)
    train_mae    1.0455
    → □□□ □□ □□□□□ □□□: 1.0455 > 1.0000

[4] 9-1(scikit-learn)□ □□ □□ □□
    baseline_mean train_mae    □□□ 1.0      □□ 1.0      □□ □
    linear train_mae           □□□ 1.0455   □□ 1.0455   □□ □
    linear slope               □□□ 0.4091   □□ 0.4091   □□ □
    linear intercept           □□□ 3.6818   □□ 3.6818   □□ □

[5] □□ □□□□ □□ □□(□□□)
    □□         96f6b6b3ce9dcdd1… → 96f6b6b3ce9dcdd1…
    train_mae    1.0455 → 1.0455   □□ True
    □□         (0.4091, 3.6818) → (0.4091, 3.6818)   □□ True

[6] □□□ □ □ □□ □□ □□ □□□ □□□ — □□□ □□□ □ □□ +1
    □□         96f6b6b3ce9dcdd1… → 07060a30f8e15e7b…   □□ False
    baseline_mean train_mae  1.0000 → 1.2222
    linear train_mae         1.0455 → 1.2576
    linear slope             0.4091 → 0.3182
```

□ 화면에 나온 값에서 읽을 것
○ **더 복잡한 모델의 오차가 기준선보다 컸음** — 선형회귀의 오차 1.0455가 평균 예측기의 1.0000보다 큼. 쌍 6개로는 의미 있는 기울기를 배울 수 없으므로 당연한 결과이며, 이 당연함이 5절의 판정을 사실대로 보여 줌
○ **계수가 분수로 정확히 나옴** — 기울기 9/22, 절편 81/22는 최소제곱 공식을 손으로 푼 값임. 라이브러리가 낸 값과 소수점 넷째 자리까지 같으므로, 모델이 무엇을 계산했는지 학생이 직접 검산할 수 있음
○ **다시 돌려도 같은 값이 나옴** — 지문도 오차도 계수도 동일함. 6주차의 "재실행 산출물 해시 동일"이 여기서 "재훈련 메트릭·계수 동일"이 된 것이며 같은 원리임
○ **입력이 한 건 바뀌면 지문과 메트릭이 함께 바뀜** — 지문이 달라졌고 오차는 1.0000에서 1.2222로, 기울기는 0.4091에서 0.3182로 바뀜. 6건 중 1건이 바뀌었을 뿐인데 학습된 함수가 달라짐

□ 거꾸로 읽으면 이 확인은 **회귀 검사**가 됨
○ "지난달과 같은 설정으로 돌렸는데 오차가 다르다"는 신고가 들어오면, 기록이 있는 한 추리가 아

니라 대조 절차가 됨
○ 값싼 대조를 먼저, 비싼 대조를 나중에 함
- 첫째, 두 run의 파라미터를 필드별로 비교함. 다르면 거기서 끝임 — “같은 설정”은 기억이고 파라미터 기록은 사실임
- 둘째, 파라미터가 전부 같아도 지문이 다르면 데이터가 바뀐 것임. 경로가 같아도 내용은 다름
- 셋째, 앞의 둘이 같으면 라이브러리 버전을 봄. 수치 계산 라이브러리의 마이너 버전 차이가 미세한 값 차이를 만드는 일은 실재함
- 넷째, 셋 다 같은데 다르면 고정되지 않은 난수를 찾음
□ 이 절차가 성립하려면 첫째·둘째의 기록이 **훈련 시점에** 이미 남아 있어야 함
○ 사고가 난 뒤에는 만들 수 없는 기록임
○ 정보공개 청구나 감사에서 “이 모델의 판단 근거를 소명하라”는 요구가 왔을 때 모델 파일만 가진 기관이 답하지 못하는 이유도 같음
○ 재현성은 연구자의 결벽이 아니라 **책임 소재의 전제 조건**임

5. 승격 게이트는 통과 규칙이 아니라 교체 규칙이다

□ 실험을 계속하면 run은 수십, 수백 개가 쌓임
○ 그것이 정상이지만, 서빙 시스템에 “run 목록에서 알아서 좋은 것을 골라 쓰라”고 할 수는 없음
□ 배포는 다른 규율을 요구함
○ 후보는 **이름 있는 모델의 번호 있는 버전**이어야 하고, 지금 운영 중인 것이 어느 버전인지 한 곳에서 답해져야 함
○ 그 질문에 한 곳에서 답하게 만드는 것이 **모델 레지스트리**임 — 하나의 이름 아래 배포 후보를 버전으로 관리하는 별도 저장소임
○ 각 버전은 자기를 만든 run을 가리키므로 기록과의 연결이 끊기지 않음
□ 운영 중인 버전을 가리키는 방법은 **별칭(alias)** 임
○ 버전에 champion 같은 가변 이름표를 붙이고, 소비자는 버전 번호가 아니라 역할 이름으로 모델을 불러옴
○ 별칭을 v1에서 v3로 옮기는 것이 곧 운영 모델 교체이며, 소비자 코드는 한 줄도 바뀌지 않음
○ 7주차에서 서빙이 피처를 정의 이름으로 조회했듯, 여기서는 모델을 역할 이름으로 조회함
□ 무엇을 통과시킬지 정하는 규칙이 **승격 게이트**임
○ 절대 게이트는 “오차가 얼마 이하일 것”처럼 후보 하나만 보고 판정함
○ 상대 조건은 “지금 운영 중인 것보다 나을 것”처럼 champion과 비교해 판정함
○ 둘은 다른 질문에 답하므로 하나만 두면 각각 다른 사고가 남

□ 세 번째 코드를 실행함. 같은 후보에 규칙 셋을 각각 적용해 판정이 갈리는지 봄

```
python3 code/9-4-gate-matrix.py
```

```
# ??: practice/chapter9/results/9-4-gate-matrix.log
[1] ?? 3? – ?? ?? ? 6?, ?? 96f6b6b3ce9dcdd1…
    ??              train_mae  ????? ????? ?   ??
    baseline_mean       1.0000  ??            ?? y ?? ?? – ???? ??
???
    linear              1.0455  ?? ??         ?? ???? 1? ??
    district_mean       0.6667  ?? ??         ???? y ?? – ????? ??
?? ??

[3] ?? ???? ? ?????? ?? – champion? baseline_mean(1.0000)
    ??                          linear(1.0455)
```

```
district_mean(0.6667)
    A □□□ (mae <= 1.05)          □□                    □□
    B □□□ (champion□□ □□)          □□(□□ □□)              □□
    C □ □                        □□(□□ □□)             □□

[4] □□ A(□□□)□ □□ □□□ □□□□□
    linear 1.0455 <= 1.05 □□□ □□ → champion□ 1.0000□□ 1.0455□ □□□
    □□ □□□ □□□ □□□□□ □□□ □□ □□□□□ □□□□

[5] □□□□ □□ □□□□ □□□ — mae <= 0.8
    baseline_mean       1.0000  □□
    linear              1.0455  □□
    district_mean       0.6667  □□
    □□ □□□ □□□□ linear□ □□ champion□ □□□□, □□ □□□□□□□
    baseline_mean(1.0000 < 1.0455) □□□ '□□' — □ □ □□ □□ □□□□ □
□□ □□□□

[6] □□ □□□ □□ — □□ C□ district_mean□ v3□ □□□ □
    champion=v1  □□□ □□ □□ 9.0 → □□ 6.00
    champion=v3  □□□ □□ □□ 9.0 → □□ 7.50
    □□ □□    v1 → v3 → (□□) v1     □□□ □□□ □ □□ □□□ □□□
    □□□ v2□ □□□ □□□ □□□ □□□□ □ □□ □□□ v1·v2 □□□

[7] □□□ □□□□□ □□□ □□□ — district_mean□ □□
    □□□ □□ □□  11440, 11620, 11680
    □□ □□ □□ 11110□ □□□  □□ None
```

□ 화면에 나온 값에서 읽을 것

○ **절대 게이트만 두면 더 나쁜 모델이 운영에 들어감** — linear는 1.0455로 임계 1.05를 넘지 않아 통과하고, champion이 1.0000인 모델에서 1.0455인 모델로 교체됨. 오차가 커졌는데 로그에는 “게이트 통과”만 남음. 예측표 셋째 줄에 “아니오”를 적었다면 여기서 어긋남

○ **상대 조건만 두면 못 쓸 모델끼리 교체가 계속됨** — 업무가 요구하는 오차가 0.8이라면 baseline_mean도 linear도 미달임. 그런데 둘 중 나은 쪽으로 바꾸는 규칙은 계속 작동해, 운영에 쓸 수 없는 모델이 바뀌기만 함

○ **둘을 함께 두어야 판정이 업무와 맞음** — 규칙 C에서 linear는 반려되고 district_mean만 승격됨. 절대 게이트가 “쓸 만한가”를 묻고 상대 조건이 “바꿀 이유가 있는가”를 물음

○ **별칭을 옮기면 같은 입력의 답이 바뀜** — 강남구 전일 건수 9.0에 champion v1은 6.00을, v3은 7.50을 냄. 소비자 코드는 그대로인데 결과가 달라지므로, 별칭 이동은 배포 행위이며 이력이 남아야 함

○ **반려된 버전을 지우지 않는 것이 롤백 준비임** — 되돌아갈 수 있는 버전이 v1과 v2로 둘임. 승격이 별칭을 앞으로 옮기는 일이면 롤백은 같은 동작의 역방향이므로, 버전을 지우는 순간 복귀 대상이 사라짐

- **오차가 작다고 운영에 맞는 모델은 아니다**
- `district_mean`은 오차가 0.6667로 가장 작지만 예측에 지역 코드를 요구하고, 훈련에 없던 지역 11110을 넣으면 값을 내지 못한다.
- 게다가 지역별 표본이 2개뿐이다. 게이트 지표 하나로 판정하면 이런 조건은 드러나지 않으므로, 승격 규칙에는 지표 외의 요건도 함께 적는다.

□ 9-1을 실행한 환경에서는 같은 판정이 레지스트리에 기록으로 남음

```
# ??: practice/chapter9/data/output/ch9_promotion_record.json
{
  "model_name": "complaint_daily_forecaster",
  "champion_version": 1,
  "gate_rule": "train_mae <= 1.05 ??? ?? champion ?? ??",
  "decisions": [
    { "version": 1, "train_mae": 1.0,    "metric_gate_pass": true, "promoted":
true,
      "action": "champion ?? ??(??)" },
    { "version": 2, "train_mae": 1.0455, "metric_gate_pass": true, "promoted":
false,
      "action": "?? ?? – ?? ??? ?????? ?? champion ?? ?? ?
?" }
  ]
}
```

□ 화면에 나온 값에서 읽을 것
○ v2의 `metric_gate_pass`가 `true`인데 `promoted`는 `false`임 — 절대 게이트 통과와 교체 승인이 서로 다른 칸으로 기록됨
○ 두 칸을 하나로 합치면 "왜 통과했는데 안 바꿨는가"라는 감사 질문에 답할 수 없음

6. 승격은 기술 행위가 아니라 승인 행위다

□ 앞의 세 절이 남긴 기록은 "어떻게 만들었고 얼마나 좋은가"에 답함
□ 공공 감사는 거기에 더해 물음
○ **누가** 만들었고, **무슨 목적**으로, **어느 기간의 어떤 출처** 데이터로, **어떤 제한** 아래 쓰이는가
□ 이 항목들은 성능과 무관하지만 책임과 직결되고, 나중에 소급 작성이 사실상 불가능함
○ 담당자는 이동하고 기억은 사라짐
○ 그래서 훈련 시점에 run의 태그(tag)로 함께 남김 — 실습이 붙인 최소 집합은 소유자·목적·데이터 출처·데이터 기간 넷임
□ 승격 판정 자체도 문서로 남음
○ 공공 운영에서 승격은 승인 행위이므로, 누가 어떤 규칙으로 어떤 근거를 보고 통과시켰는지가 남아야 함
○ 이 기록은 사람이 나중에 쓰는 보고서가 아니라 판정 로직이 그 자리에서 낸 출력이어야 함
□ 검수 기록에 재현성 확인이 별도 항목으로 들어가는 이유를 짚어 둠
○ 자동 게이트는 수치를 보고, 재현성은 그 수치를 믿어도 되는지를 봄
○ **재현되지 않는 run은 게이트 수치가 좋아도 승격 대상이 아님** — 그 수치가 코드와 데이터의 성질인지 우연인지 구분할 수 없기 때문임

□ 네 번째 코드를 실행함. 승격 검수 기록이 감사 질문에 답할 수 있는지 점검함

```
python3 code/9-5-review-record-check.py
```

```
# ??: practice/chapter9/results/9-5-review-record-check.log
[2] ?? ??? ??
    ??  ??  model_name          ??  ?????
    ??  ??  champion_version    ??  ??  ??  ??  ?  ????
    ??  ??  gate_rule           ??  ?????  ???????
    ??  ??  decisions           ?  ????  ????  ???????
    ??  ??  reproducibility_check  ?  ????  ??  ?????
```

```
    □□  □□ data_fingerprint_sha256 □□ □□□□ □□□□□□
    □□  □□ reviewer            □□ □□□□□□
    □□  □□ notes               □□ □□□ □□□
    □□  □□ □□□ □□                □□□ □□□ □□□□ □□ □□□□
          □□ 96f6b6b3ce9dcdd1… / □□□ 96f6b6b3ce9dcdd1…
    □□  champion □□            champion □□□ □□ □□□ □□□
          champion v1 / □□ □□ [1]
    □□  □□ □□ □□                □□□ □□□ □□□ □□ □□□
          □□ [2] — □□ □□□□□ □□□ □□ □□
    □□  □□□ □□                  □□ □□□□ □□ □□□ □□□□
          mae_equal=True coef_equal=True
    □□  □□□ □□                  □□□ □□□ □□□□□□
          reviewer='□□ □□(□□ — □□□□□□ □□)' — □□□□□□ □ □□ □□
□ □□
    → 12/13 □□

[3] □□□ □□□ □ — reviewer□ □□ □□□ □□ □□□ □□ □□
    □□  □□ reviewer            □□ □□□□□□
    □□  □□ □□□ □□                □□□ □□□ □□□□ □□ □□□□
          □□ 0000000000000000… / □□□ 96f6b6b3ce9dcdd1…
    □□  □□□ □□                  □□□ □□□ □□□□□□
    → 10/13 □□
```

□ 화면에 나온 값에서 읽을 것
○ **감사 질문을 점검 항목으로 옮겨 적을 수 있음** — 13개 항목 각각이 "어느 모델인가", "누가 확인했는가" 같은 질문 하나에 대응함. 기록 설계는 감사 질문 목록을 파일 스키마로 옮기는 일임
○ **지문 재계산 대조가 기록의 진위를 검증함** — 기록된 64자를 원천 자료에서 다시 계산해 맞춰 봄. 기록만 읽는 점검은 "값이 적혀 있다"까지만 확인하지만, 재계산은 "그 값이 사실이다"까지 확인함
○ **12/13에서 걸린 한 칸이 사람 칸임** — 나머지는 자동으로 채워지는데 검수자만 비었음. 교육용이라 가상 표기로 두었지만, 행정 처분이나 자원 배분에 쓰이는 모델이라면 이 칸이 비면 안 됨
○ **점검이 실제로 잡아냄** — 검수자를 빼고 지문을 다른 값으로 바꾼 사본은 10/13으로 내려감. 통과 수가 줄어드는 것을 확인해야 그 점검이 형식이 아님을 알 수 있음

□ 설계할 때 정할 것이 셋임
○ 게이트를 통과했을 때 승격을 자동으로 둘 것인가 사람 확인을 요구할 것인가
○ 게이트 미달인데 승격해야 하는 상황에서 누가 예외를 승인하는가
○ champion 별칭을 옮길 권한을 누가 갖는가
□ 셋째가 특히 실무적임
○ **모델을 훈련하는 사람과 별칭을 옮기는 사람이 같으면 게이트는 자기 검사에 그침**

7. 핵심 요약

□ **1. run 하나는 파라미터·메트릭·아티팩트로 완결되고, 데이터만은 직접 지문을 찍어야 한다.** (3절)
○ 입력 설정과 결과 수치와 결과 파일은 찾는 방식이 달라 나누어 남김
○ 코드는 git이, 파라미터는 도구가 자동으로 남기지만 훈련 데이터는 경로가 같아도 내용이 바뀌므로 sha256 지문을 파라미터로 실어 보냄
○ 원천 한 칸을 6에서 7로 고쳤더니 지문 앞 16자 중 일치하는 글자가 0개였음
□ **2. 같은 입력이면 같은 모델이 나오고, 안 나오면 무엇이 바뀌었는지 기록으로 가려낼 수 있다.** (4절)
○ 선형회귀를 다시 훈련해도 오차 1.0455와 계수 (0.4091, 3.6818)가 그대로였음

○ 입력을 한 건만 바꾸자 지문이 달라지고 오차가 1.0000에서 1.2222로 바뀌었음
○ 파라미터 → 지문 → 환경 → 난수 순으로 대조하되, 앞의 둘은 훈련 시점에 남겨야만 존재함
□ **3. 절대 게이트와 상대 조건은 다른 질문에 답하므로 둘 다 필요하다.** (5절)
○ 절대 게이트만 두면 1.0455가 임계 1.05를 통과해 1.0000인 현행 모델이 교체됨
○ 상대 조건만 두면 업무 기준 0.8에 둘 다 미달인 후보끼리 교체가 계속됨
○ 둘을 함께 둔 규칙 C에서만 linear가 반려되고 district_mean이 승격됐음
□ **4. 별칭 이동이 배포이고, 반려 버전을 남기는 것이 롤백 준비다.** (5절)
○ 같은 입력 9.0에 champion v1은 6.00을, v3은 7.50을 냈고 소비자 코드는 바뀌지 않았음
○ 반려된 v2를 지우지 않았기에 되돌아갈 수 있는 버전이 둘로 남았음
□ **5. 승격은 승인 행위이고, 검수 기록은 감사 질문 목록을 파일로 옮긴 것이다.** (6절)
○ 13개 점검 중 12개가 자동으로 통과했고 걸린 한 칸이 검수자였음
○ 지문을 원천에서 다시 계산해 맞춰야 기록의 진위까지 확인됨
○ 훈련하는 사람과 champion 별칭을 옮기는 사람이 같으면 게이트는 자기 검사에 그침

8. 과제

□ 실습을 순서대로 실행해 만든 산출물을 LMS에 제출한다

1. 표 9.2 예측표 — 실행 결과와 대조해 채운 최종본. 텍스트든 이미지든 형식은 무방하다.
2. `practice/chapter9/data/output/ch9_training_runs.json`
3. `practice/chapter9/data/output/ch9_gate_matrix.json`
4. `practice/chapter9/data/output/ch9_record_audit.json`
5. `practice/chapter9/data/output/ch9_experiment_report.json`

□ 5번은 선택 실습(`9-1-mlflow-tracking.py`)의 산출물이다
○ MLflow 설치가 막혀 실행하지 못했으면 저장소에 포함된 파일을 그대로 내고, 어디서 막혔는지 한 줄로 적는다

□ 이어서 네 가지를 각각 세 문장 이내로 쓴다

1. `ch9_training_runs.json`의 `data_fingerprint_sha256`과 `input_changed_one_cell.data_fingerprint_sha256`을 나란히 옮겨 적고, 훈련 데이터가 바뀐 것을 지문 없이 알아내려면 무엇이 필요한지 쓴다.
2. `ch9_gate_matrix.json`의 `gate_matrix`에서 규칙 A와 규칙 C의 `linear` 판정을 옮겨 적고, 두 판정이 갈린 이유를 쓴다.
3. `ch9_gate_matrix.json`의 `alias_move`에서 `forecast_champion_v1`과 `forecast_champion_v3`를 옮겨 적고, 별칭을 옮길 때 소비자에게 무엇을 알려야 하는지 쓴다.
4. `ch9_record_audit.json`에서 `pass`가 `false`인 항목을 찾아 이름을 적고, 그 칸을 채우려면 누가 무엇을 해야 하는지 쓴다.

□ 값을 지어내지 않는다
□ 실행이 안 되면 어디서 막혔는지 그대로 쓴다
□ 수업일 포함 7일 이내에 제출한다

9. 더 알아보기

□ 실습을 더 해 보려면 `practice/chapter9/`에서 다음을 시도함
○ `9-4-gate-matrix.py`의 `GATE_BUSINESS` 값을 바꿔, 임계를 몇으로 두면 어떤 후보도 통과하지 못하는지 찾음
○ `9-2-training-pairs.py`의 정규화 규칙(열 순서·정렬 기준)을 바꿔, 내용이 같은데도 지문이 달

라지는 것을 확인함
○ `9-5-review-record-check.py`의 `REQUIRED` 표에 항목을 더해, 자기 기관이라면 어떤 질문을 더 물을지 점검 항목으로 옮김
○ MLflow를 설치했다면 `mlflow ui --backend-store-uri sqlite:///data/output/mlflow.db`로 run 목록과 아티팩트를 화면에서 봄
□ 뒤 주차에서 이어지는 내용
○ 승격된 모델을 실제 서비스로 내보내고 되돌리는 절차는 10주차, 배포 후 성능이 경고 없이 나빠지는 것을 잡는 일은 11주차에서 실행함
○ 피처 수준의 권한·이력 관리는 12주차, 이 장의 기록을 이용자에게 설명하는 문제는 14주차에서 이어짐
□ 원문을 직접 보고 싶다면 다음 두 편이 출발점임
○ MLflow Documentation,「Model Registry」— 버전·별칭·단계의 정의. https://mlflow.org/docs/latest/ml/model-registry/
○ Mitchell 외,「Model Cards for Model Reporting」— 모델을 외부에 설명하는 공개 양식. https://arxiv.org/abs/1810.03993